Рабочая программа дисциплины

Системы искусственного интеллекта: обработка естественного языка

Авторская содержательная редакция для бакалавриата. Версия 2.0, сентябрь 2026 года. Программа сопровождается полными текстами восьми лекций, презентациями, лабораторными, данными и фондом оценочных средств.

Поля локального утверждения

Образовательная организация, направление и профиль подготовки, кафедра, курс и семестр, составитель, согласующие лица, протокол и дата утверждения заполняются кафедрой при включении дисциплины в конкретный учебный план. Коды компетенций и индикаторов определяются действующей образовательной программой вуза. Ниже заданы проверяемые результаты Р1–Р8 для сопоставления с компетенциями образовательной программы.

1. Цель и место дисциплины

Цель — научить студента строить, проверять и объяснять небольшие системы обработки естественного языка: от подготовки русскоязычного текста до классификации, поиска и генерации ответов по документам.

Курс последовательно вводит основы машинного обучения, разреженные и плотные представления, языковое моделирование, механизм внимания, перенос предобученных моделей, работу с LLM и RAG. Основной акцент — связь постановки задачи, данных, метрик и наблюдаемых ошибок. Знание названия модели без понимания эксперимента не считается результатом обучения.

Дисциплина предназначена для бакалавров, освоивших основы программирования на Python. Предварительный курс машинного обучения не требуется. Нужны функции, циклы, списки, словари, чтение файлов, базовое представление о массивах и школьная алгебра. Вероятность, логарифм, векторы и основные понятия обучения вводятся по мере необходимости. Выводы сложных оптимизационных алгоритмов в обязательный объём не входят.

Курс может входить в вариативную часть подготовки по информатике и смежным направлениям. Конкретное место, семестр и связь с официальными компетенциями устанавливаются учебным планом организации.

2. Планируемые результаты

По завершении дисциплины студент знает основные постановки NLP-задач, принципы токенизации и представления текста, назначение обучающей и проверочных выборок, базовые метрики классификации и поиска, вероятностную постановку языкового моделирования, устройство внимания и общую роль предобучения.

Студент умеет провести аудит корпуса, собрать воспроизводимый baseline, сравнить модели при контролируемом протоколе, получить эмбеддинги локальной модели, выполнить ограниченную генерацию, проверить источник ответа и локализовать ошибку системы RAG.

Студент владеет практикой документирования данных и параметров, сохранения исходных наблюдений, анализа ошибок и формулирования выводов в пределах проведённого эксперимента.

Код	Проверяемое действие	Подтверждение
Р1	Определяет единицу наблюдения, выявляет дефекты и обосновывает обработку текста	ЛР1, вопросы зачёта о данных
Р2	Обучает классификатор без утечки и интерпретирует accuracy/macro-F1	ЛР2, расчёт метрик и разбор split
Р3	Строит поиск в согласованном пространстве и оценивает ранжирование	ЛР3, косинус, Recall@k, MRR
Р4	Вычисляет вероятности n-грамм, NLL/PPL и объясняет генерацию	ЛР4, расчёт и анализ UNK
Р5	Вычисляет attention, проверяет маски и объясняет роль позиций	ЛР5, ручной пример и контроль будущего
Р6	Использует замороженный энкодер и различает способы переноса	ЛР6, сравнение с TF-IDF и pooling
Р7	Разделяет промпт, декодирование, формат и фактическую правильность	ЛР7, все исходные ответы и рубрика
Р8	Собирает RAG и различает ошибки поиска, упаковки и генерации	ЛР8, журнал, oracle и проверка источника

Лабораторные 6–8 используют готовые нейросетевые веса; работы 1–5 посвящены обработке данных, классическим моделям и вычислениям на NumPy. Дообучение большого Transformer, разработка веб-сервиса, обработка речи и мультимодальность не входят в обязательные результаты. RNN, NER, fine-tuning и

предпочтения ответов рассматриваются на уровне, указанном в содержании лекций.

3. Объём дисциплины

Единица планирования — академический час 45 минут. Одно занятие длится 90 минут и соответствует двум академическим часам. Общая трудоёмкость — 72 академических часа, или 54 астрономических часа. При принятом в учебном плане эквиваленте 36 академических часов это 2 зачётные единицы; окончательное обозначение закрепляет вуз.

Вид работы	Академические часы
Лекции: 8 × 2	16
Лабораторные: 8 × 2	16
Самостоятельная работа	38
Промежуточная аттестация: устный зачёт	2
Итого	72

Лекции интерактивные: речь преподавателя, вопросы, ручные расчёты и обсуждения входят в 90 минут. Лабораторные проводятся отдельными занятиями. Подготовка библиотек и моделей выполняется до аудиторного запуска и включена в самостоятельную подготовку.

4. Тематический план

№	Тема	Лекц.	ЛР	Самост.	Результат практики
1	Текст как данные: задачи, корпус, нормализация, токенизация	2	2	4	Аудит корпуса и политика обработки
2	TF-IDF, обучение классификатора и честная оценка	2	2	5	Baseline, validation, test и ошибки
3	Эмбеддинги, косинус и поиск	2	2	4	TF-IDF/SVD, выдача и метрики
4	Языковая модель: n-граммы, сглаживание, RNN	2	2	4	NLL/PPL, выбор порядка и генерация

№	Тема	Лекц.	ЛР	Самост.	Результат практики
5	Attention и Transformer	2	2	5	Реализация внимания и проверки масок
6	BERT, перенос и контекстные представления	2	2	5	Замороженный CLS и классификация
7	LLM: инструкции, декодирование, проверка ответа	2	2	5	Сравнение промптов, sampling и JSON
8	RAG: источники, контекст и оценка системы	2	2	6	Система ответов и диагностика компонентов
Всего по темам		16	16	38	70 часов

Дополнительно 2 часа отведены на зачёт. Рекомендуемая последовательность — восемь недель по одной лекции и одной лабораторной в неделю; иной календарь допустим при сохранении порядка предпосылок.

5. Содержание разделов

1. Данные и предобработка

NLP как семейство задач над естественным языком. Различие строки и независимой ситуации. Неоднозначность слов и меток. Схема корпуса, происхождение, пропуски, дубликаты, конфликтная разметка. Unicode/NFC, пробелы, регистр, отрицание, коды ошибок. Токенизация, ограниченная демонстрация лемматизации, зависимость предобработки от задачи. ЛР1: аудит основного и специально испорченного корпуса, сравнение преобразований и собственные контрпримеры.

2. Классификация текста

Объект, признак, метка, модель, обучение и предсказание. Train/validation/test и групповые варианты одной ситуации. Мешок слов, n-граммы, TF, IDF, нормировка. Линейная классификация и логистическая регрессия на уровне интерпретируемой постановки. Pipeline, постоянный baseline, confusion matrix, accuracy, precision/recall/F1, macro-усреднение, дисбаланс и утечка. ЛР2: TF-IDF по словам и символам, выбор на validation, окончательный test и фактический разбор ошибок.

3. Представления и поиск

Разреженный вектор и плотное представление. Косинус и его геометрия, влияние масштаба. SVD как учебный способ уменьшить размерность; смысл и ограничения проекции. Дистрибутивная идея Word2Vec, подсловные признаки fastText, контекстные представления. Индекс известной коллекции, согласованность пространств, ранжирование, Recall@k и MRR@k. ЛР3: два индекса одной базы, сравнение выдач, поиск без ответа и ограничения двумерной картинки.

4. Вероятностное продолжение последовательности

Цепное разложение, ограничение истории n-граммой, подсчёт частот, BOS/EOS/UNK, сглаживание. Отрицательный логарифм правдоподобия, perplexity и условия сопоставимости. Редкий словарь и искусственное снижение сложности через UNK. Greedy и sampling, локальный и глобальный максимум. RNN: состояние, рекуррентная связь, следующий токен и teacher forcing. ЛР4: unigram/bigram/trigram на группах train, выбор по validation PPL, test и сохранённые генерации.

5. Attention и Transformer

Q/K/V, масштабированное скалярное внимание, устойчивый softmax. Строковая нормировка, causal- и padding-маски, недопустимость полностью закрытой строки. Роль позиционной информации, перестановочная эквивариантность без позиций и масок, multi-head. Остаточные связи, нормировка, feed-forward и семейства encoder/decoder/encoder-decoder. Память матрицы внимания и отличие весов внимания от доказанного объяснения. ЛР5: NumPy-реализация, ручной пример, контроль влияния будущего, padding и позиций.

6. Предобученный энкодер

BERT и masked language modeling, двунаправленный контекст, специальные токены. Токенизация и ограничение длины. CLS и masked mean, выбор pooling по конкретной модели. Замороженные признаки и fine-tuning, режим eval и отключение градиентов. Классификация документов и общая постановка NER с BIO-

разметкой и сущностными метриками. ЛР6: rubert-tiny2, пакетное кодирование, воспроизводимость, сравнение с char-TFIDF и анализ усечения.

7. Генеративная LLM

Предобучение, демонстрации инструкции, обучение по предпочтениям: назначение сигналов и пределы фактической надёжности. Zero/few-shot, контекст и веса, chat template, роли сообщений. Temperature, top-p, greedy, лимит входа и новых токенов. Извлечение только продолжения. Формат JSON и содержательная проверка, неизвестный факт, условие и обрыв. ЛР7: две инструкции на трёх вопросах, фиксированные sampling-запуски, строгий валидатор и ручная рубрика исходных ответов.

8. Система RAG

База, фрагмент и происхождение, версия и индекс. Извлечение и упаковка, измерение полного промпта, retrieved_ids/included_ids. Ответимость, поддержка утверждения и ссылка. Компонентные метрики, единый знаменатель и границы малой диагностической выборки. Empty-контекст, oracle как отдельный опыт. Косвенная инъекция через источник и ограниченность единичного зонда. ЛР8: локальный поиск, последовательная загрузка моделей, 12 основных генераций, два диагностических случая и журнал для анализа.

6. Самостоятельная работа

Тема	Часы	Задания и предъявляемый результат
1	4	Термины и источники 1; пояснения в ноутбуке 1; пять контрольных примеров 1; повторный запуск и защита 1
2	5	TF-IDF и метрики 1; ручной расчёт 1; ноутбук и разбор ошибок 2; защита 1
3	4	Косинус и источники 1; сравнение выдач 1; пояснения в ноутбуке 1; защита 1
4	4	Вероятности и PPL 1; анализ генераций/UNK 1; пояснения в ноутбуке 1; защита 1
5	5	Формулы внимания 1; ручные вычисления 1; маски и позиции 1; пояснения в ноутбуке 1; защита 1
6	5	Подготовка энкодера и карточка 1; pooling/усечение 1; ошибки классификации 1; пояснения в ноутбуке 1; защита 1
7	5	Подготовка генератора 1; промпты и декодирование 1; фактическая рубрика 1; пояснения в ноутбуке 1; защита 1

Тема	Часы	Задания и предъявляемый результат
8	6	Проверка двух моделей 1; таблица RAG 1; диагностика и улучшения 1; пояснения в ноутбуке и повторный запуск 1; подготовка к зачёту 2
Итого	38	

Подготовка среды и загрузка моделей выполняются до занятия. Если нужно, преподаватель организует разрешённое локальное копирование заранее загруженного кеша.

7. Образовательные технологии

Каждая лекция имеет полный сценарий речи, план с минутами и визуальную опору примерно из 20–25 слайдов. К каждому слайду привязаны раздел и точная цитата-якорь; заметки содержат краткое объяснение, пример, комментарий и переход. Формулы сопровождаются ручным примером, а заявленные наблюдения — воспроизводимым кодом или явной маркировкой условных данных.

Лабораторная начинается с задачи и рабочего примера. Студент завершает предложенные функции, запускает открытые проверки, получает наблюдения и объясняет их в ноутбуке. Готовая инфраструктура загрузки модели уменьшает техническую нагрузку; задание сосредоточено на конкретном механизме занятия. Собственные примеры исследуются отдельно от исходного теста.

Преподавательская версия содержит решения, сохранённые результаты и конкретную интерпретацию ошибок. Она выдаётся преподавателю отдельно. Для занятия без сети используются заранее загруженные модели; при неисправности среды возможен разбор сохранённых наблюдений с последующим подтверждением собственного запуска.

Материалы предоставлены в DOCX/MD и PDF; код — в IPYNB. PDF позволяет читать без Office, редактируемые файлы — адаптировать размер шрифта и подачу. Смысл схем не кодируется только цветом: используются подписи, направления и числа. По образовательным потребностям студента преподаватель может увеличить время защиты или предоставить текстовую форму ответа с сохранением оцениваемого результата и в соответствии с правилами организации.

Пояснения и анализ результатов сдаются в выполненном ноутбуке. Для ЛР8 также сохраняется автоматически созданный журнал запросов и ответов. Дополнительный текстовый отчёт не требуется.

8. Оценивание и промежуточная аттестация

Текущий контроль — восемь лабораторных, каждая по 100 баллов. Общая структура: корректность 40, эксперимент 30, интерпретация 20, защита 10. Детализация применительно к каждой работе дана в её методичке. Порог сдачи каждой работы — 60. Проверяется предъявленный результат; ошибки небольшой модели сами по себе не снижают оценку корректно проведённого и объяснённого эксперимента.

Для итогового зачёта должны быть сданы все восемь лабораторных. Устный зачёт содержит два теоретических вопроса и практический случай; веса 30+30+40, порог 60. Итог «зачтено» выставляется при выполнении обоих условий: сданы все работы и набрано не менее 60 на зачёте. Высокий средний балл лабораторных не компенсирует несданную работу.

Фонд оценочных средств включает 16 билетов, публичную рубрику и отдельные преподавательские ключи. Вопросы требуют объяснения механизма и применения к небольшому примеру. Перечень билетов может использоваться для подготовки; конкретный билет определяется преподавателем при проведении зачёта.

Рекомендуется 15–20 минут подготовки и 12–15 минут индивидуального ответа. Два академических часа в плане — трудоёмкость аттестации студента, а не обещание принять произвольную группу за 90 минут. Для большой группы кафедра составляет очереди или несколько сеансов. Организационный график не меняет содержание критериев.

При недостаточном результате студент получает замечания по критериям, исправляет работу или повторяет зачёт в порядке, установленном организацией. Этот комплект не подменяет локальные правила сроков, допуска и пересдачи.

9. Учебные ресурсы и данные

Основное чтение — полные тексты L01–L08 и указанные в них первичные источники. Центральный открытый учебник: Jurafsky, Martin, Speech and Language Processing, 3rd edition draft, https://web.stanford.edu/~jurafsky/slp3/. Прямые ссылки на источники даны в лекциях. Онлайн-черновик следует сверять перед новым учебным годом.

Дополнительные первичные источники: Mikolov et al. (2013), Word2Vec; Bojanowski et al. (2017), fastText; Vaswani et al. (2017), Transformer; Devlin et al. (2019), BERT; Brown et al. (2020), few-shot; Ouyang et al. (2022), обучение инструкциям; Lewis et al. (2020), RAG. Прямые ссылки и оговорки по применимости приведены в соответствующих лекциях. Документация: scikit-learn, PyTorch, Hugging Face Transformers и карточки двух закреплённых моделей.

Данные созданы для этого курса. Основной корпус: 600 обращений, 120 базовых ситуаций по пять вариантов, шесть классов, разбиение 360/120/120 с разделением

групп. Аудит: 24 намеренно проблемные записи. База знаний: 12 коротких документов. Поисковые вопросы: 30, из них 24 с ответом и шесть без ответа в базе.

Все правила университета «Север» вымышлены. Малая синтетическая коллекция позволяет разбирать каждый пример, но не является репрезентативной выборкой реального потока. Некоторые авторские метки неоднозначны без дополнительного контекста; это отражено в паспорте и преподавательских комментариях. Контрольные суммы и схема находятся в `data/manifest.json` и `data/README.md`.

10. Программное и материальное обеспечение

Для студента: компьютер с 64-битным Python, CPU, JupyterLab, NumPy, pandas, scikit-learn, matplotlib, PyTorch и Transformers. Ориентир — 8 ГБ ОЗУ; перед генеративными работами закрываются лишние приложения. Точные проверенные версии записаны в `requirements-lock.txt`; команды подготовки — в `START.md`.

GPU, платные модельные API и постоянный интернет для обязательных работ не требуются. Модели скачиваются заранее из публичных репозиториев с закреплёнными ревизиями. Все вызовы в ноутбуках используют локальные файлы. Интернет нужен для первичной подготовки и чтения внешних источников.

Для лекций: проектор или большой экран 16:9 и средство просмотра PDF либо PowerPoint. Для изменения содержимого доступны DOCX и PPTX. Локальная авторская сборка использует python-docx, PptxGenJS через MCP, MathJax, Sharp, LibreOffice и Poppler; студенту не нужно выполнять её для лабораторных.

В комплекте есть протоколы фактических запусков и результаты независимых рецензий. Исторические замеры ресурсов относятся к первой редакции вычислительных опытов. Замер на машине с 31,1 ГБ не называется проверкой на физическом компьютере с 8 ГБ. Перед первым проведением преподаватель проверяет наиболее тяжёлые ЛР7–ЛР8 на оборудовании аудитории. Последовательная загрузка моделей и ограниченный контекст уменьшают одновременную потребность в памяти.

11. Состав учебного комплекта

Студенту: РПД, инструкция запуска, билеты и рубрика; восемь текстов лекций; восемь PPTX и PDF; восемь методичек и ноутбуков с заданиями; данные, версии зависимостей и загрузчик моделей.

Преподавателю дополнительно: краткие планы с распределением времени, выполненные решения, исходные журналы генерации, ключи билетов, карты соответствия слайдов, отдельные заметки, отчёты проверок. Исходники материалов и скриптов сборки предоставляются отдельным архивом для адаптации курса.

При изменении лекции обновляется связанный сценарий слайдов. При изменении данных, кода или моделей пересчитываются затронутые результаты и преподавательские выводы. Так сохраняется согласованность речи, визуальной опоры и лабораторного эксперимента.