Предобученный энкодер

От восстановления слов
к классификации обращений

Архитектура, веса и наша задача

Архитектура	Какие вычисления выполняются
Веса	Какие преобразования уже обучены
Наша система	Токенизатор, pooling и классификатор

rubert-tiny2: 3 слоя · 12 голов · 312 координат

Конфигурация закреплённой модели

Восстановление видит обе стороны

«Студент положил книгу в **[MASK]**,
чтобы нести её домой»

Исходное слово — цель

сумку

Доступное окружение

Слева и справа

Учебный пример masked language modeling

Выбранные цели не все скрыты

Исходный BERT: из 1000 токенов выбираем около 150 целей

Заменены [MASK]	Случайный токен	Не изменены
120	15	15
80% выбранных	10% выбранных	10% выбранных

15% относятся ко всем токенам; 80/10/10 — к выбранным

Devlin et al., 2019 · ожидаемые пропорции

Три разные роли маски

Маска	Что меняет
[MASK]	Содержимое выбранного токена
Padding mask	Доступ к техническим позициям
Causal mask	Доступ к будущим позициям

Одинаковое слово обозначает разные операции

Токены принадлежат этой модели

«Как продлить книгу?»

0	1	2	3	4	5
[CLS]	Как	продлить	книгу	?	[SEP]

Шесть позиций, включая специальные

Токенизатор rubert-tiny2 · реальные названия токенов

Padding выравнивает пакет

attention_mask · два текста, шесть позиций

Текст	0	1	2	3	4	5
Вопрос о книге	1	1	1	1	1	1
Спасибо	1	1	1	0	0	0

1 — позиция входа, 0 — техническое дополнение

Вектор для каждой позиции

last_hidden_state

B: тексты	L: позиции	Координаты
2	6	312

Форма показанного пакета: 2 × 6 × 312

CLS выбирается у всех текстов

CLS находится в позиции 0 каждого текста

$$\text{hidden}[:, 0, :] \rightarrow 2 \times 312$$

L2-нормировка по оси признаков

Способ pooling, рекомендованный автором rubert-tiny2

Padding попадает в среднее

Отдельный пример mean pooling

Позиция	Вектор	Маска m
1	(1; 0)	1
2	(0; 1)	1
PAD	(9; 9)	0

Маска ключей не обязана занулять выход padding-позиции

Учебные векторы для ручного расчёта

Маска выбирает слагаемые

Все три позиции

(10/3; 10/3)

≈ (3,3333; 3,3333)

Только выбранные маской

(1/2; 1/2)

= (0,5; 0,5)

Masked mean = Σ m_t h_t / Σ m_t

Что меняется при дообучении

Готовые признаки	Учится только новый классификатор
Fine-tuning	Меняются и энкодер, и голова
Адаптеры / LoRA	Учится ограниченная часть параметров

В этой работе энкодер фиксирован

Три настройки решают разное

Вызов	Что регулирует
eval()	Поведение модулей, включая dropout
requires_grad_(False)	Нужны ли градиенты параметрам
inference_mode()	Построение графа autograd

Для фиксированных признаков задаём условия явно

От пакета к признакам

Те же два демонстрационных текста

Токенизатор	→	Энкодер	→	CLS + L2
2 × 6		2 × 6 × 312		2 × 312

Сохраняем порядок текстов и соответствующих им меток

Индекс меняет форму результата

Выражение	Форма при B=2
hidden[:, 0, :]	2 × 312
hidden[0, 0, :]	312

Во втором случае остаётся только первый текст

NER: границы и типы

BIO-разметка на уровне слов

Анна	Петрова	учится	в	университете	Север
B-PER	I-PER	O	O	B-ORG	I-ORG

Границы задаются принятой инструкцией разметки

Ручной пример · классификационная голова не является NER-головой

Граница имени тоже часть ответа

Пример строгой оценки сущностей

Эталон PER	Предсказано PER
Анна Петрова	Петрова

Тип совпал; точные границы — нет: один FP и один FN

От слова к подтокенам

Один из способов согласования меток с подтокенами

Первый подтокен	Остальные подтокены
Метка исходного слова	Исключены из потери
Участвует в потере	В этом варианте разметки

Нужна связь с исходным словом или символьные смещения

Качество на тесте выросло

Признаки	Accuracy	Macro-F1
TF-IDF char_wb	0,7917	0,7652
CLS rubert-tiny2	0,9000	0,8863

Фиксированные системы, одинаковый test и C=1

Лабораторная 6 · 120 тестовых обращений

Recall поступления — 0,40

Класс «поступление»

Верно распознаны

8 / 20

Recall = 0,40

Ошибки класса

12

Направлены в другие отделы

Общая accuracy = 0,90 не описывает каждый класс

Короткие тексты не усечены

Основной корпус из 600 обращений

Длина со спецтокенами

8–21

токенов

Усечено

0

при пределе опыта 128

Основные ошибки нельзя объяснить отрезанным концом

Усечение убрало просьбу

80 повторов вступления и просьба «Как продлить книгу?» в конце

Полный вход

566

токенов

После усечения

128

просьба о книге исчезла

Маска не восстанавливает удалённую часть текста

Отдельный диагностический пример

Найдём причину ошибки

Отрезано	Нужная часть не дошла до модели
Не указано	В сообщении не хватает контекста
Не использовано	Сведения были, но решение ошибочно

Этим случаям нужны разные изменения системы или данных

От токенов к прикладному ответу

Текст и токенизатор → Энкодер и pooling → Обученная голова

Один из шести отделов

Предобученные параметры и прикладное обучение выполняют разные роли