Подготовка текстовых данных

В этой работе вы проверите обращения в электронную приёмную: найдёте пустые записи, повторы и ошибки разметки, напишете нормализацию и сравните способы выделять токены. Затем разберётесь, почему привычная «очистка» иногда стирает важную часть сообщения.

Материалы

Откройте `lab.ipynb`. Он использует файлы из папки `data`: основной корпус `requests.csv`, набор для аудита `audit_requests.csv` и описание меток `manifest.json`. Установка среды описана в общей инструкции курса.

В корпусе одна ситуация может быть записана несколькими способами. Поле `group_id` связывает такие варианты. Остальные поля — идентификатор записи, текст, категория и часть выборки. Категории соответствуют шести темам обращений: ИТ, библиотека, общежитие, учебный процесс, поступление и стипендия.

Работа с ноутбуком

Сначала прочитайте несколько строк и отметьте то, что кажется подозрительным. Затем переходите к заданиям: подсчёту записей, нормализации, поиску повторов, токенизации и разбору потери смысла. В каждом задании есть место для кода и небольшая проверка результата.

Нормализованный текст записывайте в новый столбец. Исходное обращение понадобится, чтобы понять, откуда появилась ошибка. Найденные конфликты меток разберите отдельно: одинаковые тексты с разными категориями нельзя исправить, просто оставив первую строку.

Что сдавать

Сдайте выполненный ноутбук с выводами в последнем разделе. В нём должны быть видны найденные записи, результаты функций и ваши объяснения. Добавьте один собственный пример для проверки нормализации. Перед сдачей перезапустите ядро и выполните все ячейки по порядку. Отдельный отчёт, повторяющий содержимое ноутбука, не нужен.

Как оценивается работа

Критерий	Баллы	Что учитывается
Код	40	Проверка данных, нормализация и поиск повторов
Разбор примеров	30	Сравнение токенизаторов и преобразований
Выводы	20	Объяснение ошибок и потери смысла
Ответы на защите	10	Разбор собственного и нового примера

Для сдачи нужно набрать 60 из 100 баллов. На защите будьте готовы объяснить, чем строка отличается от исходного обращения, почему NFC не заменяет похожие буквы разных алфавитов и что потерялось после удаления отрицания или номера ошибки.