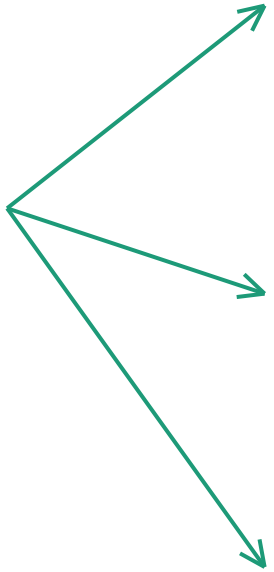
Как компьютер работает с текстом

Что сохранить, когда превращаешь сообщение в данные

Сначала определим результат

Одно сообщение

«Я не могу войти
в личный кабинет»



Выбрать отдел

ИТ

Извлечь сведения

личный кабинет

Подготовить ответ

«Какой кабинет
вы используете?»

У NLP-задач разные выходы

«Не могу войти в личный кабинет»

Классификация

ИТ

Извлечение

личный кабинет

сервис

Поиск

1 Восстановление доступа

Выше остальных документов

Генерация

«Что появляется при входе?»

Контекст выбирает значение

ключ

от комнаты



доступа к сервису



Lucide · ISC

Одно слово может обмануть

«**Отлично**,
портал снова **не работает**»

Тон задаёт сочетание слов

Набор лемм теряет роли

Преподаватель консультирует **студента**

Студент консультирует **преподавателя**



Леммы без порядка

преподаватель	консультировать	студент

Корпус хранит связи

«Не открывается учебный портал»

ИТ

id	запись
text	сообщение
label	категория
group_id	исходная ситуация
split	часть выборки

600 строк — 120 ситуаций

600

строк в корпусе

120

исходных ситуаций

Одна ситуация — пять формулировок

Основа	Приветствие	Просьба	Благодарность	Консультация

Ошибки видны до обучения

Пробел	«Не открывается учебный портал•»	ИТ
Пустота	« »	Библиотека
Метка	«Когда можно продлить книгу?»	Общежитие

• обозначает пробел

Метка следует правилу

«Не могу оплатить **общежитие** через **портал**»

О чём обращение?

Оплата общежития

Что именно мешает?

Сбой сайта?

Конфликт меток требует решения

Одна категория на обращение

«Когда можно продлить книгу?»	**Библиотека**
«Когда можно продлить книгу?»	**Общежитие**

Сверить сообщение и правила разметки

Границы токена задаёт метод

ИТ-поддержка: вход не работает!

split() · 4 токена

ИТ-поддержка:	вход	не	работает!

\w+|[^\w\s] · 8 токенов

ИТ	-	поддержка	:	вход	не	работает	!

Адрес распался на части

help@sever.example



help	@	sever	.	example

Один адрес для человека — пять элементов для этого правила

Повтор не расширяет словарь



Какие различия можно убрать?

Исходная запись

··**Не**··отменяйте·запись!··

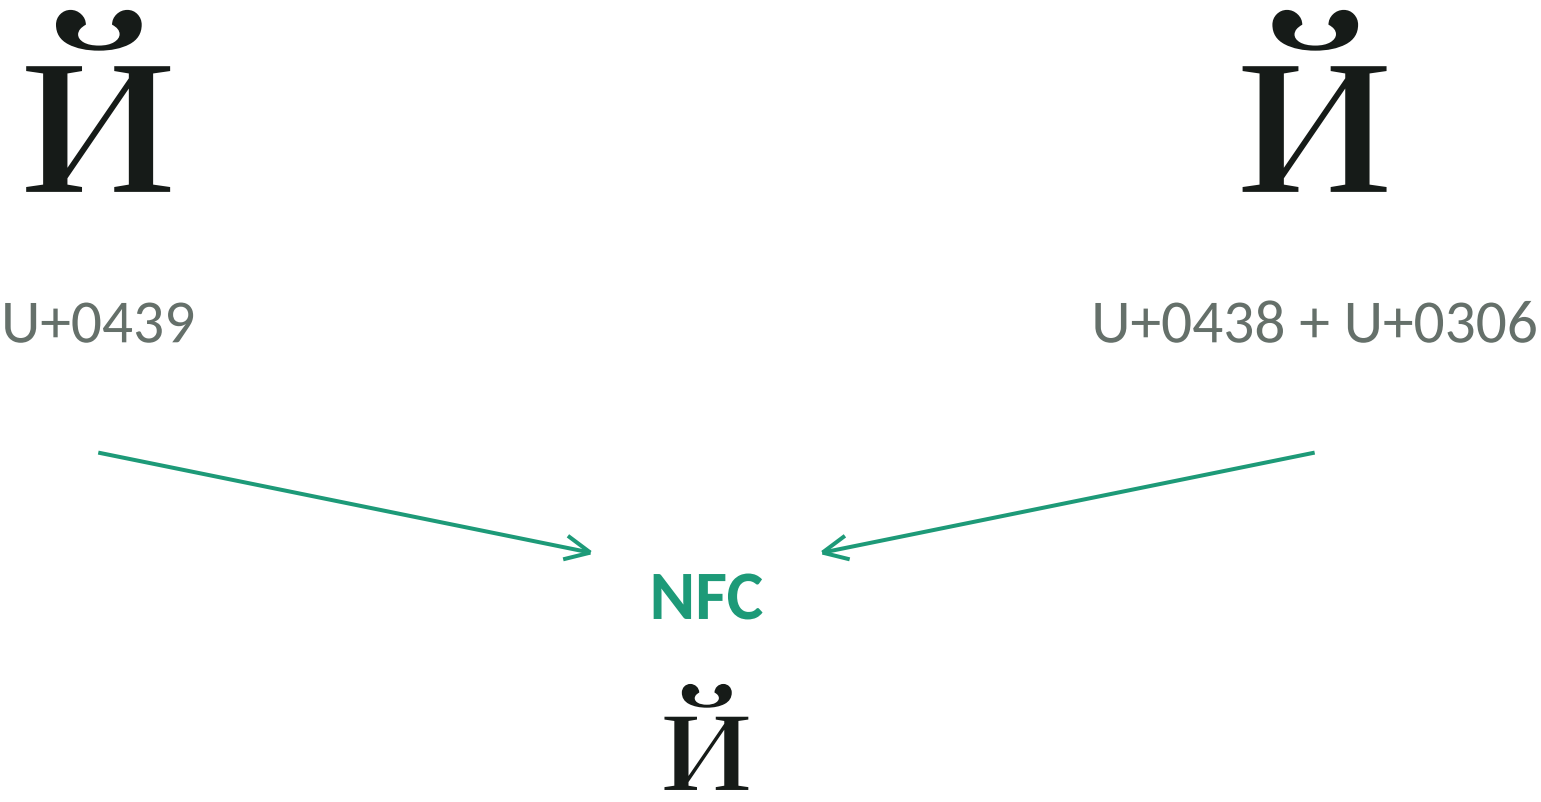


После сжатия пробелов

Не·отменяйте·запись!

· обозначает пробел

Один вид — две записи



Удаление «не» меняет смысл

«Я доволен работой портала»

«Я **не** доволен работой портала»

↓

Удалили «я» и «не»

доволен работой портала

Почему важен номер ошибки

Ошибка **403**

Удалили цифры



Ошибка

Повторная обработка стабильна

f — сжатие пробелов

$$f(f(x)) = f(x)$$

Вход		После f		После ещё одного f
··Ошибка··403··	→	Ошибка 403	→	Ошибка 403

· обозначает пробел

Лемма связывает словоформы



Одна форма — разные леммы

образцы **стали**



сталь

студенты **стали**
проверять результаты



стать

Сохраняйте исходную строку

text

« Не отменяйте запись! »



normalized

Не отменяйте запись!



tokens

Не	отменяйте	запись	!

Оригинал остаётся рядом с результатом обработки

Что нужно сохранить для задачи?

Исходная строка с пробелами

« **Не** отменяйте запись
на **12 октября**! »

Что убираем?

Что должно остаться?