Связь презентации и лекции

Как компьютер работает с текстом

Слайд 01. Как компьютер работает с текстом

Раздел: `L01-S01`. Идентификатор слайда: `L01-01`.

В электронную приёмную пришло сообщение: «Я не могу войти в личный кабинет». Сотрудник почти сразу понимает, о чём речь. Он может переслать письмо в техническую поддержку, уточнить название сервиса или предложить следующий шаг. А что именно мы хотим поручить программе?

Слайд 02. Сначала определим результат

Раздел: `L01-S01`. Идентификатор слайда: `L01-02`.

Один вариант — выбрать отдел. Тогда на входе будет текст, а на выходе одна категория: «ИТ», «библиотека», «общежитие» и так далее. Другой вариант — найти в сообщении полезные сведения: название сервиса, время сбоя, код ошибки. Третий — подготовить ответ студенту. Сообщение одно, но результат работы системы в этих случаях устроен по-разному.

Слайд 03. У NLP-задач разные выходы

Раздел: `L01-S02`. Идентификатор слайда: `L01-03`.

В классификации мы выбираем из заранее заданных вариантов. Например, обращение относится к библиотеке или к технической поддержке. Сам текст может быть длинным, коротким, вежливым или раздражённым; ответ классификатора всё равно имеет одну и ту же форму. Это полезное упрощение: вместо свободного понимания всего сообщения мы решаем конкретный вопрос о его теме.

Слайд 04. Контекст выбирает значение

Раздел: `L01-S03`. Идентификатор слайда: `L01-04`.

Рассмотрим слово «ключ». В сочетании «ключ от комнаты» оно связано с замком. В сочетании «ключ доступа к сервису» — с разрешением работать с системой. Если программа видит только само слово, этих двух значений она не различает. Соседние слова дают информацию, которой нет в отдельной записи словаря.

Слайд 05. Одно слово может обмануть

Раздел: `L01-S03`. Идентификатор слайда: `L01-05`.

Теперь фраза «Отлично, портал снова не работает». Если искать только положительные и отрицательные слова, «отлично» будет толкать решение в сторону положительной оценки. Но вместе с остальной фразой оно, скорее всего, выражает раздражение. Здесь приходится учитывать сочетание слов и способ употребления, а не просто складывать их словарные характеристики.

Слайд 06. Набор лемм теряет роли

Раздел: `L01-S03`. Идентификатор слайда: `L01-06`.

Русский язык даёт наглядный пример такого упрощения. Сравните «Преподаватель консультирует студента» и «Студент консультирует преподавателя». Если привести слова к начальной форме и оставить только их набор, оба предложения дадут «преподаватель», «консультировать», «студент». Однако роли участников поменялись. Порядок слов и окончания помогали различать эти роли; набор лемм их не сохранил.

Слайд 07. Корпус хранит связи

Раздел: `L01-S04`. Идентификатор слайда: `L01-07`.

В Python отдельный текст обычно хранится в строке. Для обучения и проверки модели нужна коллекция текстов — корпус. У каждого текста должны быть понятное место в этой коллекции и связь с другими сведениями: категорией, датой, источником или диалогом, из которого он взят.

Слайд 08. 600 строк — 120 ситуаций

Раздел: `L01-S04`. Идентификатор слайда: `L01-08`.

Почему недостаточно просто посчитать строки? Возьмём исходное обращение «Не работает учебный портал» и четыре варианта, как в нашем корпусе: с приветствием «Здравствуйте!», с просьбой «Подскажите, пожалуйста.», с благодарностью «Буду благодарен за ответ.» и с фразой «Нужна консультация.». В таблице пять строк. Но это не пять независимо возникших проблем — мы пять раз описали одну ситуацию. На схеме эти пять записей обозначены как основа, приветствие, просьба, благодарность и консультация. Если часть вариантов окажется среди примеров для обучения, а часть — среди проверочных, модель встретит на проверке очень знакомые сообщения.

Слайд 09. Ошибки видны до обучения

Раздел: `L01-S04`. Идентификатор слайда: `L01-09`.

Теперь посмотрим на три подозрительные записи.

Слайд 10. Метка следует правилу

Раздел: `L01-S05`. Идентификатор слайда: `L01-10`.

Вернёмся к письму «Не могу оплатить общежитие через портал». Какую категорию ему поставить? Если студента направляют по теме платежа, можно выбрать общежитие. Если сначала нужно восстановить работу сайта, можно выбрать ИТ. До чтения правил оба решения выглядят объяснимыми.

Слайд 11. Конфликт меток требует решения

Раздел: `L01-S05`. Идентификатор слайда: `L01-11`.

В таблице могут встретиться одинаковые тексты с разными метками. Возьмём две записи «Когда можно продлить книгу?». У одной метка «Библиотека», у другой — «Общежитие». Мы рассматриваем задачу, где каждому обращению назначают одну категорию, поэтому такое расхождение нужно проверить. После нормализации обнаружить это просто: сгруппировать строки по тексту и посчитать число различных категорий. Однако программа ещё не знает, какая категория верна. Она нашла место, где требуется решение. Если оставить первую попавшуюся строку, конфликт исчезнет из таблицы, но причина расхождения останется неизвестной.

Слайд 12. Границы токена задаёт метод

Раздел: `L01-S06`. Идентификатор слайда: `L01-12`.

Прежде чем представить текст числами, обычно нужно выделить элементы, с которыми будет работать программа. Такие элементы называют токенами. Токен может совпадать со словом, быть знаком пунктуации или частью слова. Его границы определяются выбранным способом разбиения.

Слайд 13. Адрес распался на части

Раздел: `L01-S06`. Идентификатор слайда: `L01-13`.

Рассмотрим адрес `help@sever.example`. Для человека это один адрес электронной почты. Наше регулярное выражение выделит `help`, `@`, `sever`, `.`, `example`. Если задача — найти адрес целиком, понадобится другое правило или дополнительный этап

объединения. Если задача — собрать статистику фрагментов текста, такое разбиение может быть удобным.

Слайд 14. Повтор не расширяет словарь

Раздел: `L01-S06`. Идентификатор слайда: `L01-14`.

Ещё одно различие — между вхождением и типом токена. В строке «книга книга журнал» три вхождения, но только два разных элемента. Список сохраняет оба появления слова «книга», множество — только одно. На следующей лекции число появлений станет одним из признаков текста, поэтому эти две величины нельзя подменять друг другом.

Слайд 15. Какие различия можно убрать?

Раздел: `L01-S07`. Идентификатор слайда: `L01-15`.

Нормализация приводит разные записи к выбранному общему виду. Самый простой пример — лишние пробелы. В строке `"  Не  отменяйте запись!  "` два пробела между словами и пробелы по краям не добавляют полезной информации для маршрутизации обращения. Пробелы по краям удаляем, а повторные пробелы между словами заменяем одним. Получается `"Не отменяйте запись!"`. На слайде пробелы отмечены точками «·», чтобы изменение было видно; в самой строке никаких точек мы не добавляем.

Слайд 16. Один вид — две записи

Раздел: `L01-S07`. Идентификатор слайда: `L01-16`.

Unicode даёт другой пример внешне одинаковых записей. Буква «й» может быть представлена одним символом `U+0439` или последовательностью «и» (`U+0438`) и комбинируемого знака краткости (`U+0306`). Форма NFC позволяет согласовать такие канонически эквивалентные записи. При этом похожие латинская `a` и кириллическая `а` остаются разными буквами: нормализация Unicode не исправляет смешение алфавитов.

Слайд 17. Удаление «не» меняет смысл

Раздел: `L01-S07`. Идентификатор слайда: `L01-17`.

Самые наглядные потери возникают при удалении служебных слов. Сравните «Я доволен работой портала» и «Я не доволен работой портала». Если убрать «я» и «не», останется одна и та же строка. Модель, получающая только эту строку, уже не сможет восстановить различие между двумя отзывами: оно исчезло до её вызова.

Слайд 18. Почему важен номер ошибки

Раздел: `L01-S07`. Идентификатор слайда: `L01-18`.

С числами происходит похожее. После удаления цифр «Ошибка 403» превращается в «Ошибка». Чтобы определить, что обращение связано с технической проблемой, этого может хватить. Для выбора инструкции по устранению сбоя номер важен. Если заранее не определить задачу, легко принять потерю полезного признака за удачную очистку.

Слайд 19. Повторная обработка стабильна

Раздел: `L01-S07`. Идентификатор слайда: `L01-19`.

Ещё одно полезное свойство — повторное применение нормализации не должно менять уже нормализованный текст. Это называют идемпотентностью: `f(f(x)) = f(x)`. Возьмём строку `"  Ошибка  403  "`. Здесь `f` удаляет пробелы по краям и сжимает повторные пробелы внутри строки. После первого применения получаем `"Ошибка 403"`, после второго — ровно ту же строку. На схеме два шага позволяют сравнить результаты непосредственно. Такое свойство удобно проверять в коде. Оно говорит о стабильности функции, но само по себе не отвечает на вопрос о сохранении смысла: стабильно удалять отрицание тоже возможно.

Слайд 20. Лемма связывает словоформы

Раздел: `L01-S08`. Идентификатор слайда: `L01-20`.

«Книга», «книги», «книгой» — разные формы одного слова. Для поиска по теме полезно связать их с леммой «книга». Тогда запрос в одной форме сможет совпасть с документом, где стоит другая. Процедуру приведения словоформ к лемме называют лемматизацией.

Слайд 21. Одна форма — разные леммы

Раздел: `L01-S08`. Идентификатор слайда: `L01-21`.

Но форма не всегда однозначно указывает на лемму. В сочетании «образцы стали» речь идёт о материале, и подходящая лемма — «сталь». В предложении «студенты стали проверять результаты» используется глагол «стать». Если словарь вернул оба варианта, он помог обнаружить неоднозначность, но выбор ещё предстоит сделать по окружению.

Слайд 22. Сохраняйте исходную строку

Раздел: `L01-S09`. Идентификатор слайда: `L01-22`.

Соберём разобранные операции в последовательность. Сначала читаем таблицу и проверяем её устройство: есть ли нужные поля, какие у них типы, сколько записей удалось загрузить. Затем ищем пустые сообщения и неизвестные категории. После этого создаём нормализованный столбец и сравниваем его с исходным.

Слайд 23. Что нужно сохранить для задачи?

Раздел: `L01-S10`. Идентификатор слайда: `L01-23`.

Проверим понимание на новой строке: