Заметки к презентации

Как компьютер работает с текстом

01. Как компьютер работает с текстом

– Прочитать обращение о личном кабинете. Сотрудник понимает проблему, но программе нужно задать конкретное действие.

– Предложить аудитории выбрать результат: отдел, полезные сведения или ответ.

– Переход: одно сообщение допускает несколько задач.

02. Сначала определим результат

– Вход в трёх вариантах один: сообщение о личном кабинете. Меняется полезное действие программы.

– Выбор отдела можно оценить по размеченным категориям; подготовка ответа требует дополнительных правил.

– Сравним, что возвращают программы в разных NLP-задачах.

03. У NLP-задач разные выходы

– Программа может вернуть метку, фрагмент текста, список документов или новый ответ.

– Для извлечения важны границы фрагмента, для поиска — порядок результатов.

– Программа задаёт уточняющий вопрос: сведений в сообщении пока недостаточно для выбора инструкции.

– Теперь посмотрим, почему отдельного слова часто недостаточно.

04. Контекст выбирает значение

– В сочетании с комнатой ключ связан с замком; в сочетании с доступом — с сервисом.

– Общее слово не содержит всех сведений, которые дают соседние слова.

– Далее посмотрим, как сочетание слов задаёт тон целой фразы.

05. Одно слово может обмануть

– Положительное слово употреблено рядом с описанием повторного сбоя.

– Здесь «отлично», скорее всего, выражает иронию и раздражение.

– Теперь сравним предложения, где меняются роли участников, хотя тема остаётся общей.

06. Набор лемм теряет роли

– В первом предложении консультирует преподаватель, во втором — студент.

– Если привести слова к леммам и не учитывать их порядок, наборы совпадут. Общая тема сохранится, но станет непонятно, кто кого консультирует.

– Упрощение оценивается относительно задачи. Перейдём к корпусу, в котором хранятся сообщения.

07. Корпус хранит связи

– Текст связан с конкретной записью, категорией, исходной ситуацией и частью выборки.

– id обозначает отдельную запись, а group_id объединяет варианты одного исходного обращения.

– Поэтому число строк ещё не равно числу независимых ситуаций.

08. 600 строк — 120 ситуаций

– У каждой ситуации пять записей: основа и варианты с приветствием, просьбой, благодарностью или запросом консультации. Добавленная формула вежливости не делает ситуацию независимой.

– При проверке на новых ситуациях все варианты группы остаются вместе.

– Числа относятся к авторскому учебному корпусу. Дальше посмотрим его возможные дефекты.

09. Ошибки видны до обучения

– После удаления лишнего пробела запись может совпасть с другой. В пустой строке нет сообщения. У вопроса о продлении книги стоит метка «Общежитие» — её нужно проверить.

– Одинаковые сообщения от разных людей не обязательно лишние: они могут свидетельствовать о массовом сбое.

– После автоматической проверки нужно разобраться, что делать с найденной записью. Для проверки меток понадобятся правила разметки.

10. Метка следует правилу

– В сообщении присутствуют предмет платежа и возможная техническая проблема.

– Правила разметки определяют, в какой отдел направить обращение. Одного слова «общежитие» для выбора недостаточно.

– Показать роль уточнения об ошибке 403. Затем разобрать конфликт одинаковых текстов.

11. Конфликт меток требует решения

– Если каждому обращению назначают одну категорию, одинаковые сообщения с разными метками нужно проверить.

– Если удалить одну из строк, это ещё не значит, что у оставшейся строки верная метка.

– Прочитать сообщение и инструкцию. Теперь перейдём к единицам самого текста.

12. Границы токена задаёт метод

– split оставляет дефис и пунктуацию при словах. Регулярное выражение выделяет их отдельно и даёт восемь элементов.

– Число токенов нужно читать вместе с правилом разбиения. Дальше пример адреса.

13. Адрес распался на части

– Человек видит один адрес; данное регулярное выражение даёт пять элементов.

– Для извлечения адреса целиком нужно другое правило или объединение частей.

– Один адрес может состоять из нескольких токенов. Далее сравним число вхождений и число разных токенов.

14. Повтор не расширяет словарь

– Список сохраняет два появления книги. Множество типов содержит книгу один раз.

– Получаются три вхождения и два типа. Эти величины отвечают на разные вопросы.

– Далее выберем, какие различия записи можно нормализовать.

15. Какие различия можно убрать?

– Пробелы по краям удаляем, а несколько пробелов между словами заменяем одним. Все слова, включая «не», сохраняем.

– Это удобно в обращениях, но пробелы в коде или таблице могут иметь структурный смысл.

– Операция с пробелами отличается от Unicode NFC, к которой переходим далее.

16. Один вид — две записи

– Буква «й» может состоять из U+0439 либо из U+0438 и комбинируемого U+0306. NFC согласует канонически эквивалентные записи.

– NFC не делает латинскую a кириллической а и не сжимает пробелы.

– Нормализация должна сохранять нужное различие. Особенно заметна потеря отрицания.

17. Удаление «не» меняет смысл

– Два противоположных отзыва после удаления я и не превращаются в одну строку.

– По такому входу модель уже не сможет восстановить различие, потерянное до её вызова.

– Следующий пример касается важного числа.

18. Почему важен номер ошибки

– Общая тема технической проблемы сохранилась, но номер мог определять подходящую инструкцию.

– Назвать задачу, для которой достаточно общей темы, и задачу, где 403 необходимо.

– Далее проверим стабильность самой функции обработки.

19. Повторная обработка стабильна

– Второе применение нормализации не должно ещё раз менять уже подготовленную строку.

– Стабильность функции не доказывает сохранение смысла: удаление отрицания тоже может быть идемпотентным.

– Затем перейдём от записи слова к его форме.

20. Лемма связывает словоформы

– Все три формы приводятся к лемме «книга». Поэтому запрос «книга» может найти документ со словом «книгой».

– Стемминг оставляет основу, которая не обязана быть словарным словом; его результат не называют леммой автоматически.

– Но одной формы иногда недостаточно для выбора леммы.

21. Одна форма — разные леммы

– В первом контексте подходит сталь, во втором — стать.

– Словарь может перечислить оба варианта; выбрать помогает окружение.

– Преобразования нужно собрать в последовательность, сохранив возможность их проверить.

22. Сохраняйте исходную строку

– Оригинал нужен для сравнения с нормализованной строкой и токенами.

– Проверки на коротких примерах помогают связать неожиданное изменение с конкретным шагом.

– Завершить лекцию новым примером, на котором аудитория сама выберет сохраняемые сведения.

23. Что нужно сохранить для задачи?

– Исходная строка содержит крайние и повторные пробелы, отрицание и дату.

– Убираем пробелы по краям и заменяем повторные пробелы одним. «Не» и «12 октября» сохраняем. Для извлечения даты нужны число и месяц.

– На следующей лекции из подготовленного корпуса получим признаки и обучим классификатор.