Связь презентации и лекции

Классификация текста

Слайд 01. Классификация текста

Раздел: `L02-S01`. Идентификатор слайда: `L02-01`.

На прошлом занятии мы подготовили обращения в электронную приёмную. Теперь попробуем автоматически выбирать для них отдел. Для сообщения «Как продлить книгу?» ожидается библиотека, для «Не могу войти в личный кабинет» — техническая поддержка. В нашем наборе шесть категорий, и каждой строке присвоена одна метка.

Слайд 02. При обучении известны ответы

Раздел: `L02-S01`. Идентификатор слайда: `L02-02`.

Важно различать обучение и применение. Во время обучения программа видит и сообщение, и его категорию. При предсказании ей передают только сообщение. Если для обработки проверочной строки понадобилась её правильная метка, значит, мы уже решили другую задачу.

Слайд 03. Проверяем на новых ситуациях

Раздел: `L02-S02`. Идентификатор слайда: `L02-03`.

Если обучить модель на всех примерах и проверить на них же, результат будет рассказывать прежде всего о знакомых ей данных. Нас интересуют новые обращения. Поэтому часть корпуса нужно отложить до обучения.

Слайд 04. Каждому слову — своя координата

Раздел: `L02-S03`. Идентификатор слайда: `L02-04`.

Классификатору понадобится числовое представление сообщения. Самый простой вариант — выбрать словарь и посчитать, сколько раз каждое слово встретилось в тексте. Одно слово соответствует одной координате. Такой способ называют мешком слов: порядок в пределах сообщения не сохраняется.

Слайд 05. TF и DF считают разные вещи

Раздел: `L02-S04`. Идентификатор слайда: `L02-05`.

Обычный счётчик одинаково учитывает два слова с одной и той же частотой внутри документа. Но одно из них может встречаться почти в каждом обращении, а другое — только в текстах определённой темы. TF-IDF объединяет частоту слова в текущем документе и его распространённость по коллекции.

Слайд 06. Меньше DF — больше IDF

Раздел: `L02-S04`. Идентификатор слайда: `L02-06`.

IDF становится меньше для слов, встречающихся во многих документах. Возьмём сглаженную формулу scikit-learn. Здесь N — число документов, а df(t) — число документов со словом t:

Слайд 07. Длина вектора становится единицей

Раздел: `L02-S04`. Идентификатор слайда: `L02-07`.

Затем выполним L2-нормировку: разделим все координаты вектора на его евклидову длину. Первый документ после этого имеет ненулевые координаты примерно 0,5494 и 0,8356. Его длина равна единице, но сумма координат не обязана быть единицей. Это веса признаков, а не распределение вероятностей по словам.

Слайд 08. Побеждает наибольшая оценка

Раздел: `L02-S05`. Идентификатор слайда: `L02-08`.

После векторизации каждый текст — вектор x. Линейный классификатор назначает каждому классу набор коэффициентов w и смещение b. Оценка класса вычисляется как скалярное произведение плюс смещение:

Слайд 09. Softmax даёт вероятности

Раздел: `L02-S05`. Идентификатор слайда: `L02-09`.

В нашем опыте с шестью категориями логистическая регрессия превращает оценки классов в вероятности с помощью softmax: для каждого класса берётся exp(s_c), затем результат делится на сумму экспонент всех оценок. Для ручного расчёта оставим два класса. При наших оценках 1,5 и −0,6 библиотека получает вероятность около 0,891, ИТ — около 0,109. Большая оценка стала большей вероятностью, а две вероятности складываются в 1.

Слайд 10. Уверенная ошибка стоит дороже

Раздел: `L02-S05`. Идентификатор слайда: `L02-10`.

Обозначим вероятность правильной категории через p_y. Потеря одного примера равна −ln(p_y). Если p_y=0,9, потеря около 0,105; если p_y=0,1 — около 2,303. Таким образом, уверенный ответ в пользу неверного класса получает большой штраф. Правильная метка нужна здесь, чтобы выбрать, какую вероятность оценивать.

Слайд 11. Новый вес — новая оценка

Раздел: `L02-S05`. Идентификатор слайда: `L02-11`.

Посмотрим на один возможный шаг. Если прибавить 0,1 к коэффициенту признака «книга» у библиотеки, его вклад при x=0,8 вырастет на 0,08. Оценка библиотеки станет 1,58 вместо 1,5. При неизменной оценке ИТ вероятность правильного класса повысится примерно с 0,891 до 0,898, а потеря данного примера уменьшится. В настоящем обучении изменение согласуется с потерями остальных сообщений и регуляризацией, поэтому нельзя независимо увеличивать каждый понравившийся коэффициент.

Слайд 12. Регуляризация ограничивает веса

Раздел: `L02-S05`. Идентификатор слайда: `L02-12`.

Параметры должны одновременно объяснять разные сообщения. Если очень точно подстроиться под случайные особенности train, перенос на новые обращения может ухудшиться. Поэтому помимо ошибки на train мы следим за качеством на отложенной части и ограничиваем сложность решения.

Слайд 13. Baseline задаёт точку отсчёта

Раздел: `L02-S06`. Идентификатор слайда: `L02-13`.

Перед сложной системой полезно проверить совсем простую: всегда возвращать одну категорию. Такой baseline задаёт точку отсчёта. Он не читает сообщение, зато показывает, сколько правильных ответов можно получить только за счёт состава выборки.

Слайд 14. Accuracy может скрыть провал

Раздел: `L02-S07`. Идентификатор слайда: `L02-14`.

Accuracy — доля объектов с правильной меткой. Это понятная величина: из ста сообщений верно направлены восемьдесят — accuracy равна 0,8. Но она не различает, в каких категориях произошли двадцать ошибок.

Слайд 15. Precision и recall считают разное

Раздел: `L02-S07`. Идентификатор слайда: `L02-15`.

Для одного выбранного класса можно выделить true positives, false positives и false negatives. TP — правильно найденные объекты этого класса. FP — объекты других классов, ошибочно отнесённые к нему. FN — объекты класса, которые модель отправила в другие категории.

Слайд 16. Macro-F1 даёт классам равный вес

Раздел: `L02-S07`. Идентификатор слайда: `L02-16`.

F1 объединяет precision и recall:

Слайд 17. Словоформы имеют общие части

Раздел: `L02-S08`. Идентификатор слайда: `L02-17`.

Теперь сравним два представления. Первое использует отдельные слова и соседние пары. Второе — символьные фрагменты длиной от трёх до пяти символов внутри границ слов, режим `char_wb`.

Слайд 18. Выбираем по validation

Раздел: `L02-S08`. Идентификатор слайда: `L02-18`.

Чтобы понять вклад представления, оставим классификатор одинаковым. Обучим вариант по словам и вариант по символам на одном train, оценим на одном validation по одной функции метрик. Если одновременно сменить представление, алгоритм и разбиение, будет трудно объяснить, что именно улучшило результат.

Слайд 19. Pipeline сохраняет порядок действий

Раздел: `L02-S09`. Идентификатор слайда: `L02-19`.

У нашей системы два связанных шага: преобразователь текста и классификатор. При обучении сначала строится словарь и вычисляется IDF, затем полученная матрица вместе с метками подаётся классификатору. При предсказании новый текст проходит через тот же преобразователь с уже сохранёнными параметрами.

Слайд 20. Сначала split, затем fit

Раздел: `L02-S09`. Идентификатор слайда: `L02-20`.

Рассмотрим ошибку: сначала вызвать `fit_transform` на всех текстах, а потом разделить готовую матрицу. Метки теста могли не использоваться, но его словарь и частоты уже повлияли на признаки. Для нашей оценки классификатора такая подготовка раскрывает информацию из отложенной части.

Слайд 21. На тесте верны 95 ответов из 120

Раздел: `L02-S10`. Идентификатор слайда: `L02-21`.

После итогового предсказания откроем ошибки. В таблице нужны исходное сообщение, правильная категория, ответ модели и `group_id`. Несколько стилистических вариантов одной ситуации стоит рассматривать вместе: у пяти похожих ошибочных ответов может быть одна и та же причина.

Слайд 22. Число метрики не объясняет ошибку

Раздел: `L02-S10`. Идентификатор слайда: `L02-22`.

Среди ошибок есть обращение «Не могу найти монографию в списке доступной литературы.». Его правильная категория — библиотека, но модель выбрала ИТ.

Слайд 23. Одна просьба — разные ответы

Раздел: `L02-S10`. Идентификатор слайда: `L02-23`.

При этом ответы внутри одной группы не всегда одинаковы. Фраза «Мне нужна помощь в подборе источников для курсовой.» была направлена в ИТ. Та же просьба с приветствием «Здравствуйте!» попала в учебный процесс. Все пять вариантов этой группы оказались ошибочными, но предсказанные категории различались: один ответ ИТ и четыре — учебный процесс. Это повод проверить устойчивость к формулировке, а не только посчитать ошибки группы. В этом сравнении модель получает текст вместе с точкой в конце: если убрать её из исходной просьбы, тот же классификатор уже выбирает учебный процесс. Поэтому для повторения результата сохраняем строку целиком, вместе с пунктуацией.