Заметки к презентации

Классификация текста

01. Классификация текста

– Вернуться к обращениям из первой работы: сообщение нужно направить в один из шести отделов.

– Ручные правила требуют дописывать случаи; обучаемая модель использует размеченные примеры.

– Различить обучение и применение, прежде чем переходить к вычислениям.

02. При обучении известны ответы

– При обучении доступны тексты и правильные категории. При применении модель получает новый текст.

– Метки validation и test используются для оценки после предсказания, а не как вход классификатора.

– Для проверки нужно заранее отложить новые ситуации.

03. Проверяем на новых ситуациях

– Все пять вариантов одного group_id остаются вместе. Размеры частей: 72/24/24 группы, 360/120/120 строк.

– На train обучаем модель, на validation выбираем вариант, на test оцениваем выбранную систему.

– Теперь превратим сообщения в числовые признаки.

04. Каждому слову — своя координата

– Прочитать три документа и найти их строки в матрице. Порядок столбцов фиксирован.

– В d1 у слова «книга» значение 2. Первые два документа имеют общую ненулевую координату.

– Перейти от частоты внутри документа к распространённости по коллекции.

05. TF и DF считают разные вещи

– TF=2 в первом документе: слово «книга» встретилось дважды. DF=2 во всей тройке: оно есть в d1 и d2.

– Повтор внутри одного документа не добавляет ещё один документ к DF.

– Теперь при N=3 вычислим IDF.

06. Меньше DF — больше IDF

– Используется сглаженная формула: 1 + ln((1+N)/(1+DF)); TF — обычное число вхождений.

– Для «книги» DF=2 и IDF≈1,2877; для «библиотеки» DF=1 и IDF≈1,6931.

– После умножения TF на IDF нормируем весь вектор.

07. Длина вектора становится единицей

– В d1 ненулевые веса библиотеки и книги: 1,6931 и 2,5754. Делим их на одну евклидову длину.

– Получаем примерно 0,5494 и 0,8356. Сумма квадратов равна единице с учётом округления; сумма координат не обязана.

– Дальше эти признаки использует классификатор.

08. Побеждает наибольшая оценка

– Коэффициенты заданы вручную для двух признаков. Смещения нулевые.

– Библиотека: 2×0,8−0,1=1,5; ИТ: −0,8+2×0,1=−0,6. Выбираем библиотеку.

– Преобразуем оценки в вероятности.

09. Softmax даёт вероятности

– Берём экспоненту каждой оценки и делим на общую сумму. Для наглядности оставлены два класса.

– Из 1,5 и −0,6 получаются 0,890903 и 0,109097; показанные проценты округлены.

– Чтобы оценить ответ, нужна вероятность правильного класса.

10. Уверенная ошибка стоит дороже

– p_y — вероятность именно правильного класса. При p_y=0,1 потеря≈2,303, при 0,9≈0,105.

– Слева на графике модель назначает правильному классу малую вероятность и получает большую потерю.

– Посмотрим, как изменение одного коэффициента влияет на результат.

11. Новый вес — новая оценка

– Правильная метка в примере — библиотека. Увеличиваем только её вес слова «книга» на 0,1.

– При x=0,8 оценка увеличивается на 0,08, вероятность растёт примерно с 0,891 до 0,898.

– Это отдельный пробный шаг. При обучении учитываются остальные сообщения и регуляризация.

12. Регуляризация ограничивает веса

– При обучении учитываем и ошибку на train, и штраф за большие коэффициенты.

– Меньший C соответствует более сильной регуляризации. В двух вариантах лабораторной C одинаков.

– Прежде чем оценивать обученную модель, зададим простой baseline.

13. Baseline задаёт точку отсчёта

– Постоянная категория при шести равных классах даёт 1/6≈16,7%. При доле ИТ 90% постоянный ИТ даёт 90%.

– Обе стратегии обходятся без чтения сообщения. Сопоставлять accuracy нужно с составом данных.

– Матрица ошибок покажет, какой класс остался без правильных ответов.

14. Accuracy может скрыть провал

– Строки — истинные классы, столбцы — предсказанные. Модель всегда отвечает A.

– 90 ответов верны, но ни один из десяти объектов B не распознан.

– Для A разберём precision и recall.

15. Precision и recall считают разное

– Для класса A: TP=90, FP=10, FN=0.

– Precision: 90 из 100 предсказаний A верны. Recall: найдены все 90 настоящих A.

– Затем посчитаем F1 отдельно для A и B.

16. Macro-F1 даёт классам равный вес

– Для A F1=180/190≈0,9474; для B F1=0. Их среднее≈0,4737.

– Accuracy=0,9 относится к той же матрице. Равный вес классов показывает провал B.

– Вернёмся к признакам и сравним слова с символьными фрагментами.

17. Словоформы имеют общие части

– Слова «книга» и «книгу» имеют разные словные координаты, но общие фрагменты «кни» и «ниг».

– char_wb строит фрагменты внутри границ слов. В лабораторной используем длины 3–5. Общие фрагменты помогают сопоставлять словоформы, но сами по себе не объясняют связь синонимов.

– Чтобы сравнить представления, оставим алгоритм и данные одинаковыми.

18. Выбираем по validation

– Обе модели обучены отдельно на одном train с одинаковыми настройками классификатора.

– На validation macro-F1 словного варианта≈0,4120, символьного≈0,7430; выбирается char_wb.

– Внутри fit оптимизируется логарифмическая потеря с регуляризацией; macro-F1 служит критерием выбора.

19. Pipeline сохраняет порядок действий

– В fit векторизатор изучает словарь и IDF, классификатор — веса по признакам и меткам train.

– В predict новые тексты проходят transform, затем классификатор использует сохранённые веса. Для validation/test новый словарь не строится.

– Покажем ошибочный порядок, который раскрывает информацию из test.

20. Сначала split, затем fit

– Если fit_transform выполнен на всех текстах до разделения, словарь и IDF уже учитывают test.

– Правильный порядок для нашего опыта: split по группам, затем fit только на train.

– После выбора на validation один раз оцениваем систему на test.

21. На тесте верны 95 ответов из 120

– Выбран символьный вариант. В test 120 строк из 24 групп; 95 строк классифицированы правильно.

– Accuracy≈0,7917 и macro-F1≈0,7652 относятся к этому учебному корпусу и закреплённым настройкам.

– Откроем сами ошибки, начиная с обращения о монографии.

22. Число метрики не объясняет ошибку

– Строка с конечной точкой относится к библиотеке, но модель выбрала ИТ.

– Слабая связь «монографии» с библиотечными примерами — гипотеза; для проверки нужны признаки и train.

– В следующем примере ответы меняются даже внутри одной группы.

23. Одна просьба — разные ответы

– Точные строки включают конечную точку. Основа даёт ИТ, добавление «Здравствуйте! » — учебный процесс.

– В library-20 все пять вариантов ошибочны: один ИТ, четыре — учебный процесс. Верная категория — библиотека. Без точки основа тоже даёт учебный процесс.

– Предложить следующую проверку устойчивости. На следующей лекции применим векторы к поиску документов.