Поиск по документам

Вы сравните два представления одной базы: TF-IDF и TF-IDF с сокращением размерности через SVD. Работа начинается с ручного косинуса, затем переходит к индексу и заканчивается чтением конкретных найденных документов.

Ход работы

Рассчитайте сходство двумерных векторов и проверьте влияние масштаба. Постройте обе матрицы документов, сохранив соответствие строк и `doc_id`. Преобразуйте запросы теми же обученными преобразователями, получите top-3 и оцените выдачу по эталонным документам.

При разборе результатов смотрите и на число, и на источник. Вопрос о сумме стипендии может найти документ о назначении стипендии; нужно прочитать его, чтобы понять, есть ли там сумма. Вопросы без ответа рассматриваются отдельно от Recall и MRR.

Что сдавать

Сдайте выполненный ноутбук с двумя разборами различающихся выдач и одним вопросом без ответа. На защите объясните совместимость координат запроса и документов и изменение метрик при перестановке эталона внутри top-3.

Оценивание

Критерий	Баллы	Что учитывается
Код	40	Косинус, индексы, ранжирование и нулевой запрос
Опыты	30	Два метода, отложенные вопросы и корректные знаменатели
Объяснение	20	Связь рангов, метрик и содержания документов
Защита	10	Разбор нового запроса или изменения ранга

Порог сдачи — 60 из 100. Пояснения пишутся в ноутбуке. Перед сдачей перезапустите ядро и выполните все ячейки по порядку.