Эмбеддинги и поиск

Как сравнивать тексты
в общем пространстве

Пользователю нужен документ

«Как продлить книгу?»

Запрос → Ранжирование → Инструкция

Срок и условия

Порядок документов влияет на полезность ответа

Смысл распределён по вектору

TF-IDF

Словарные признаки

$(0; x_2; 0; \ldots)$

Плотный вектор

Распределённое представление

$(z_1; z_2; \ldots; z_k)$

Вектор может представлять слово, позицию или целый текст

Общее пространство векторов

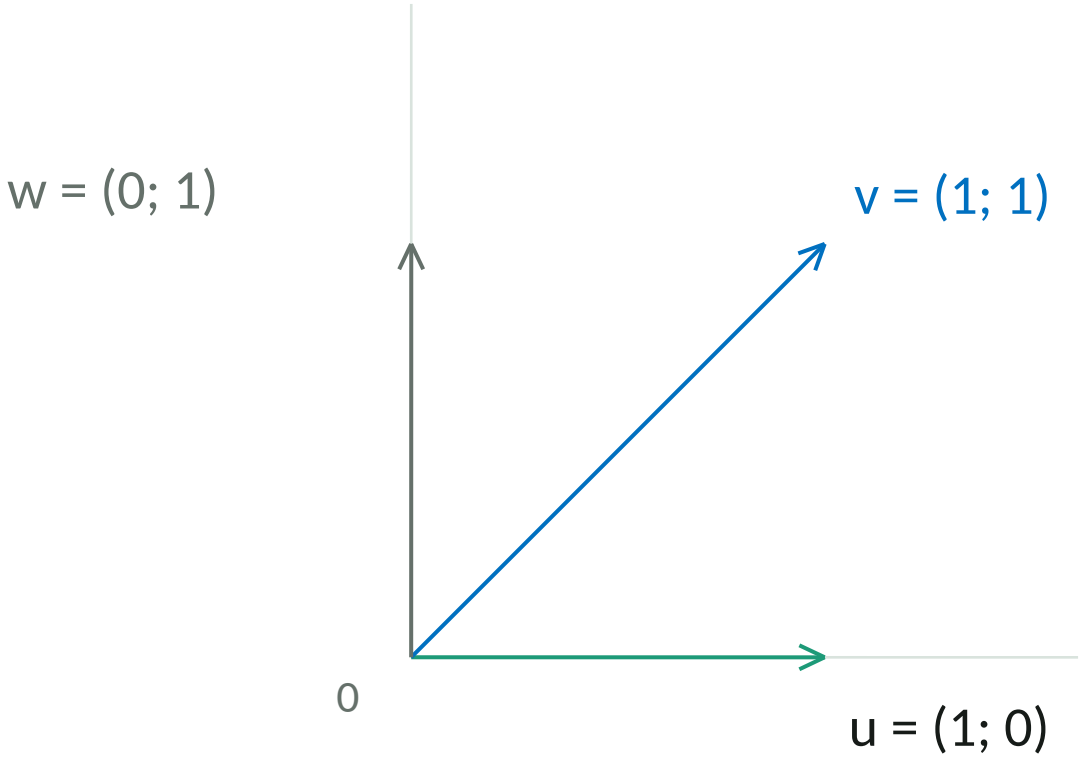
Одинаковая размерность ещё не означает совместимость

Словарь документов	Другой словарь запроса
книга → координата 1	пароль → координата 1
пароль → координата 2	книга → координата 2

Для сравнения нужны согласованные преобразования

Условные словарные оси

Косинус сравнивает направления



$\cos(u, v) \approx 0{,}7071$

$\cos(u, w) = 0$

Учебные векторы · одинаковый масштаб осей

Один косинус вручную

$$u \cdot v = 1; \quad ||u|| = 1; \quad ||v|| = \sqrt{2}$$

$$\cos(u, v) = 1 / \sqrt{2} \approx 0{,}7071$$

Для единичных векторов $\cos(u, v) = u \cdot v$

Масштаб не меняет косинус

$$v = (1; 1) \rightarrow 10v = (10; 10)$$

$$1 / \sqrt{2} = 10 / \sqrt{200}$$

Направление сохраняется

Положительный масштаб; нулевой вектор — отдельный случай

Нулевой запрос требует решения

Ни один фрагмент запроса не встретился в словаре

TF-IDF → Нулевой вектор → Пустая выдача

Норма равна 0

Косинус с нулевым вектором не определён

SVD выбирает направления

$$X \approx U_k \Sigma_k V_k^T$$

$$Z = XV_k$$

Запрос: $z_q = qV_k$

Документы и запрос проецируются на те же направления

Truncated SVD · приближение матрицы меньшего ранга

Проекция сохраняет выбранную ось

X		$V_1 = (1; 0)$	$Z = XV_1$
2	0		2
0	1	→	0
2	0		2

Первая ось сохраняет 8 из 9 единиц суммы квадратов

Учебная матрица · знак направления условен

Компактность меняет информацию

TF-IDF

12×670

документы × признаки

SVD

12×6

те же документы

Меньше координат; полезность поиска проверяется отдельно

Лабораторная 3 · фактические размеры матриц

Окно создаёт обучающие пары

Skip-gram · окно по одному слову с каждой стороны

Студент **читает** новую книгу



читает → студент

читает → новую

«Книгу» находится в двух шагах от центра

Skip-gram и CBOW меняют задачу

Skip-gram

читает

↓

студент · новую

CBOW

студент · новую

↓

читает

Разные направления обучающей задачи

Учимся различать пары

Negative sampling

Пара	Роль в этом шаге
читает · студент	Наблюдаемое соседство
читает · замок	Отрицательный пример

Оценка пары: σ(v_center · v_context)

Отрицательная пара не означает запрет сочетания в языке

Подслова помогают новой форме

fastText

Новая словоформа → Известные фрагменты → Вектор слова

кни · ниг · …

Подсловные векторы обучаются по окружениям

Bojanowski et al., 2017 · подсловные представления

Контекст меняет вектор позиции

ключ от комнаты

Вектор позиции
в этом предложении

ключ доступа

Вектор позиции
в другом предложении

Окружение участвует в вычислении представления

От текста к вектору документа

Текст → $h_1, h_2, \ldots$ → Вектор документа

Векторы позиций

Pooling

Каждое h_i — отдельный вектор

Запрос проходит тот же путь

Один набор обученных преобразований



Строка индекса остаётся связанной с doc_id

Ранг меняет вклад в метрику

Вопрос	Ранг эталона	Вклад в MRR@3
1	1	1
2	3	1/3
3	Вне top-3	0
4	2	1/2

Учебный пример · четыре ответимых вопроса

Попадание и ранг

Recall@1

0,25

1 из 4

Recall@3

0,75

3 из 4

MRR@3

0,4583

Среднее обратных рангов

MRR@3 = (1 + 1/3 + 0 + 1/2) / 4

Место при нулевой оценке

Q04: «Какие сведения нужны при технической ошибке?»

TF-IDF	SVD
1 D05 · 0,0855	1 D02 · 0,7899
2 D01 · 0,0807	
3 D02 · 0	

Равные оценки упорядочиваются по doc_id

Разница — одно попадание

Метод	Recall@1	Recall@3
TF-IDF	14/16 = 0,875	15/16 = 0,9375
SVD	14/16 = 0,875	16/16 = 1

Разница относится к одному вопросу в небольшой коллекции

Лабораторная 3 · 16 тестовых вопросов с эталоном

Близость не добавляет фактов

«Сколько рублей составляет академическая стипендия?»

Косинус с D11

0,9909

Содержание документа

О назначении стипендии.
Суммы в нём нет.

Близость темы не подтверждает наличие нужного факта

Q26 · вопрос без ответа в учебной базе