Связь презентации и лекции

Эмбеддинги и поиск

Слайд 01. Эмбеддинги и поиск

Раздел: `L03-S01`. Идентификатор слайда: `L03-01`.

Классификатор может определить, что вопрос относится к библиотеке. Но студенту нужна конкретная инструкция: например, как продлить книгу и на какой срок.

Слайд 02. Пользователю нужен документ

Раздел: `L03-S01`. Идентификатор слайда: `L03-02`.

Теперь результатом системы станет список документов, которые стоит прочитать для ответа.

Слайд 03. Смысл распределён по вектору

Раздел: `L03-S02`. Идентификатор слайда: `L03-03`.

После TF-IDF каждый документ представлен вектором одной и той же размерности. Его координаты связаны со словарными признаками. Если слова в документе нет, соответствующий вес равен нулю. У короткого сообщения ненулевых координат обычно намного меньше, чем размер всего словаря.

Слайд 04. Общее пространство векторов

Раздел: `L03-S02`. Идентификатор слайда: `L03-04`.

Для поиска требуется общее пространство. Если документы закодированы одним преобразованием, а запросы — другим несогласованным, одинаковое число координат их не спасёт. Первая координата одного вектора может иметь совсем другой смысл, чем первая координата другого.

Слайд 05. Косинус сравнивает направления

Раздел: `L03-S03`. Идентификатор слайда: `L03-05`.

Один из распространённых способов сравнить векторы — косинусная близость:

Слайд 06. Один косинус вручную

Раздел: L03-S03. Идентификатор слайда: L03-06.

Скалярное произведение u и v равно 1, длина u равна 1, длина v — $\sqrt{2}$. Поэтому $\cos(u,v)=1/\sqrt{2}\approx 0{,}7071$. У u и w скалярное произведение нулевое, значит, $\cos(u,w)=0$.

Слайд 07. Масштаб не меняет косинус

Раздел: L03-S03. Идентификатор слайда: L03-07.

Теперь заменим v на (10;10). Длина увеличилась в десять раз, скалярное произведение с u — тоже. Их отношение осталось прежним. Поэтому положительное масштабирование вектора не меняет косинус. Вектор стал длиннее, но сохранил направление.

Слайд 08. Нулевой запрос требует решения

Раздел: L03-S03. Идентификатор слайда: L03-08.

Нулевой вектор — отдельный случай: его длина равна нулю, и формула не определена. Для TF-IDF такой запрос может получиться, если ни один его фрагмент не встретился в словаре. Вместо случайного ранжирования равных нулевых оценок наша функция вернёт пустую выдачу.

Слайд 09. SVD выбирает направления

Раздел: L03-S04. Идентификатор слайда: L03-09.

Попробуем перейти от разреженных векторов с большим числом словарных признаков к плотным векторам с небольшим числом координат. Truncated SVD выбирает несколько направлений, которые описывают существенную часть структуры исходной матрицы. Документы проецируются на эти направления.

Слайд 10. Проекция сохраняет выбранную ось

Раздел: L03-S04. Идентификатор слайда: L03-10.

Посмотрим на маленькую матрицу из трёх строк: X=((2;0), (0;1), (2;0)). Первая координата даёт сумму квадратов $2^2+0^2+2^2=8$, вторая — $0^2+1^2+0^2=1$; их скалярное произведение равно нулю. При сокращении до одного направления SVD оставляет первую ось, $V_1=(1;0)$, с точностью до знака. Проекция даёт три числа: 2, 0 и 2. Например, $(0;1)\cdot(1;0)=0$. Восстановить вторую координату из этих чисел уже нельзя: второй документ стал нулевым. Здесь знаки и направления особенно простые; в общем случае направление сочетает несколько исходных признаков.

Слайд 11. Компактность меняет информацию

Раздел: `L03-S04`. Идентификатор слайда: `L03-11`.

Если исходная матрица X имеет размер «документы × признаки», после сокращения до k направлений получим «документы × k». В лабораторной матрица TF-IDF имеет размер 12×670: двенадцать документов и 670 признаков. После SVD с шестью направлениями получаем матрицу 12×6. Запрос должен пройти через тот же обученный преобразователь SVD, иначе его координаты не будут согласованы с документами.

Слайд 12. Окно создаёт обучающие пары

Раздел: `L03-S05`. Идентификатор слайда: `L03-12`.

Другая идея — учить представления по окружениям слов. Слова, употребляющиеся в похожих контекстах, получают связанные обучающие сигналы. Так можно получить полезные векторы без разметки каждого слова по тематической категории.

Слайд 13. Skip-gram и CBOW меняют задачу

Раздел: `L03-S05`. Идентификатор слайда: `L03-13`.

В Word2Vec есть также вариант CBOW: по окружению предсказывается центральное слово. Эти задачи устроены иначе, чем классификация обращений. Обучающий ответ создаётся из самого текста, из положения слов в нём.

Слайд 14. Учимся различать пары

Раздел: `L03-S05`. Идентификатор слайда: `L03-14`.

Для большого словаря сравнивать каждую пару со всеми возможными словами дорого. В обучении с negative sampling настоящая пара противопоставляется выбранным отрицательным примерам. Мы не будем реализовывать этот алгоритм в обязательной работе, но важно понимать, откуда берётся сигнал для векторов: он связан с наблюдаемыми окружениями.

Слайд 15. Подслова помогают новой форме

Раздел: `L03-S06`. Идентификатор слайда: `L03-15`.

Статическому словарю трудно обработать слово, которого в нём нет. Можно заменить его общим UNK-вектором, но тогда разные неизвестные слова становятся

неразличимыми. Для русского языка это особенно заметно из-за множества словоформ.

Слайд 16. Контекст меняет вектор позиции

Раздел: `L03-S07`. Идентификатор слайда: `L03-16`.

Контекстная модель получает не одно слово, а последовательность. Представление «ключа» в «ключе от комнаты» может отличаться от его представления в «ключе доступа». Окружение участвует непосредственно в вычислении вектора для данного употребления.

Слайд 17. От текста к вектору документа

Раздел: `L03-S07`. Идентификатор слайда: `L03-17`.

Это меняет и единицу, которую мы сравниваем. Статический вектор относится к слову в словаре. Контекстный — к позиции в конкретном входе. А для поиска по документам нужен ещё способ получить один вектор из последовательности таких представлений.

Слайд 18. Запрос проходит тот же путь

Раздел: `L03-S08`. Идентификатор слайда: `L03-18`.

Соберём поиск по шагам. Сначала берём известные документы, соединяем заголовок и текст, обучаем TF-IDF и сохраняем полученную матрицу. Для второго варианта обучаем SVD на этой матрице и нормируем строки.

Слайд 19. Ранг меняет вклад в метрику

Раздел: `L03-S09`. Идентификатор слайда: `L03-19`.

Предположим, у каждого ответимого вопроса есть один размеченный релевантный документ. Recall@k показывает долю вопросов, для которых этот документ оказался среди первых k результатов. Для k=1 проверяется только верхняя позиция, для k=3 — первые три.

Слайд 20. Попадание и ранг

Раздел: `L03-S09`. Идентификатор слайда: `L03-20`.

Тогда Recall@1=1/4=0,25; Recall@3=3/4=0,75. MRR@3 равна `(1 + 1/3 + 0 + 1/2)/4 ≈ 0,4583`.

Слайд 21. Место при нулевой оценке

Раздел: `L03-S10`. Идентификатор слайда: `L03-21`.

Запрос Q04 «Какие сведения нужны при технической ошибке?» нашёл документ D02 третьим в TF-IDF и первым после SVD в валидационном разборе. Откройте выдачу и сам документ: нужные сведения там действительно перечислены. Так можно понять, что означает изменение ранга для ответа пользователю.

Слайд 22. Разница — одно попадание

Раздел: `L03-S10`. Идентификатор слайда: `L03-22`.

В лабораторной мы сравним TF-IDF и TF-IDF→SVD(6). На тестовых ответимых вопросах у обоих методов Recall@1 в исходном опыте равна 0,875. При расширении выдачи до трёх документов у TF-IDF Recall@3 около 0,9375, у SVD — 1. Эти числа полезно сопоставить с теми запросами, где порядок изменился.

Слайд 23. Близость не добавляет фактов

Раздел: `L03-S10`. Идентификатор слайда: `L03-23`.

Другой вопрос касается суммы стипендии. Точная формулировка Q26 — «Сколько рублей составляет академическая стипендия?». Нужного числа в нашей базе нет, однако SVD находит документ D11 с косинусом около 0,9909. Высокое сходство не добавляет в документ отсутствующую сумму. Этот случай особенно важен перед RAG: генератору потребуется различать полезный источник и документ, который просто относится к похожей теме.