Заметки к презентации

Эмбеддинги и поиск

01. Эмбеддинги и поиск

– Категория уже известна, но для ответа нужна конкретная инструкция.

– Сегодня проследить представление, ранжирование и чтение найденного источника.

02. Пользователю нужен документ

– Для продления книги нужен текст с условиями.

– Порядок результатов важен: документ о заселении не должен вытеснять нужную инструкцию.

– Далее векторизуем коллекцию.

03. Смысл распределён по вектору

– В TF-IDF координаты привязаны к словарным признакам; у плотного вектора они обычно не имеют простых названий.

– Значения здесь схематические, не результаты кодирования.

04. Общее пространство векторов

– Одинаковая размерность двух векторов не гарантирует одинакового смысла координат.

– Показаны условные словарные оси, переставленные местами.

– Реальные энкодеры могут различаться сложнее.

05. Косинус сравнивает направления

– Одинаковый масштаб осей. u и v образуют 45°, u и w — 90°.

– Косинусы равны примерно 0,7071 и 0.

– Это геометрия заданных векторов, а не вероятность ответа.

– Следующий слайд разбирает первый расчёт.

06. Один косинус вручную

– Скалярное произведение равно 1, длины векторов равны 1 и $\sqrt{2}$.

– Подставить числа в формулу.

– Для единичных норм косинус совпадает со скалярным произведением, что удобно при сравнении со всеми документами.

– Затем изменить масштаб одного вектора.

07. Масштаб не меняет косинус

– Умножение v на положительное число 10 увеличивает в 10 раз и скалярное произведение, и норму v.

– Отношение сохраняется.

– При отрицательном масштабе направление меняется.

– Нулевой вектор разберём отдельно.

08. Нулевой запрос требует решения

– Если ни один фрагмент запроса не попал в словарь, норма равна 0 и косинус не определён.

– Наша функция возвращает пустую выдачу.

– Случай ненулевого запроса и нулевой оценки отдельного документа разберём на Q04.

– Теперь сократим размерность представления.

09. SVD выбирает направления

– Направления V_k выбраны по матрице документов; запрос использует те же.

– Сокращение ранга минимизирует квадратичную ошибку восстановления.

– В следующем примере выполним это преобразование на конкретных числах.

10. Проекция сохраняет выбранную ось

– В ручной матрице сумма квадратов первой координаты равна 8, второй — 1; столбцы ортогональны.

– При k=1 остаётся первая ось, с точностью до знака.

– Проекции равны 2, 0 и 2.

– Это учебные числа; далее покажем размеры матрицы основной работы.

11. Компактность меняет информацию

– Фактическая матрица TF-IDF имеет размер 12×670, после SVD — 12×6.

– Двенадцать документов остаются теми же.

– Размерность меньше, но полезность для запроса проверяется отдельно.

– После нормировки перейдём к другому способу получить плотные представления — Word2Vec.

12. Окно создаёт обучающие пары

– Окно ±1 вокруг «читает» включает «студент» и «новую», но не «книгу».

– Радиус 2 добавил бы и эту пару.

– Обучающие ответы создаются из позиций в самом тексте.

– Сопоставить это с обратной задачей CBOW.

13. Skip-gram и CBOW меняют задачу

– Один и тот же фрагмент даёт разные направления предсказания.

– В CBOW используется объединённое представление окружения.

– Это разные обучающие задачи, а не последовательные шаги одного энкодера.

14. Учимся различать пары

– «Замок» выбран отрицательным примером конкретного шага; это не запрет сочетания в языке.

– К скалярному произведению обучаемых векторов применяется сигмоида.

– Потеря поощряет большую оценку положительной пары и меньшую отрицательной.

– Затем обсудить внутреннее устройство слова.

15. Подслова помогают новой форме

– Книга и книгой имеют общие символьные части.

– В fastText обучаемые подсловные векторы участвуют в представлении слова.

– Это не морфемный разбор.

– Далее меняется и контекст употребления.

16. Контекст меняет вектор позиции

– Здесь два употребления слова, а не две записи статического словаря.

– На слайде сопоставлены два употребления; численные значения векторов не показаны.

17. От текста к вектору документа

– Различить входной текст, векторы позиций h_i и агрегированный вектор документа.

– Каждый h_i сам является вектором.

– Pooling выбирается по модели; CLS будет подробно разобран в L06.

– Для поиска итоговый вектор должен совпадать по смыслу координат с индексом.

18. Запрос проходит тот же путь

– TF-IDF и SVD обучаются на документах; индекс сохраняет соответствие строк и doc_id.

– К запросу применяются эти преобразования через transform.

– Эталонные ответы в fit не включаются.

– Дальше оценим полученный порядок документов.

19. Ранг меняет вклад в метрику

– Ранги эталонов: 1, 3, отсутствие в top-3 и 2.

– Вклад MRR равен обратному рангу; вне top-3 он нулевой.

– На следующем кадре усредняем по четырём ответимым вопросам.

20. Попадание и ранг

– Один первый ранг из четырёх, три попадания в top-3 из четырёх.

– Сумма обратных рангов равна 11/6; делим её на 4.

– Перемещение эталона с третьего места на второе сохраняет Recall@3 и повышает MRR@3.

– Затем посмотрим реальную выдачу.

21. Место при нулевой оценке

– Q04: «Какие сведения нужны при технической ошибке?».

– В TF-IDF D02 третий с score=0; его место определяется doc_id после D05 и D01.

– В SVD D02 первый с близостью около 0,7899.

– Вклад Recall@3 одинаков, вклад MRR меняется с 1/3 на 1.

– Эталон действительно содержит нужные сведения.

22. Разница — одно попадание

– На тесте 16 вопросов с эталоном.

– Recall@1 у обоих методов — 14/16; Recall@3 у TF-IDF — 15/16, у SVD — 16/16.

– Разница соответствует одному вопросу в маленькой коллекции.

– Для вопросов без ответа нужен отдельный разбор.

23. Близость не добавляет фактов

– Точная строка Q26 взята из CSV.

– SVD возвращает D11 с косинусом 0,9909, но документ о назначении не сообщает сумму.

– Близость темы не является вероятностью наличия факта.

– Завершить предложением проверить источник; на следующем занятии перейдём к предсказанию продолжения.