N-граммная языковая модель

Вы построите распределения следующих токенов по счётчикам переходов, сравните три длины истории и получите собственные продолжения текста. Числовой пример из трёх предложений связывает код с лекцией.

Ход работы

Изучите готовый итератор пар «история, цель». Постройте общий словарь по обучающей части, реализуйте счётчики и сглаживание. Проверьте нормировку знакомой и новой истории. Затем вычислите perplexity трёх моделей на validation, выберите порядок и оцените его на test.

При чтении генерации сохраните видимые UNK и причину остановки. Эти сведения помогут объяснить разницу между вероятностной оценкой по эталонным префиксам и свободным продолжением собственных токенов.

Что сдавать

Сдайте выполненный ноутбук с разбором выбранного порядка, доли UNK, двух продолжений и скалярного состояния RNN. На защите нужно уметь вручную получить вероятность продолжения после сглаживания и объяснить, какие позиции входят в perplexity.

Оценивание

Критерий	Баллы	Что учитывается
Код	40	Счётчики, вероятности, perplexity и генератор
Опыты	30	Общий словарь, выбор порядка и несколько продолжений
Объяснение	20	UNK, границы, вероятности и собственные префиксы
Защита	10	Ручной расчёт и прогноз для изменённой истории

Порог сдачи — 60 из 100. Перед сдачей перезапустите ядро и выполните все ячейки по порядку.