Связь презентации и лекции

Как языковая модель продолжает текст

Слайд 01. Как языковая модель продолжает текст

Раздел: `L04-S01`. Идентификатор слайда: `L04-01`.

Начнём с фразы «Студент открыл…». Как её продолжить? Можно открыть учебник, дверь, окно или личный кабинет. Если перед этим обсуждался вход на сайт, один вариант станет естественнее. Если речь шла о душной аудитории — другой. Нам нужна программа, которая учитывает уже написанное и оценивает возможные продолжения.

Слайд 02. У префикса несколько продолжений

Раздел: `L04-S01`. Идентификатор слайда: `L04-02`.

Языковая модель задаёт распределение вероятностей следующего токена по префиксу. Внутри одного шага вероятности всех допустимых вариантов складываются в единицу. Само распределение ещё не является ответом: из него нужно выбрать токен. После выбора токен добавляется к префиксу, и следующий шаг получает уже другое начало.

Слайд 03. У последовательности есть границы

Раздел: `L04-S01`. Идентификатор слайда: `L04-03`.

Пока договоримся о границах. BOS обозначает начало последовательности и служит контекстом. EOS — конец, который модель должна предсказать. После EOS генерация завершается. Различие удобно увидеть на пустом тексте: слов нет, но событие завершения всё равно есть.

Слайд 04. Вероятность пути — произведение

Раздел: `L04-S02`. Идентификатор слайда: `L04-04`.

Для последовательности w_1, w_2, …, w_T цепное правило записывает вероятность как произведение условных вероятностей: $P(w_1,\ldots,w_T)=\prod_t P(w_t|w_1,\ldots,w_{t-1})$. Каждый множитель оценивает следующий токен при уже заданных предыдущих. Если мы моделируем завершённый текст, последним токеном в этой записи будет EOS.

Слайд 05. Длина истории равна n – 1

Раздел: `L04-S03`. Идентификатор слайда: `L04-05`.

Униграммная модель, n=1, предсказывает токен по общей частоте, без предыдущих слов. Биграммная, n=2, учитывает один предыдущий токен. Триграммная, n=3, — два. В число n входит и предсказываемый элемент, поэтому длина истории равна n−1.

Слайд 06. Три предложения дают счётчики

Раздел: `L04-S03`. Идентификатор слайда: `L04-06`.

Возьмём три предложения: «студент читает книгу», «студент читает журнал», «студент возвращает книгу». Добавим к каждому BOS и EOS. После слова «студент» дважды встретилось «читает» и один раз «возвращает».

Слайд 07. Частота становится вероятностью

Раздел: `L04-S03`. Идентификатор слайда: `L04-07`.

Биграммная оценка даёт P(читает|студент)=2/3 и P(возвращает|студент)=1/3.

Слайд 08. Новый переход получает ноль

Раздел: `L04-S04`. Идентификатор слайда: `L04-08`.

В мини-корпусе переход «студент журнал» не встречался. Частотная оценка назначает ему ноль, хотя оба слова известны. Один нулевой множитель делает нулевой вероятность всего текста. Отсутствие сочетания в трёх предложениях — слабое основание считать его невозможным, поэтому изменим оценку.

Слайд 09. Добавка меняет весь знаменатель

Раздел: `L04-S04`. Идентификатор слайда: `L04-09`.

При сглаживании add-alpha к каждому счётчику продолжения добавляется α>0. Формула принимает вид P(w|h)=(c(h,w)+α)/(c(h)+α|V|), где V — фиксированный выходной словарь. Добавка в знаменателе учитывает все |V| возможных продолжений.

Слайд 10. Сглаживание на семи токенах

Раздел: L04-S04. Идентификатор слайда: L04-10.

Для ручного примера положим α=1. В выходном словаре семь элементов: студент, читает, возвращает, книгу, журнал, EOS, UNK. Последний обозначает неизвестное слово; BOS в этот список не входит. После «студент» наблюдалось три продолжения, поэтому новый знаменатель равен 3+7=10.

Слайд 11. UNK объединяет разные слова

Раздел: L04-S04. Идентификатор слайда: L04-11.

Неизвестное сочетание нужно отличать от неизвестного слова. Для слова вне словаря нет отдельной выходной координаты. В нашей работе редкие слова обучения, встретившиеся меньше двух раз, объединяются в UNK. Затем этот же словарь применяется к validation и test. Модель оценивает получившуюся последовательность, а различия между заменёнными словами уже потеряны.

Слайд 12. Потеря на целевых токенах

Раздел: L04-S05. Идентификатор слайда: L04-12.

Чтобы проверить модель, предъявим ей новые тексты и на каждой позиции возьмём вероятность правильного следующего токена. Потеря позиции равна −ln p. Если вероятность близка к единице, потеря мала; если модель считает наблюдённый токен маловероятным, потеря растёт.

Слайд 13. Perplexity на трёх событиях

Раздел: L04-S05. Идентификатор слайда: L04-13.

Вернёмся к вероятностям 0,5; 0,25; 0,5. Их произведение равно 1/16, поэтому H=ln16/3≈0,9242, а perplexity=16^(1/3)≈2,5198. В три цели включён EOS. BOS здесь задавал начало и целью не являлся.

Слайд 14. Общие условия сравнения

Раздел: L04-S05. Идентификатор слайда: L04-14.

Для корпуса суммируем потери всех токенов и делим на их общее число. Простое среднее perplexity документов даст другое взвешивание: короткая записка и длинное письмо получат одинаковый вес. В нашей функции вместе с метрикой будет возвращаться число целей, чтобы можно было проверить знаменатель.

Слайд 15. Greedy: локальный максимум

Раздел: L04-S06. Идентификатор слайда: L04-15.

Жадный выбор, greedy, берёт самый вероятный токен на каждом шаге. Это локальное решение. Проверим на дереве из двух шагов: первая ветвь A имеет вероятность 0,6, вторая B — 0,4. Лучший следующий переход после A равен 0,4, после B — 0,9. Greedy начинает с A и получает путь вероятности 0,24. Путь через B имеет вероятность 0,36.

Слайд 16. Sampling создаёт разные пути

Раздел: L04-S06. Идентификатор слайда: L04-16.

При sampling следующий токен выбирается случайно с вероятностями модели. Самый частый вариант встречается чаще, но остальные тоже могут быть выбраны. Один и тот же префикс поэтому способен дать несколько продолжений. Для повторения опыта используем фиксированный seed; для наблюдения вариативности — несколько заранее выбранных значений.

Слайд 17. RNN обновляет состояние

Раздел: L04-S07. Идентификатор слайда: L04-17.

N-граммная модель хранит конкретный короткий хвост. Рекуррентная нейросеть вместо этого обновляет вектор состояния после каждого токена. Предыдущее состояние и текущий вход вместе определяют новое. Его можно рассматривать как сжатое представление уже прочитанного префикса.

Слайд 18. Нулевой вход не стирает прошлое

Раздел: L04-S07. Идентификатор слайда: L04-18.

Возьмём скалярный пример $h_t=\tanh(0{,}5h_{t-1}+e_t)$, $h_0=0$. При $e_1=1$ получим $h_1\approx0{,}7616$. Если $e_2=0$, то $h_2\approx0{,}3634$. Второй вход нулевой, но влияние предыдущего ещё сохраняется. Для двух нулевых входов оба состояния были бы нулевыми. Эти параметры заданы вручную, чтобы увидеть действие связи.

Слайд 19. Входы и цели сдвинуты

Раздел: L04-S08. Идентификатор слайда: L04-19.

Для «студент читает книгу» запишем два ряда. Входы: BOS, студент, читает, книгу. Цели: студент, читает, книгу, EOS. Сдвиг равен одной позиции. На каждом шаге считаем −ln вероятности соответствующей цели, затем объединяем потери.

Слайд 20. Откуда берётся следующий вход

Раздел: L04-S08. Идентификатор слайда: L04-20.

В режиме teacher forcing следующий вход берётся из эталонного текста. Если целевое слово — «книгу», а модель предпочла «журнал», при обучении следующий шаг всё равно получит «книгу». При свободной генерации дальше пойдёт выбранный самой моделью токен. Ошибка тогда меняет все последующие условия.

Слайд 21. LSTM управляет сохранением

Раздел: L04-S08. Идентификатор слайда: L04-21.

На длинной цепочке градиент может становиться очень маленьким или большим. Это затрудняет обучение дальних зависимостей. LSTM и GRU меняют устройство рекуррентного блока, чтобы гибче управлять сохранением информации. Например, LSTM поддерживает отдельное состояние ячейки и обучаемые коэффициенты сохранения, добавления и выдачи информации.

Слайд 22. Валидация выбирает биграмму

Раздел: L04-S09. Идентификатор слайда: L04-22.

В работе возьмём по одному обращению из каждой группы: 72 текста для обучения, 24 для валидации и 24 для теста. Общий словарь строится на train, min_count=2. Сравниваются n=1,2,3 при α=0,1. После выбора по validation оценивается выбранный порядок на test.

Слайд 23. Perplexity и покрытие словаря

Раздел: L04-S09. Идентификатор слайда: L04-23.

Тестовая perplexity биграммы составляет около 4,9404 на 190 целях. Чтобы понять абсолютную величину, посмотрим на покрытие: UNK заменил примерно 58,02% слов train, 68,48% validation и 71,08% test. Доля UNK считается по обычным словам, без EOS; в число целей perplexity EOS входит. Большая доля исходных различий потеряна. Более низкую тестовую perplexity по сравнению с обучающей нельзя объяснять только хорошим переносом: состав последовательностей после замены тоже различается.

Слайд 24. Прочитаем продолжения

Раздел: `L04-S09`. Идентификатор слайда: `L04-24`.

Генерация делает ограничение заметным. Greedy после «как» повторил UNK 40 раз и достиг предела. Sampling с seed 7 дал «как подать социальной стипендии» и EOS на четвёртом новом предсказании. Тема узнаваема, но фраза построена с грамматической ошибкой. Другие seed дали более длинные смеси конструкций. Чтение этих выходов помогает понять то, чего не видно в одной метрике.