План лекции «Внимание и Transformer»

Основной пример проходит через всё объяснение: $Q=K=I_2$, $V_1=(10;0)$, $V_2=(0;20)$. Сначала разбирается первый запрос, затем та же операция для всех строк и действие маски. Вторая часть связывает вычисление с устройством Transformer.

Часть	Содержание	Работа с аудиторией
От контекста к Q/K/V	Роли представлений и размерности	Найти источник запроса, ключей и значений
Числовой разбор	Скалярные произведения, softmax, сумма	Вручную получить первый выход и проверить нормировку
Маски и позиции	Будущее, padding, порядок	Предсказать результат изменения V_2 и перестановки токенов
Архитектура	Несколько голов, FFN, остаточные связи, семейства	Пройти по схеме блока и различить две последовательности в cross-attention
Обсуждение и лабораторная	Размер таблицы, интерпретация весов	Разобрать равные V при разных весах; сформулировать проверки реализации

Для пары 90 минут ориентировочно выделить 15 минут на Q/K/V, 25 на числовой разбор, 20 на маски и позиции, 20 на архитектуру и 10 на обсуждение и постановку лабораторной. Вопросы и совместные вычисления входят в эти интервалы.