Связь презентации и лекции

Внимание и Transformer

Слайд 01. Внимание и Transformer

Раздел: `L05-S01`. Идентификатор слайда: `L05-01`.

Механизм attention позволяет построить новое представление позиции, смешав информацию из нескольких доступных позиций. Степень их участия определяется весами. Одни значения внесут большой вклад, другие — маленький; при определённых ограничениях некоторые вообще не будут использоваться.

Слайд 02. Нужная деталь бывает далеко

Раздел: `L05-S01`. Идентификатор слайда: `L05-02`.

Представим длинное обращение. В начале студент указал ошибку 403, потом перечислил несколько попыток входа и в конце спросил, что делать. Для ответа может понадобиться именно номер из начала сообщения. В рекуррентной сети сведения о нём проходят через цепочку скрытых состояний. Хотелось бы иметь более прямой способ обратиться к нужной части текста.

Слайд 03. Из X получаем Q, K и V

Раздел: `L05-S02`. Идентификатор слайда: `L05-03`.

Пусть вход представлен матрицей X. В каждой строке находится вектор одной позиции: если токенов N, а координат d, размер X равен N×d. С помощью трёх обучаемых преобразований получим три набора векторов:

Слайд 04. Размеры подсказывают порядок

Раздел: `L05-S02`. Идентификатор слайда: `L05-04`.

Запрос и ключ должны иметь одинаковую размерность d_k, чтобы можно было вычислить их скалярное произведение. Размерность значения d_v может быть другой. Если N запросов сравниваются с M ключами, таблица оценок имеет размер N×M. У каждого запроса будет своя строка: по одной оценке для каждого доступного ключа.

Слайд 05. Два запроса, два ключа

Раздел: `L05-S03`. Идентификатор слайда: `L05-05`.

В scaled dot-product attention сначала вычисляют скалярные произведения запросов и ключей, затем делят оценки на $\sqrt{d_k}$. К каждой строке применяют softmax и получают веса. Последнее действие — умножение этих весов на значения:

Слайд 06. Из оценок получаются веса

Раздел: `L05-S03`. Идентификатор слайда: `L05-06`.

Теперь softmax. Экспонента от 0,7071 приблизительно равна 2,028, от нуля — 1. Делим каждое число на их сумму и получаем веса около (0,6698; 0,3302). Они складываются в 1. Нулевая исходная оценка при этом получила положительный вес: exp(0)=1, поэтому её вклад не исчез.

Слайд 07. Выход — взвешенная сумма

Раздел: `L05-S03`. Идентификатор слайда: `L05-07`.

Новое значение для первой позиции — 0,6698×(10; 0)+0,3302×(0; 20). При расчёте с неокруглёнными весами результат приблизительно равен (6,6976; 6,6048). Первая часть суммы дала вклад в первую координату, вторая — во вторую. У второго значения вес меньше, но его ненулевая координата вдвое больше; поэтому вклады в выход оказались близки по величине.

Слайд 08. Расчёт для всех запросов

Раздел: `L05-S03`. Идентификатор слайда: `L05-08`.

Для второго запроса в нашем примере веса меняются местами: (0,3302; 0,6698). Его выход приблизительно равен (3,3024; 13,3952). Полная матрица A имеет две строки; сумма элементов каждой строки равна 1. Одна строка относится к первому запросу, другая — ко второму.

Слайд 09. Будущее закрыто до softmax

Раздел: `L05-S04`. Идентификатор слайда: `L05-09`.

До сих пор каждый запрос мог обращаться ко всем ключам. Для анализа готового предложения это удобно: у слова есть левое и правое окружение. Но при авторегрессионном предсказании будущие токены ещё неизвестны. Если показать их модели во время обучения, она сможет использовать сведения, которых не будет при генерации.

Слайд 10. Что изменится при замене V2?

Раздел: `L05-S04`. Идентификатор слайда: `L05-10`.

Проверим понимание. Пусть мы изменили V_2, оставив Q, K, V_1 и маску прежними. Что произойдёт с первым выходом?

Слайд 11. Ранний выход не изменился

Раздел: `L05-S04`. Идентификатор слайда: `L05-11`.

При корректной маске выход первой позиции не меняется: изменённое значение по-прежнему умножается на нулевой вес. Это удобно проверить в лабораторной — такое изменение выявляет ошибку, если будущее оказалось случайно доступным.

Слайд 12. Padding исключаем из ключей

Раздел: `L05-S04`. Идентификатор слайда: `L05-12`.

Другой вид маски нужен для padding. Чтобы обработать несколько текстов одним пакетом, короткие последовательности часто дополняют служебными позициями до общей длины. Эти позиции не содержат сообщения пользователя. Маска ключей исключает их из источников информации.

Слайд 13. Когда все ключи закрыты

Раздел: `L05-S04`. Идентификатор слайда: `L05-13`.

Что произойдёт, если в строке закрыть все ключи? Экспоненты будут равны нулю, и нормировать их не получится: знаменатель тоже нулевой. В учебной реализации такой вход лучше явно отклонить. Это помогает отличить ошибку построения маски от содержательного поведения модели.

Слайд 14. Перестановка входа и выхода

Раздел: `L05-S05`. Идентификатор слайда: `L05-14`.

Для следующего опыта временно уберём маски: все позиции смогут обращаться ко всем ключам. В формуле QK^T нет номера позиции. Если одинаково переставить входные строки и не добавить позиционную информацию, такой self-attention переставит соответствующие выходные строки. Сами вычисления будут следовать за векторами. Это называют перестановочной эквивариантностью. Если П обозначает перестановку строк, то без позиций и ограничений Attention(ПX)=ПAttention(X). Неизменная причинная маска, напротив, уже различает доступ по положению и не подходит для этой проверки.

Слайд 15. Позиции остаются на местах

Раздел: `L05-S05`. Идентификатор слайда: `L05-15`.

Один из способов — добавить к представлению токена позиционный вектор: H=X+P. У одной и той же словоформы в разных местах вход теперь будет различаться. В исходной статье Transformer использовались синусоидальные позиционные представления; существуют и обучаемые, и другие способы задавать положение. Их общая задача — сделать порядок доступным вычислению.

Слайд 16. У каждой головы свои проекции

Раздел: `L05-S06`. Идентификатор слайда: `L05-16`.

Одна голова attention использует свои проекции запросов, ключей и значений. Если сделать несколько голов, каждая сможет выполнять сравнение в своём представлении. У всех один исходный текст, но обучаемые матрицы различаются.

Слайд 17. Соединяем результаты голов

Раздел: `L05-S06`. Идентификатор слайда: `L05-17`.

Для каждой головы вычисляются свои Q, K, V и свой выход. Затем выходы конкатенируют по координатам и применяют выходную проекцию W_O. Если у головы N строк и d_v координат, у h голов после конкатенации будет $N\times(h\cdot d_v)$. Проекция переводит это представление в нужную ширину модели. Например, у трёх голов с двумя координатами в каждой после конкатенации будет шесть координат для одной позиции.

Слайд 18. Внутри блока Transformer

Раздел: `L05-S07`. Идентификатор слайда: `L05-18`.

Attention — часть блока, а не весь Transformer. После обмена информацией между позициями модель также преобразует признаки каждой позиции. Для этого используется feed-forward сеть, обычно с нелинейностью между линейными слоями.

Слайд 19. Разная доступность контекста

Раздел: `L05-S08`. Идентификатор слайда: `L05-19`.

Энкодер обрабатывает доступную последовательность целиком. Для представления слова он может использовать левое и правое окружение, кроме заполнителей PAD, закрытых маской. Такой вариант подходит для получения признаков текста,

классификации и выделения сущностей. На следующей лекции мы будем использовать предобученный BERT-энкодер.

Слайд 20. Cross-attention связывает два ряда

Раздел: `L05-S08`. Идентификатор слайда: `L05-20`.

В encoder-decoder архитектуре исходная последовательность сначала проходит через энкодер. Декодер строит выход, используя собственный префикс и cross-attention к выходам энкодера. В таком cross-attention запросы происходят из состояния декодера, а ключи и значения — из представлений исходного текста.

Слайд 21. Квадратичный рост

Раздел: `L05-S09`. Идентификатор слайда: `L05-21`.

Если N запросов сравниваются с N ключами, таблица оценок содержит N^2 элементов. При увеличении длины в четыре раза число пар увеличивается в шестнадцать. Это видно геометрически: сторона квадратной таблицы выросла в четыре раза, а площадь — в шестнадцать.

Слайд 22. Разные веса — тот же выход

Раздел: `L05-S09`. Идентификатор слайда: `L05-22`.

Есть и другой важный вопрос: можно ли считать большой вес объяснением ответа? Вес действительно показывает вклад строки V в конкретную сумму. Но итог зависит и от значений, и от других голов, проекций, остаточных связей и последующих слоёв.

Слайд 23. Что проверить в реализации

Раздел: `L05-S10`. Идентификатор слайда: `L05-23`.

В лабораторной мы реализуем небольшой attention на NumPy. Сначала проверим softmax на простых числах, затем воспроизведём пример с двумя запросами, ключами и значениями. После этого добавим маски и посмотрим, какие изменения входа перестают влиять на результат.

Слайд 24. От ручных матриц к модели

Раздел: `L05-S10`. Идентификатор слайда: `L05-24`.

На следующем занятии вместо маленьких матриц мы возьмём готовый энкодер. Размеры станут больше, а параметры будут получены предобучением, но запросы, ключи, значения и маски сохранят тот смысл, который мы разобрали сегодня.