Заметки к презентации

Внимание и Transformer

01. Внимание и Transformer

– Начать с идеи: новое представление позиции объединяет информацию из доступного окружения.

– Веса определяют вклад доступных позиций.

– Сегодня разберём, как позиция может использовать информацию из окружения.

02. Нужная деталь бывает далеко

– Проследить раннюю деталь в длинном обращении.

– RNN передаёт состояние по цепочке.

– Attention позволяет сравнивать запрос с доступными ключами, в том числе удалёнными по позиции; вес ещё предстоит вычислить.

03. Из X получаем Q, K и V

– Показать общий вход и три отдельные обучаемые проекции.

– Строка соответствует позиции.

– Q и K имеют совместимую ширину; V может иметь другую.

04. Размеры подсказывают порядок

– Для устного примера подставить N=2 и M=3 в показанные общие размерности.

– Сначала получается таблица 2×3, затем умножение на три значения даёт два выходных вектора.

– Число запросов и ключей может различаться.

05. Два запроса, два ключа

– Первый запрос $q_1=(1;0)$.

– Его скалярные произведения с ключами равны 1 и 0.

– Значения V пока не участвуют.

– На слайде оценки уже разделены на $\sqrt{2}$; далее применим softmax.

06. Из оценок получаются веса

– После деления оценок на $\sqrt{2}$ уже получены 0,7071 и 0.

– После softmax веса равны 0,6698 и 0,3302, их сумма — 1.

– Нулевая оценка не означает нулевого веса.

07. Выход — взвешенная сумма

– Умножить каждое значение на его вес.

– Получить (6,6976;0) и (0;6,6048), затем сложить координаты.

– У меньшего веса может быть заметный вклад, если само значение больше.

08. Расчёт для всех запросов

– Каждая строка A относится к своему запросу.

– В нашем симметричном примере веса меняются местами.

– Умножение A на V даёт по новому вектору для каждой позиции; общего требования симметрии нет.

09. Будущее закрыто до softmax

– Заменить оценку будущего ключа на $-\infty$ до softmax.

– $\mathrm{Exp}(-\infty)=0$: первая строка весов становится (1;0).

– Это результат применения маски, сама маска задаёт доступность.

– Затем предложить вопрос следующего слайда.

10. Что изменится при замене V2?

– Остановиться на вопросе.

– Обсудить, какие величины изменились: только V_2; Q, K, V_1 и маска прежние.

– Попросить предсказать первый выход.

– Ответ показывается следующим кадром.

11. Ранний выход не изменился

– Сопоставить ответ с предыдущим кадром: доступность ключей осталась прежней.

– Вклад V_2' равен нулю, поэтому $o_1=V_1=(10;0)$.

– Это проверка применения маски, которую затем воспроизводим в коде.

12. Padding исключаем из ключей

– Сопоставить ключ позиции текста и ключ заполнителя PAD.

– Для позиции текста указано True, для заполнителя PAD — False.

– Маска ограничивает ключи; обработка выходов padding-позиций — отдельный вопрос.

13. Когда все ключи закрыты

– Попросить восстановить знаменатель softmax.

– Все экспоненты нулевые, поэтому нормировка не определена.

– В лабораторной такой вход вызывает ValueError.

14. Перестановка входа и выхода

– Сопоставить две части равенства: перестановку входных строк и ту же перестановку выходных.

– Маски и позиции отсутствуют.

– После одинаковой перестановки строк выходы меняют порядок таким же образом.

15. Позиции остаются на местах

– Сравнить перемещение содержимого и фиксированные позиционные значения.

– X меняется по порядку, P сохраняется по местам.

– Это уже другое изменение входа, чем перестановка X+P целиком.

16. У каждой головы свои проекции

– Объяснить параллельные обучаемые преобразования.

– Каждая голова получает общий X, но строит собственные Q/K/V и веса.

– Предметные роли голов заранее не назначаются.

17. Соединяем результаты голов

– Проследить, что координаты выходов голов записываются одна за другой, а не усредняются.

– Для устного примера возьмём три головы по две координаты: получится шесть координат одной позиции.

– W_O возвращает нужную ширину.

18. Внутри блока Transformer

– Найти слагаемые X и H: они сохраняют вход соответствующего подблока.

– Здесь pre-norm: LayerNorm перед attention и FFN.

– Attention включает выходную проекцию, поэтому размерность совместима с X.

19. Разная доступность контекста

– Это схемы доступности, не численные веса.

– Энкодер может обращаться к левому и правому окружению; причинный декодер использует префикс.

– В обоих случаях padding закрывается отдельно.

20. Cross-attention связывает два ряда

– Различить происхождение Q и K/V.

– Энкодер обрабатывает исходную последовательность.

– Декодер формирует запрос по своему состоянию и обращается к представлениям источника.

21. Квадратичный рост

– Сопоставить увеличение стороны в четыре раза с ростом площади в шестнадцать. 4/64 MiB относятся к одной полной матрице float32; весь расход реализации может отличаться.

22. Разные веса — тот же выход

– Два набора нормированных весов смешивают одинаковые значения.

– Оба дают (1;2).

– Поэтому карта A не определяет содержательную важность без V и дальнейшего вычисления.

23. Что проверить в реализации

– Связать каждую проверку с разобранной операцией: строковая нормировка, запрет ключа и изменение будущего значения.

– Студенты должны объяснить ожидаемый результат до выполнения кода.

24. От ручных матриц к модели

– Завершить вопросом о происхождении проекций.

– Сегодня числа были заданы вручную; в предобученном энкодере параметры уже получены на данных.

– Механизм внимания остаётся тем же.