Готовые представления и классификация обращений

Вы получите векторы обращений из предобученного энкодера и обучите на них классификатор. Сравнение с TF-IDF продолжает вторую лабораторную: теперь меняется источник признаков, а задача и разбиение остаются знакомыми.

Ход работы

Начните с вывода токенизатора и формы скрытых состояний одного текста. Проверьте несколько строк разной длины, наличие CLS и число усечений в корпусе. Затем напишите пакетное кодирование и проверьте влияние соседнего padding.

Обучите два фиксированных варианта классификатора, прочитайте метрики отдельных классов и сопоставьте ошибки разных групп. В конце исследуйте специально удлинённый вход и вручную разметьте сущности в короткой строке.

Что сдавать

Сдайте выполненный ноутбук с разбором ошибки энкодера, исправленной ошибки TF-IDF, усечения и BIO-разметки. На защите объясните, какие параметры обучались, откуда взят вектор текста и почему eval не равнозначен заморозке.

Оценивание

Критерий	Баллы	Что учитывается
Код	40	Токенизация, CLS, пакетное кодирование и классификация
Опыты	30	Сравнение двух систем, padding и длинный вход
Объяснение	20	Ошибки категорий, pooling и границы сущностей
Защита	10	Режимы модели и прогноз для изменения входа

Порог сдачи — 60 из 100. Перед сдачей перезапустите ядро и выполните все ячейки по порядку.