Связь презентации и лекции

Предобученный энкодер

Слайд 01. Предобученный энкодер

Раздел: `L06-S01`. Идентификатор слайда: `L06-01`.

На второй лекции классификатор учился по словам нашего небольшого корпуса. На пятой мы задавали матрицы attention вручную и прослеживали вычисления. Теперь возьмём энкодер, параметры которого уже получены при обучении на других текстах. Он преобразует обращение в контекстные векторы, а мы научимся использовать их для знакомой задачи выбора отдела.

Слайд 02. Архитектура, веса и наша задача

Раздел: `L06-S01`. Идентификатор слайда: `L06-02`.

Здесь полезно различать архитектуру, веса и прикладную систему. Архитектура описывает, какие вычисления выполняются. Веса задают конкретные обученные преобразования. Прикладная система определяет, как подать текст, какой выход взять и как связать его с шестью категориями университета «Север».

Слайд 03. Восстановление видит обе стороны

Раздел: `L06-S02`. Идентификатор слайда: `L06-03`.

В предложении «Студент положил книгу в сумку, чтобы нести её домой» скроем «сумку». Получится задание с пропуском внутри текста. Левое окружение говорит о помещении книги во что-то, правое — о переноске. Энкодер может использовать обе стороны, чтобы восстановить выбранный токен.

Слайд 04. Выбранные цели не все скрыты

Раздел: `L06-S02`. Идентификатор слайда: `L06-04`.

В исходном BERT выбирали 15% токенов как цели. Из выбранных 80% заменяли на [MASK], 10% — случайным токеном, 10% оставляли без изменения. Эти доли относятся к разным множествам. Для условных 1000 токенов выбирается около 150 целей, из них примерно 120 скрываются, 15 заменяются и 15 остаются прежними. Это иллюстрация ожидаемых пропорций, а не точные количества в каждом маленьком пакете.

Слайд 05. Три разные роли маски

Раздел: `L06-S02`. Идентификатор слайда: `L06-05`.

Слово «маска» здесь легко перепутать с пятой лекцией. [MASK] — токен, которым заменили содержимое. Padding-маска указывает, какие ключи относятся к техническому дополнению. Causal-маска запрещает будущие позиции. У них разные роли, хотя в разговоре используется одно слово.

Слайд 06. Токены принадлежат этой модели

Раздел: `L06-S03`. Идентификатор слайда: `L06-06`.

На первой лекции один адрес мог стать пятью токенами при выбранном регулярном выражении. У предобученного энкодера также есть собственные правила и словарь. Их нужно использовать вместе с моделью: идентификатор токена указывает на конкретную строку таблицы эмбеддингов.

Слайд 07. Padding выравнивает пакет

Раздел: `L06-S03`. Идентификатор слайда: `L06-07`.

Чтобы подать несколько текстов одним пакетом, строки дополняются до общей длины. `input_ids` содержит идентификаторы, `attention_mask` — указание содержательных и технических позиций в ожидаемом моделью формате. Если в пакете B текстов длины L после дополнения, обе таблицы имеют форму B×L. Для двух выбранных строк B=2 и L=6: у вопроса шесть единиц в маске, у «Спасибо» — три единицы и три нуля.

Слайд 08. Вектор для каждой позиции

Раздел: `L06-S04`. Идентификатор слайда: `L06-08`.

Энкодер возвращает `last_hidden_state` формы B×L×312. Для каждого текста и каждой позиции есть вектор из 312 координат. Для классификатора обращений нужен один вектор на текст, поэтому требуется выбрать способ объединения позиций — pooling.

Слайд 09. CLS выбирается у всех текстов

Раздел: `L06-S04`. Идентификатор слайда: `L06-09`.

В нашем опыте используется нормированный CLS, как рекомендует автор модели. Запись `hidden[:, 0, :]` выбирает первую позицию у всех B текстов и даёт B×312. После L2-нормировки каждая ненулевая строка имеет единичную длину.

Нормируем по оси признаков, чтобы соседние тексты пакета не участвовали в знаменателе.

Слайд 10. Padding попадает в среднее

Раздел: `L06-S04`. Идентификатор слайда: `L06-10`.

У других моделей может быть рекомендовано усреднение токенов. Рассмотрим его отдельно на маленьком примере: H=((1;0), (0;1), (9;9)), маска m=(1;1;0). Первые две позиции содержательные, третья обозначает padding.

Слайд 11. Маска выбирает слагаемые

Раздел: `L06-S04`. Идентификатор слайда: `L06-11`.

Обычное среднее всех трёх равно (10/3;10/3), а среднее выбранных маской — (0,5;0,5).

Слайд 12. Что меняется при дообучении

Раздел: `L06-S05`. Идентификатор слайда: `L06-12`.

Самый прямой вариант переноса — оставить энкодер фиксированным и обучить новую модель на его выходах. Мы получим векторы train и подадим их логистической регрессии вместе с шестью метками. Меняться будут коэффициенты классификатора, а преобразование текста внутри энкодера останется прежним.

Слайд 13. Три настройки решают разное

Раздел: `L06-S05`. Идентификатор слайда: `L06-13`.

В коде встречаются три похожих на первый взгляд действия. `eval()` переключает поведение модулей, например отключает случайное выбрасывание признаков в dropout. `requires_grad_(False)` задаёт, что для соответствующих параметров не нужен градиент. `inference_mode()` выполняет проход без обычного построения графа autograd.

Слайд 14. От пакета к признакам

Раздел: `L06-S06`. Идентификатор слайда: `L06-14`.

Рассмотрим один проход от списка строк к признакам. Токенизатор и энкодер уже загружены вместе. Переменная `texts` содержит пакет обращений.

Слайд 15. Индекс меняет форму результата

Раздел: `L06-S06`. Идентификатор слайда: `L06-15`.

Если случайно написать `hidden[0, 0, :]`, пропадёт весь второй текст: получится только 312 чисел первого.

Слайд 16. NER: границы и типы

Раздел: `L06-S07`. Идентификатор слайда: `L06-16`.

Теперь изменим форму результата. Вместо одной темы сообщения нужно выделить имена и организации. Эта задача называется named entity recognition, NER. Один документный вектор уже не даёт прямого соответствия границам слов, поэтому здесь используются представления позиций и сведения об их связи с исходным текстом.

Слайд 17. Граница имени тоже часть ответа

Раздел: `L06-S07`. Идентификатор слайда: `L06-17`.

Допустим, эталон — «Анна Петрова», а система вернула только «Петрова» с типом PER. При строгой оценке границы не совпали. Получается один лишний предсказанный фрагмент и один пропущенный эталон. Высокая доля правильно размеченных O в остальном тексте не исправляет эту ошибку выделения.

Слайд 18. От слова к подтокенам

Раздел: `L06-S07`. Идентификатор слайда: `L06-18`.

Слово может разбиться на несколько токенов модели. Тогда метки исходных слов нельзя просто прикрепить к выходам по порядку: после первого разбиения соответствие сдвинется. Один из подходов — обучать метку только на первом подтокене слова, а остальные исключать из потери. Другой распределяет метки по всем частям с согласованным правилом BIO.

Слайд 19. Качество на тесте выросло

Раздел: `L06-S08`. Идентификатор слайда: `L06-19`.

Сравним две заранее заданные системы. Первая — char_wb TF-IDF с фрагментами 3–5 и логистической регрессией. Вторая — нормированный CLS rubert-tiny2 и такая же регрессия с C=1. Разделение данных, шесть меток и функции оценки одинаковы. Энкодер фиксирован, новые коэффициенты классификатора обучаются только по train.

Слайд 20. Recall поступления — 0,40

Раздел: `L06-S08`. Идентификатор слайда: `L06-20`.

В показанных вариантах система на основе TF-IDF ошиблась в классификации обращений о монографии и подборе источников для курсовой, а система с энкодером определила их категории правильно. Однако у класса поступления recall равен только 0,40: двенадцать из двадцати его строк ушли в другие категории. Общая accuracy 0,90 этого не показывает.

Слайд 21. Короткие тексты не усечены

Раздел: `L06-S09`. Идентификатор слайда: `L06-21`.

В основном корпусе полные длины со специальными токенами лежат между 8 и 21. При пределе 128 ни одно обращение не усечено. Поэтому объяснять ошибки основной классификации потерянным концом здесь нельзя.

Слайд 22. Усечение убрало просьбу

Раздел: `L06-S09`. Идентификатор слайда: `L06-22`.

Построим отдельный диагностический текст: восемьдесят раз повторим строку `"Уточняю ранее отправленный вопрос. "`, а в конце добавим `"Как продлить книгу?"`. Точка и пробел входят в повторяемую строку. Полная длина получилась 566 токенов. После усечения осталось 128, и просьба о книге исчезла. Декодируем сохранённый вход, чтобы увидеть это непосредственно.

Слайд 23. Найдём причину ошибки

Раздел: `L06-S09`. Идентификатор слайда: `L06-23`.

Есть и другой недостаток входа: сообщение само по себе неоднозначно. Вопрос «Можно ли отправить пакет документов по почте?» отнесён к категории поступления в задуманной автором ситуации, но сама фраза может относиться к разным процедурам. В показанном варианте с приветствием энкодер выбрал библиотеку. Это расхождение с меткой одновременно поднимает вопрос о достаточности контекста.

Слайд 24. От токенов к прикладному ответу

Раздел: `L06-S10`. Идентификатор слайда: `L06-24`.

Теперь путь обращения выглядит так: текст проходит через связанный с моделью токенизатор, энкодер возвращает представления позиций, выбранный pooling даёт

один вектор, обученная голова выбирает отдел. Мы можем указать, какие параметры взяты из предобучения и какие получены на нашем train.