Заметки к презентации

Предобученный энкодер

01. Предобученный энкодер

– Связать готовые параметры с ручными матрицами прошлой лекции.

– Энкодер даёт представление, а нашим категориям ещё нужно обучить классификатор.

02. Архитектура, веса и наша задача

– Архитектура задаёт вычисления, веса — обученные значения параметров, наша разметка — категории отделов.

– Попросить отнести число слоёв, матрицу W и метку library к нужному уровню.

03. Восстановление видит обе стороны

– Левое окружение говорит о помещении книги, правое — о переноске.

– В MLM обе стороны доступны.

– В причинном предсказании правая часть ещё неизвестна.

04. Выбранные цели не все скрыты

– 15% относится ко всем токенам; 80/10/10 — к выбранным целям.

– Для условных 1000 токенов получаем около 150 целей, из них 120/15/15.

– Это исходная схема BERT, не утверждение об идентичном обучении rubert-tiny2.

– Затем различить MASK, padding и causal-маску.

05. Три разные роли маски

– Назвать действие каждого механизма на конкретном входе: заменить содержимое, исключить технические ключи, закрыть будущее.

– При классификации обычного текста вставлять MASK не требуется.

06. Токены принадлежат этой модели

– Показан реальный разбор вопроса «Как продлить книгу?» токенизатором rubert-tiny2: шесть позиций с CLS и SEP.

– Идентификаторы относятся к словарю этой модели; чужие номера подставлять нельзя.

– Затем добавим короткое «Спасибо» и соберём пакет из двух строк.

07. Padding выравнивает пакет

– В демонстрационном пакете два текста. Их полные длины 6 и 3, после padding L=6.

– Маска вопроса состоит из шести единиц. Для «Спасибо» — три единицы и три нуля.

– Единицы учитывают и специальные позиции. Энкодер вернёт вектор каждой позиции.

08. Вектор для каждой позиции

– Общая форма B×L×312. У показанного пакета B=2, L=6.

– Последняя ось — координаты одного вектора, средняя — позиции, первая — тексты.

– Для классификации нужно выбрать один вектор на текст.

09. CLS выбирается у всех текстов

– hidden[:,0,:] сохраняет обе строки пакета и выбирает CLS; форма 2×312.

– L2-нормировка выполняется по оси признаков. CLS рекомендован автором именно этого checkpoint.

– Отдельный пример среднего покажет, почему padding нужно учитывать явно.

10. Padding попадает в среднее

– Три ручных вектора; последний обозначает padding.

– Предсказать влияние (9;9) на среднее, затем применить маску.

– Это иллюстрация mean pooling, основной классификатор по-прежнему использует CLS.

– Следующий кадр показывает оба результата.

11. Маска выбирает слагаемые

– Обычное среднее делит сумму трёх строк на 3.

– Masked mean суммирует первые две строки и делит на 2.

– Для пустой маски нужно отдельное правило.

– Далее определим, какие параметры будут изменяться при обучении модели для нашей задачи.

12. Что меняется при дообучении

– В первой строке обучается только классификатор.

– При полном fine-tuning меняются и параметры энкодера.

– Показаны три варианта обучения; в работе используется первый.

13. Три настройки решают разное

– eval переключает dropout, requires_grad задаёт необходимость градиента параметров, inference_mode управляет проходом без обычного графа.

– Одно действие не заменяет остальные.

14. От пакета к признакам

– Проследить формы для тех же двух текстов: input_ids 2×6, hidden 2×6×312, признаки 2×312.

– Код в полном тексте дополнительно задаёт режим применения, заморозку и переход в NumPy.

– Теперь сравнить две почти одинаковые записи индекса.

15. Индекс меняет форму результата

– Для B=2 сравнить две формы.

– Один и тот же код на пакете из одного текста может скрыть ошибку, поэтому проверяется количество выходных строк.

16. NER: границы и типы

– По заданной инструкции имя включает первые два слова, организация — последние два.

– B начинает сущность, I продолжает её, O стоит вне сущностей.

– Это ручная разметка, не предсказание rubert-tiny2.

– Затем проверим частично найденное имя.

17. Граница имени тоже часть ответа

– При строгом совпадении «Петрова» вместо «Анна Петрова» даёт один FP и один FN.

– Если допускаются частичные совпадения, критерий задаётся отдельно и заранее.

– Ещё одна проблема границ появляется при разбиении слова на подтокены.

18. От слова к подтокенам

– Показан один вариант: обучаем метку первого подтокена, остальные исключаем из потери.

– Нужна связь подтокенов с исходным словом; другой вариант BIO может размечать все части.

– Дальше вернёмся к результатам классификации обращений.

19. Качество на тесте выросло

– Две заранее заданные системы сравниваются на 120 тестовых строках.

– Классификаторы одного семейства с одинаковым C обучены отдельно на своих признаках.

– Общие показатели улучшились.

– Далее проверить recall конкретной категории.

20. Recall поступления — 0,40

– У поступления 20 тестовых строк: верно распознаны 8, потеряны 12.

– Все ошибки энкодера в данном тесте относятся к этому классу.

– Accuracy 0,90 скрывает локальную слабость.

– Затем проверить, могло ли её объяснить усечение.

21. Короткие тексты не усечены

– У 600 основных обращений длины от 8 до 21 токена; при пределе 128 усечений нет.

– Их ошибки нельзя объяснить отрезанным концом.

– Следующий длинный пример построен отдельно для диагностики.

22. Усечение убрало просьбу

– Точная повторяемая строка: «Уточняю ранее отправленный вопрос. » — с точкой и пробелом.

– После 80 повторов добавлена просьба о книге.

– Полный вход содержит 566 токенов, усечённый — 128; просьба исчезла.

– Сравниваются длина полного входа и число токенов после усечения.

– Далее отличить эту причину ошибки от других.

23. Найдём причину ошибки

– Различить потерю входа, неоднозначность самого сообщения и неверное использование доступных сведений.

– Пример про документы по почте относится к достаточности контекста.

– Затем завершить весь путь классификации.

24. От токенов к прикладному ответу

– Токенизатор и энкодер взяты из готового комплекта; логистическая регрессия обучена по нашему train.

– CLS — промежуточный вектор, отдел выбирает классификатор.

– Для NER понадобился бы другой выход.

– Следующая лекция добавляет инструкцию и свободную генерацию.