Связь презентации и лекции

Инструкции и ответы LLM

Слайд 01. Инструкции и ответы LLM

Раздел: `L07-S01`. Идентификатор слайда: `L07-01`.

Студент спрашивает, можно ли продлить книгу, которую уже забронировал другой читатель. Модель отвечает коротко и уверенно: «Можно». Такой ответ легко прочитать, но пока неизвестно, верен ли он. В документе нашей учебной библиотеки сказано обратное: бронь другого читателя делает продление недоступным.

Слайд 02. Один документ, три проверки

Раздел: `L07-S01`. Идентификатор слайда: `L07-02`.

Возьмём один документ D03. Он разрешает продление на 14 дней через кабинет читателя, но запрещает его при чужой брони. Число продлений за семестр в документе не задано. По этим сведениям можно составить три разных проверки: срок, исключение и вопрос без нужного факта.

Слайд 03. Обучающие сигналы различаются

Раздел: `L07-S02`. Идентификатор слайда: `L07-03`.

При авторегрессионном предобучении модель учится продолжать тексты. Она получает префикс и повышает вероятность следующих токенов из обучающего материала. Это помогает освоить закономерности языка и содержание данных, но задача сама по себе не требует отвечать пользователю в нужном формате.

Слайд 04. Что именно требуется от ответа

Раздел: `L07-S03`. Идентификатор слайда: `L07-04`.

Запрос «Помоги студенту с библиотекой» оставляет много свободы. Неясно, какой вопрос нужно решить, разрешено ли добавлять общие советы, нужна ли короткая фраза и что делать, если сведений нет. Для свободной беседы такая постановка может подойти, но сравнить результаты по ней трудно.

Слайд 05. Две инструкции, один источник

Раздел: `L07-S03`. Идентификатор слайда: `L07-05`.

При сравнении оставим сам документ и вопросы одинаковыми. Если вместе с уточнённой инструкцией добавить новый источник, разницу ответа уже нельзя связать только с инструкцией. Это тот же принцип контролируемого изменения, который применялся при сравнении словных и символьных признаков.

Слайд 06. Пример добавляется в контекст

Раздел: `L07-S04`. Идентификатор слайда: `L07-06`.

В zero-shot постановке мы даём инструкцию без решённых примеров текущей задачи. В few-shot добавляем несколько пар «вход — нужный выход». Например, один пример показывает, как кратко вернуть факт из документа, второй — как ответить при его отсутствии.

Слайд 07. Few-shot не обновляет веса

Раздел: `L07-S04`. Идентификатор слайда: `L07-07`.

Параметры от этих демонстраций не обновляются. Модель читает их как часть текущего контекста. Если в следующем независимом вызове примеров нет, приложение не может рассчитывать, что они стали постоянным знанием весов. История чата тоже передаётся приложением, а не возникает внутри отдельного запроса сама собой.

Слайд 08. Масштабирование оценок

Раздел: `L07-S05`. Идентификатор слайда: `L07-08`.

Пусть модель уже вычислила оценки следующего токена z. Для выборки можно разделить их на положительную температуру T, а затем применить softmax: $p_i = \exp(z_i/T) / \Sigma_j \exp(z_j/T)$. Это изменение распределения выбора, а не переобучение модели.

Слайд 09. Три значения temperature

Раздел: `L07-S05`. Идентификатор слайда: `L07-09`.

Посчитаем три оценки (2;1;0). При T=1 вероятности примерно (0,6652;0,2447;0,0900). При T=0,5 различия оценок усиливаются: получается (0,8668;0,1173;0,0159). При T=2 распределение более ровное: (0,5065;0,3072;0,1863).

Слайд 10. Уверенность и достоверность

Раздел: `L07-S05`. Идентификатор слайда: `L07-10`.

Greedy в нашем коде задаётся выбором максимума и отключённой выборкой. Мы не делим оценки на T=0: это не определённая математическая операция. При фиксированных оценках greedy вообще не нуждается в вероятностной выборке из оставшихся альтернатив.

Слайд 11. Top-p оставляет нужную массу

Раздел: `L07-S06`. Идентификатор слайда: `L07-11`.

Nucleus sampling, или top-p, сначала упорядочивает вероятности по убыванию. Затем оставляет минимальное число верхних элементов, накопленная сумма которых достигает порога p. Остальные исключаются, а оставшиеся вероятности нормируются заново.

Слайд 12. Делим на выбранную массу

Раздел: `L07-S06`. Идентификатор слайда: `L07-12`.

Делим первые два числа на 0,8 и получаем (0,625;0,375;0). Третий токен больше не участвует в выборке.

Слайд 13. Порядок правил декодирования

Раздел: `L07-S06`. Идентификатор слайда: `L07-13`.

В реальном опыте дополнительно задан top_k=20. В используемой версии библиотеки для этих параметров сначала применяется temperature, затем top-k и top-p. Поэтому реальную выборку нельзя объяснять только операцией top-p, которую мы отдельно разобрали на числах. Упрощённая функция объясняет одну операцию; полный вызов сохраняет все настройки.

Слайд 14. EOS или предел продолжения

Раздел: `L07-S06`. Идентификатор слайда: `L07-14`.

Ограничение новых токенов решает другую задачу. `max_new_tokens=64` задаёт предел числа новых предсказаний; оно не означает, что ответ обязан иметь 64 обычных слова. Модель может раньше выдать EOS, а может достичь предела, не завершив мысль. Причина остановки будет сохранена вместе с исходным ответом.

Слайд 15. От ролей к последовательности

Раздел: `L07-S07`. Идентификатор слайда: `L07-15`.

В интерфейсе мы видим сообщения с ролями system, user и assistant. Для модели они превращаются в последовательность специальных разделителей и содержимого. Эту процедуру задаёт chat template, связанный с выбранным токенизатором и моделью.

Слайд 16. Считаем весь вход модели

Раздел: `L07-S07`. Идентификатор слайда: `L07-16`.

Вызов `apply_chat_template` использует `add_generation_prompt=True`, чтобы обозначить начало ответа assistant. Для выбранного Qwen3 задан `enable_thinking=False`. Если сначала получаем от шаблона строку, а потом токенизируем отдельно, ставим `add_special_tokens=False`, чтобы не добавить специальные позиции второй раз.

Слайд 17. Отделяем новые токены

Раздел: `L07-S07`. Идентификатор слайда: `L07-17`.

У decoder-only генератора выход обычно включает исходный префикс и новые токены. Поэтому после генерации берём `output[0, input_length:]` и декодируем только эту часть. Если показать весь массив как ответ, рядом окажутся и введённый документ, и собственный вывод модели.

Слайд 18. Два критерия ответа

Раздел: `L07-S08`. Идентификатор слайда: `L07-18`.

Рассмотрим ответ «Можно» на вопрос о книге с чужой бронью. Он короткий, но противоречит D03. Теперь ответ «На 14 дней» на вопрос о количестве продлений за семестр. Сам срок подтверждён документом, однако он отвечает на другой вопрос. Эти ошибки различаются, хотя обе требуют нулевой оценки главного факта поставленной задачи.

Слайд 19. Смысл отказа и формат

Раздел: `L07-S08`. Идентификатор слайда: `L07-19`.

Для strict проверяется и формат. Если данных нет, требуется точная строка «НЕТ ДАННЫХ». «В источнике это не указано» может быть содержательно подходящим отказом, но не совпадает с заданным форматом. Для basic такого требования не

было, поэтому несовпадение с этой строкой нельзя считать нарушением инструкции.

Слайд 20. Схема верна, факт ошибочен

Раздел: `L07-S08`. Идентификатор слайда: `L07-20`.

В JSON-опыте требуются ровно два ключа: `answer` со строкой и `has_answer` с логическим значением. Начнём с обычного JSON-парсера, затем проверим корневой тип, набор ключей и типы значений. Строка `"false"` не равна логическому `false`. Markdown-ограждение вокруг объекта тоже не входит в заданный ответ.

Слайд 21. Условие прочитано неверно

Раздел: `L07-S09`. Идентификатор слайда: `L07-21`.

В основной части выполнены шесть запросов: две инструкции и три вопроса, всегда greedy. Оба варианта правильно назвали срок 14 дней. Оба ошиблись на условии чужой брони. В strict модель вернула «Ответ: Можно.» — короткая форма не исправила главный факт.

Слайд 22. Срок не заменяет число раз

Раздел: `L07-S09`. Идентификатор слайда: `L07-22`.

На вопрос о числе продлений basic начал добавлять правило о продлении каждую неделю и дошёл до предела 64 новых токенов. Это неподдержанная подробность и незавершённый ответ. Strict вместо количества снова назвал срок 14 дней: «Продление книги можно продлить на 14 дней.». Здесь не было нужного отказа, хотя связанная с темой цифра оказалась правильной сама по себе.

Слайд 23. Четыре одинаковых ответа

Раздел: `L07-S09`. Идентификатор слайда: `L07-23`.

Затем один strict-промпт о сроке проверен при T=0,5 и T=1 с seed 7 и 42, при одинаковых top-p и top-k. Все четыре выборки дали «14 дней.» и завершились EOS. В этих наблюдениях изменение параметров не проявилось в видимом тексте. Это не означает, что распределение осталось прежним: его изменение мы уже рассчитали на числовом примере.

Слайд 24. JSON прошёл обе проверки

Раздел: `L07-S09`. Идентификатор слайда: `L07-24`.

Отдельный JSON-запрос вернул `{"answer":"14","has_answer":true}`. Структура прошла проверку, число соответствует вопросу о днях и документу. В схеме не требовалось включать слово «дней» внутрь строки, поэтому его отсутствие не является форматной ошибкой этого опыта.

Слайд 25. Следующий шаг — поиск

Раздел: `L07-S10`. Идентификатор слайда: `L07-25`.

Сегодня документ был известен заранее и целиком передан модели. Поэтому ошибки нельзя объяснять тем, что поисковик не нашёл D03. Мы исследовали инструкцию, декодирование и чтение доступного источника.