Заметки к презентации

Инструкции и ответы LLM

01. Инструкции и ответы LLM

– Открыть вопросом о книге с чужой бронью.

– Короткое «Можно» звучит понятно, но противоречит нашему источнику.

– Сегодня различить связность, выполнение инструкции и правильность.

02. Один документ, три проверки

– D03 сообщает срок 14 дней и исключение при чужой брони, но не число продлений.

– Определить три эталонных ответа до вызова модели.

– Эта информационная основа остаётся одинаковой в опытах с двумя инструкциями.

03. Обучающие сигналы различаются

– Сопоставить три формата данных.

– Веса меняются при обучении.

– Это функциональные различия, а не обязательная одинаковая последовательность подготовки любой LLM.

04. Что именно требуется от ответа

– Прочитать три требования strict: источник, короткая форма, отказ при отсутствии факта.

– Они задают проверяемое поведение.

– Далее сравним два входа с одним документом.

05. Две инструкции, один источник

– Две инструкции получают один D03 и одинаковые вопросы.

– Модель и greedy неизменны.

– Если добавить новый документ только strict, это уже другое сравнение.

06. Пример добавляется в контекст

– Few-shot показан на правиле о ссылке восстановления пароля: срок 30 минут известен, количество повторных запросов не задано.

– Демонстрации показывают факт и отказ.

– В основном сравнении лабораторной few-shot не используется.

– Далее отделить контекст от изменения весов.

07. Few-shot не обновляет веса

– Модель читает примеры как часть контекста.

– В следующем независимом вызове они должны быть переданы снова.

– Это отличие от SFT.

– Затем перейдём к изменению выбора токенов при фиксированных весах.

08. Масштабирование оценок

– T положительна.

– Оценки делятся на T до softmax: порядок сохраняется, концентрация меняется.

– Следующий слайд сравнивает три температуры на одних оценках (2;1;0).

09. Три значения temperature

– Вероятности округлены до четырёх знаков.

– При T=0,5 первый токен получает около 0,8668, при T=2 — 0,5065.

– Строки нормированы с учётом округления.

– Порядок A/B/C прежний.

– Затем обсудить, чего температура не проверяет.

10. Уверенность и достоверность

– Низкая T усиливает уже существующее предпочтение, но не добавляет факт.

– Greedy задаётся отдельным режимом без выборки; деления на ноль нет.

– Вернуться к неверному разрешению при брони.

– Далее ограничим набор кандидатов через top-p.

11. Top-p оставляет нужную массу

– Первый элемент даёт массу 0,5, первые два — 0,8 и пересекают порог 0,75.

– Число сохранённых элементов минимально.

– Таблица показывает накопление вероятности A и B.

– Следующий шаг — нормировка выбранной массы.

12. Делим на выбранную массу

– A и B сохраняются, C исключается.

– Деление на 0,8 даёт 0,625 и 0,375.

– Top-p меняет набор кандидатов, сохраняя параметры модели прежними.

– В полном вызове также действует top-k.

13. Порядок правил декодирования

– Порядок проверен в используемой версии Transformers.

– В опыте top_k=20 и top_p=0,8, температура 0,5 либо 1.

– Ручной расчёт top-p объяснял одну операцию; полный вызов сохраняет все настройки.

– Далее различить выбор токена и причину остановки.

14. EOS или предел продолжения

– MAX_NEW=64 считает новые токены, не обычные слова.

– EOS может появиться раньше; остановка по limit может оборвать ответ.

– Затем покажем, почему измерять нужно весь вход после шаблона.

15. От ролей к последовательности

– System общий для двух вариантов: учебный помощник, русский язык.

– Ограничение источником находится в user только для strict.

– Шаблон обозначает роли и начало assistant.

– Эта структура входит в реальную длину запроса.

16. Считаем весь вход модели

– Длина включает роли, разделители и содержимое.

– После отдельного применения шаблона токенизируем без повторного добавления специальных токенов.

– В опыте отклоняем вход длиннее 768, сохраняя источник целиком.

– Затем выделим только новое продолжение.

17. Отделяем новые токены

– Выход decoder-only модели включает префикс.

– Срез начинается после L входных токенов.

– Введённый документ не является частью нового ответа.

– Само продолжение теперь нужно проверить по содержанию и форме.

18. Два критерия ответа

– «Можно» при чужой брони коротко, но неверно.

– «14 дней» на вопрос о числе продлений подменяет требуемую величину.

– Главный факт оценивается относительно вопроса.

– Отказ тоже нужно разделить на смысл и буквальный формат.

19. Смысл отказа и формат

– В strict требуется ровно «НЕТ ДАННЫХ».

– Другое пояснение может честно сообщать об отсутствии факта, но не совпадать с форматом.

– Для basic такое требование не выдавалось.

– В JSON появится ещё более явная проверка структуры.

20. Схема верна, факт ошибочен

– Это ручной контрпример, а не наблюдённый JSON-вывод модели.

– Структура объекта верна, но число 42 противоречит сроку D03.

– Проверить типы, затем факт отдельно.

– Следующий кадр показывает реальную ошибку strict.

21. Условие прочитано неверно

– Буквальный ответ strict на вопрос о брони: «Ответ: Можно.».

– Блок «В документе D03» передаёт смысл запрета.

– Короткая форма не обеспечила верность.

– Следующая ошибка касается подмены количества сроком.

22. Срок не заменяет число раз

– Точная просьба спрашивает количество продлений.

– В D03 его нет, ожидается отказ.

– Модель strict вместо этого повторила срок.

– Basic добавил правило о каждой неделе и дошёл до предела; подробный вывод сохранён в ноутбуке.

23. Четыре одинаковых ответа

– Результаты одного strict-вопроса о сроке.

– Во всех четырёх вызовах top_p=0,8 и top_k=20; меняются T и seed.

– Ответ везде буквально «14 дней.» с EOS.

– По совпадению строк нельзя заключить, что распределения одинаковы.

– Затем показать отдельный JSON-опыт.

24. JSON прошёл обе проверки

– Фактический объект отформатирован для слайда. answer — строка, has_answer — bool; ключей два.

– Число 14 соответствует вопросу о днях, единица в самой строке не требовалась схемой.

– Это один успешный случай.

– Завершить переходом к поиску источника.

25. Следующий шаг — поиск

– Сегодня D03 был выбран заранее.

– Следующий шаг — поиск в коллекции, включение фрагментов и та же проверка ответа.

– Если документ уже доступен, но условие прочитано неверно, одно улучшение поиска не устраняет эту ошибку.