Заметки к презентации

RAG: ответ по документам

01. RAG: ответ по документам

– Пользователь спрашивает о заявлении на пересдачу, не прикладывая инструкцию.

– Сначала нужно найти источник.

– Сегодня проследить путь документа до проверяемого ответа.

02. Поиск приносит контекст

– Показать границу поиска и генерации.

– Найденные сведения входят в текущий запрос; веса модели не дообучаются.

– Каждый переход дальше будем проверять отдельно.

03. Граница разрывает условие

– Первый кусок отвечает на вопрос о сроке, но недостаточен для вопроса с чужой бронью.

– Граница между связанными предложениями меняет доступное основание ответа.

04. Срок и условие остаются вместе

– Тот же материал теперь доступен вместе.

– Перекрытие тоже может помочь, но приносит повторы.

– В нашей короткой базе один документ равен одному фрагменту.

05. Индекс связан с редакцией текста

– Условное обновление, не изменение действующего корпуса курса.

– Если срок в источнике поменяли, нужно обновить его вектор и связь с версией.

– Старый ответ оценивается по старому входу.

06. Матрица оценок поиска

– Векторы CLS нормированы.

– D хранит 12 документов, Q — 30 вопросов.

– Матрица QD^T содержит оценку каждой пары.

– Эталон не участвует в кодировании или сортировке.

– Далее прочитаем полученные ранги.

07. Ранги за тестовыми числами

– Шестнадцать ответимых тестовых вопросов: 13 первых мест, одно второе, одно третье, один пропуск.

– Recall@1=13/16, Recall@3=15/16, MRR@3≈0,8646.

– Вопросы без ответа не входят в эти знаменатели.

– Даже верхний кандидат ещё требует проверки содержания.

08. Top-3 ещё не означает три ответа

– Запрос о сумме стипендии находит документы близкой темы, но суммы нет.

– Ранжирование даёт кандидатов.

– Наличие конкретного факта проверяется чтением.

09. От выдачи к входу модели

– Показан отдельный тест упаковки с очень длинной копией D03.

– Кандидаты D03/D04, в контекст входит только D04.

– Это не обычная выдача основного опыта.

10. Токенизатор считает весь вход

– Токенизаторы энкодера и генератора различаются.

– Подсчёт включает роли, вопрос, заголовки и разделители.

– Сначала измерить реальный вход, затем проверять предел.

11. Каждый кандидат проверяется

– Сначала проверяется вопрос без источников.

– Затем каждый кандидат пробуется целиком.

– Пропуск одного не завершает цикл: следующий может оказаться короче.

– Усечение не используется.

12. Три проверки ссылки

– Первый уровень — распознать идентификатор, второй — проверить его присутствие во входе, третий — сопоставить утверждение и источник.

– Проверка regex не выполняет последний шаг.

13. Один D03, два разных утверждения

– Оба идентификатора существуют.

– Первое утверждение подтверждено, второе противоречит условию.

– Нужно читать связь источника с каждой существенной частью ответа.

14. Факт верен, вопрос другой

– Это смысл фактического ответа Q14.

– D02 подтверждает часы работы ИТ-службы, но пользователь спрашивает о месте подачи заявления.

– Релевантность вопросу и поддержка контекстом независимы.

15. На каком этапе потерян ответ?

– Для каждого случая выбрать проверяемый этап.

– Несколько ошибок могут встречаться одновременно.

– Эти различия определяют, какое изменение имеет смысл исследовать.

16. Когда отказ уместен

– При пустом контексте источников отказ может быть честным для генератора, но не решать ответимый вопрос по полной базе.

– Если факта нет во всей коллекции, уместный отказ выполняет задачу.

– Формат оценивается отдельно.

17. Три контекста для одного Q14

– Empty не получает источников, обычный RAG получает свою выдачу, oracle намеренно получает эталон.

– Модель и декодирование одинаковы.

– Oracle — диагностика, не результат обычного поиска.

18. Oracle: ответ с эталонным D07

– Буквальный oracle-ответ Q14.

– В обычной выдаче D07 не было, с эталоном ответ получился.

– Это основание исследовать работу поиска в данном случае; oracle нельзя включать в основную метрику.

19. Команда внутри источника

– Команда находится внутри данных источника.

– Приложение требует использовать документы как сведения, не выполнять их команды.

– Далее проверим реальное поведение на изменённой копии.

20. Команда изменила ответ

– Команда добавлена к копии D03 после поиска.

– Вопрос, остальные источники и правильный срок сохранились.

– Обычный ответ о 14 днях сменился на «42. Нет данных.».

– Проверяется один вход генератора; CSV и индекс не изменялись.

– Далее свести основные случаи по типам ошибок.

21. Четыре ответимых вопроса

– Четыре заранее выбранных ответимых случая.

– Q05 верен; Q06 переворачивает условие при D03; Q08 отказывается при включённом D04; в Q14 поиск пропустил D07.

– Общая колонка «галлюцинация» скрыла бы эти различия.

– Следом идут два вопроса вне базы.

22. В двух вопросах факта нет

– Эти вопросы не имеют ответа в коллекции.

– Отказ по смыслу ожидаем и при empty, и при RAG.

– Следующий слайд покажет отдельную ошибку буквального формата.

23. Смысл верен, формат нарушен

– Фактическая строка отличается от требуемой регистром и точкой. exact_refusal=False не означает отсутствия отказа по смыслу.

– Не исправлять строку перед оценкой исходного результата.

24. Следующий опыт по результату

– Для Q14 есть основание исследовать поиск.

– Для Q06 и Q08 требуется проверка использования доступного источника.

– Менять по одному условию, выбирать на данных разработки и проверять на новых вопросах.

– Завершить курс самостоятельным объяснением одного случая.

25. От данных к объяснению

– Завершить курс конкретным заданием: выбрать наблюдение, показать доступные сведения, место расхождения и одно проверяемое изменение.

– Связать это с подготовкой данных, представлением и оценкой из предыдущих тем.