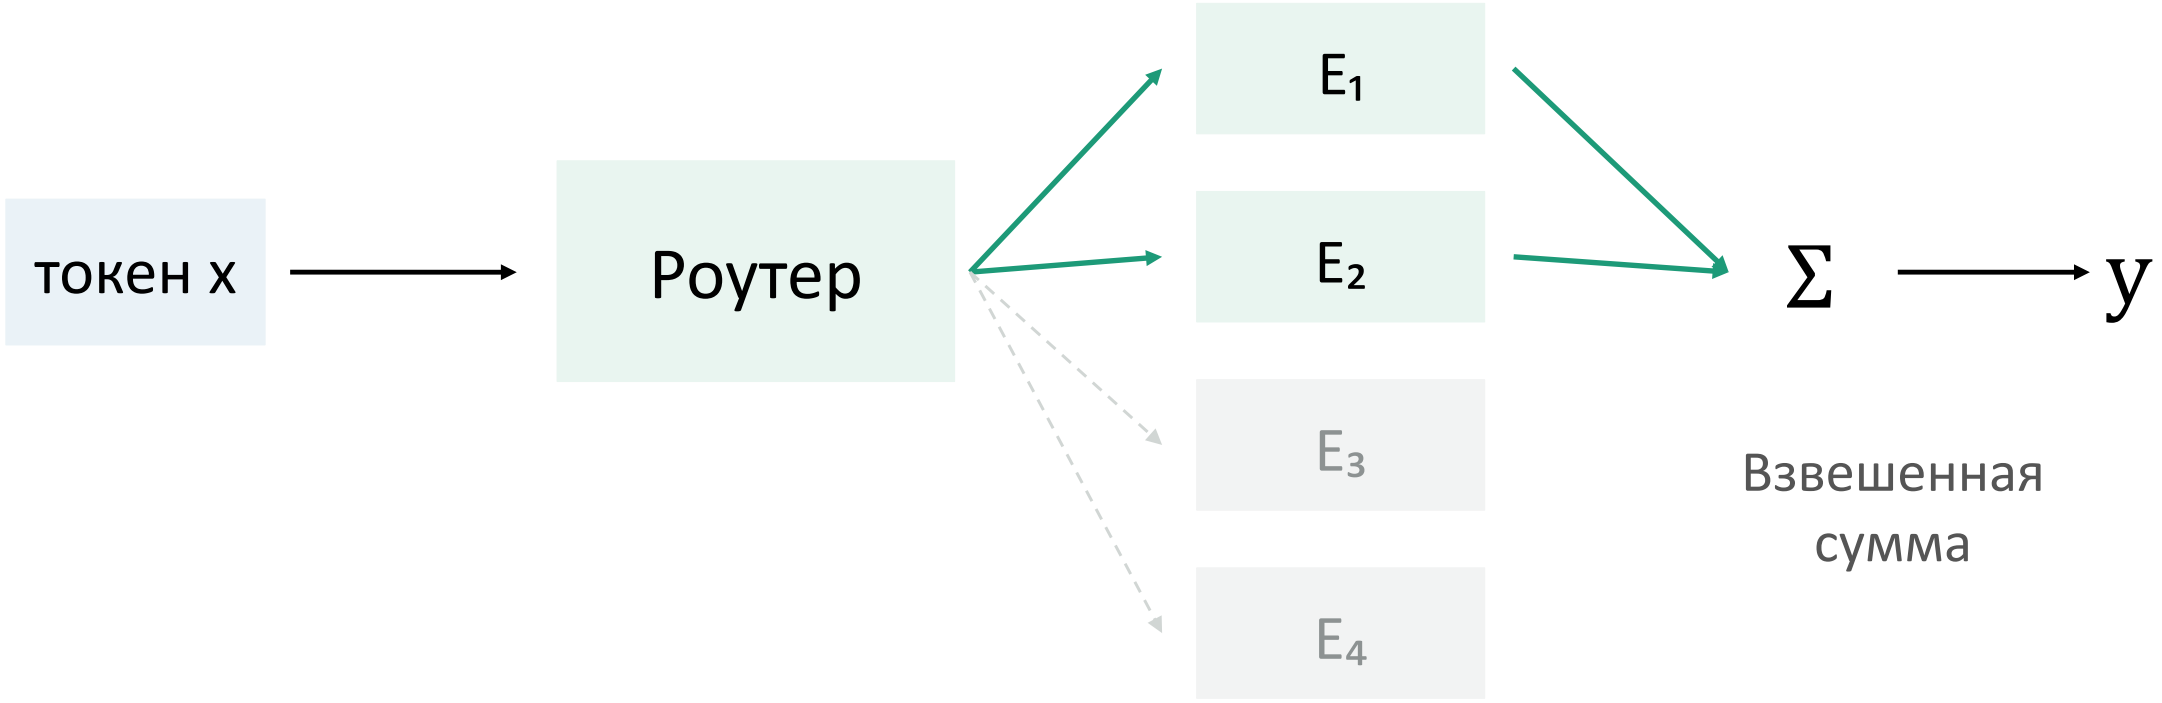
Shazeer et al., 2017

Mixture of Experts

Для одного токена вычисляется часть экспертных сетей



Роутер выбирает экспертов

Top-2: оставляем две оценки и делим их на 0,8

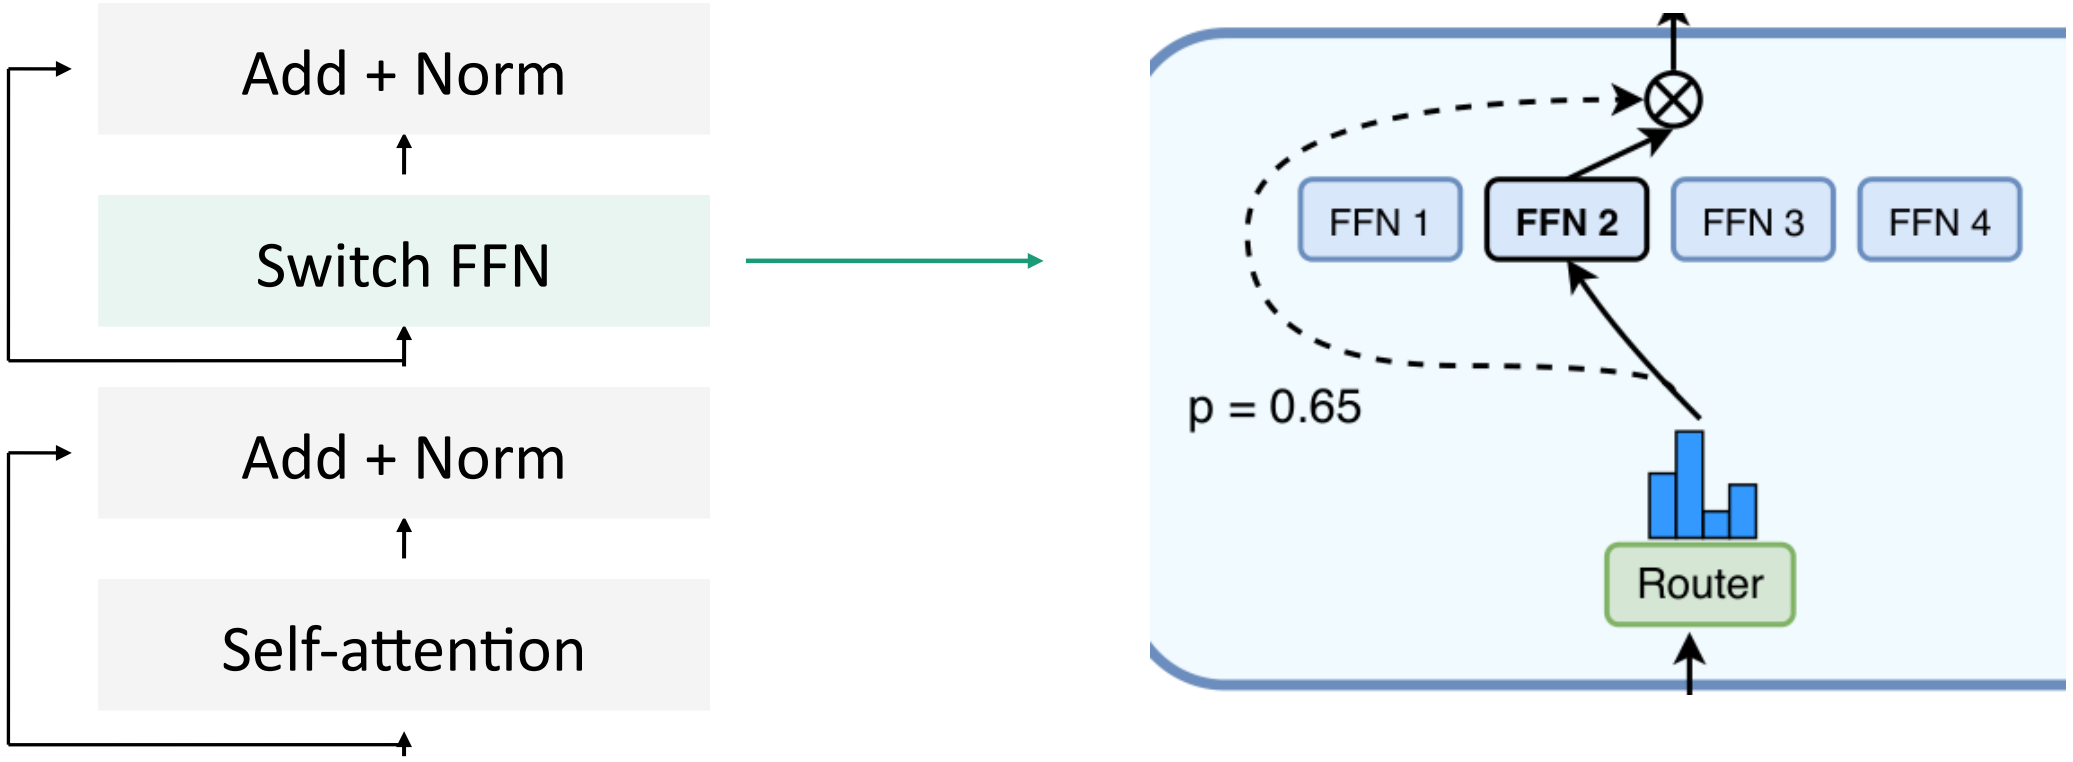
E_1	E_2	E_3	E_4
0,55	0,25	0,15	0,05
÷ 0,8 = 0,6875	÷ 0,8 = 0,3125		

$$y = 0.6875\, E_1(x) + 0.3125\, E_2(x)$$

Числа — учебный пример; идея sparse gating: Shazeer et al., 2017

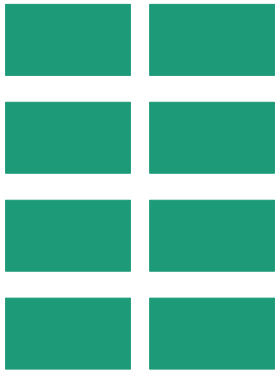
Switch Transformer: top-1

Каждый токен проходит через один выбранный FFN



Достаточно ли добавить экспертов?

Восемь токенов выбрали одного эксперта

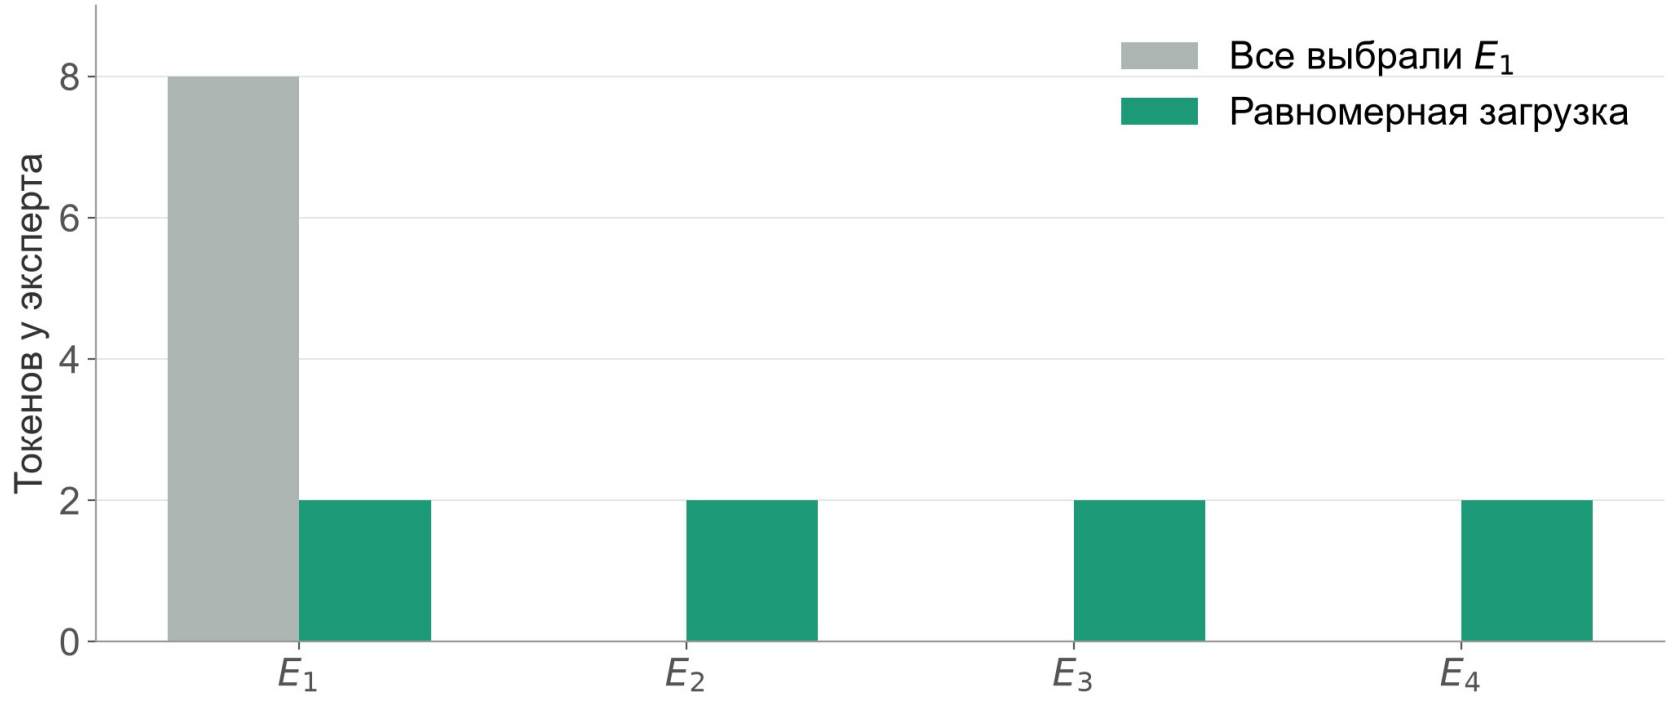


0 0 0

E_1 E_2 E_3 E_4

Балансировка загрузки

Одинаковое число экспертов — разные маршруты токенов



Учебная иллюстрация. Методы балансировки: Fedus et al., 2022