Классификация текста

От слов в сообщении
к решению модели

При обучении известны ответы

Обучение

Тексты + верные метки → Параметры модели

Применение

Новый текст → Модель → Категория

Проверяем на новых ситуациях

Все варианты одного обращения остаются вместе



120 групп · 600 строк

Учебный корпус · разделение по group_id

Каждому слову — своя координата

d1 книга книга библиотека

d2 книга продление

d3 общежитие оплата

	библиотека	книга	общежитие	оплата	продление
d1	1	2	0	0	0
d2	0	1	0	0	1
d3	0	0	1	1	0

Учебный пример · строки — документы, столбцы — слова

TF и DF считают разные вещи

В первом документе

книга книга

библиотека

$TF = 2$

Во всей коллекции

d1 книга книга библиотека

d2 книга продление

d3 общежитие оплата

$DF = 2$

Учебный пример · DF учитывает документ один раз

Меньше DF — больше IDF

N = 3 документа

$$IDF = 1 + \ln((1 + N) / (1 + DF))$$

книга

DF = 2

1,2877

библиотека

DF = 1

1,6931

scikit-learn · сглаженный IDF; натуральный логарифм

Длина вектора становится единицей

Координаты: библиотека, книга

$$(1{,}6931;\ 2{,}5754)$$

↓ ÷ евклидова длина

$$(0{,}5494;\ 0{,}8356)$$

$$0{,}5494^2 + 0{,}8356^2 \approx 1$$

Сумма координат не обязана равняться 1

Побеждает наибольшая оценка

x: книга = 0,8; пароль = 0,1

Коэффициенты заданы вручную · b = 0

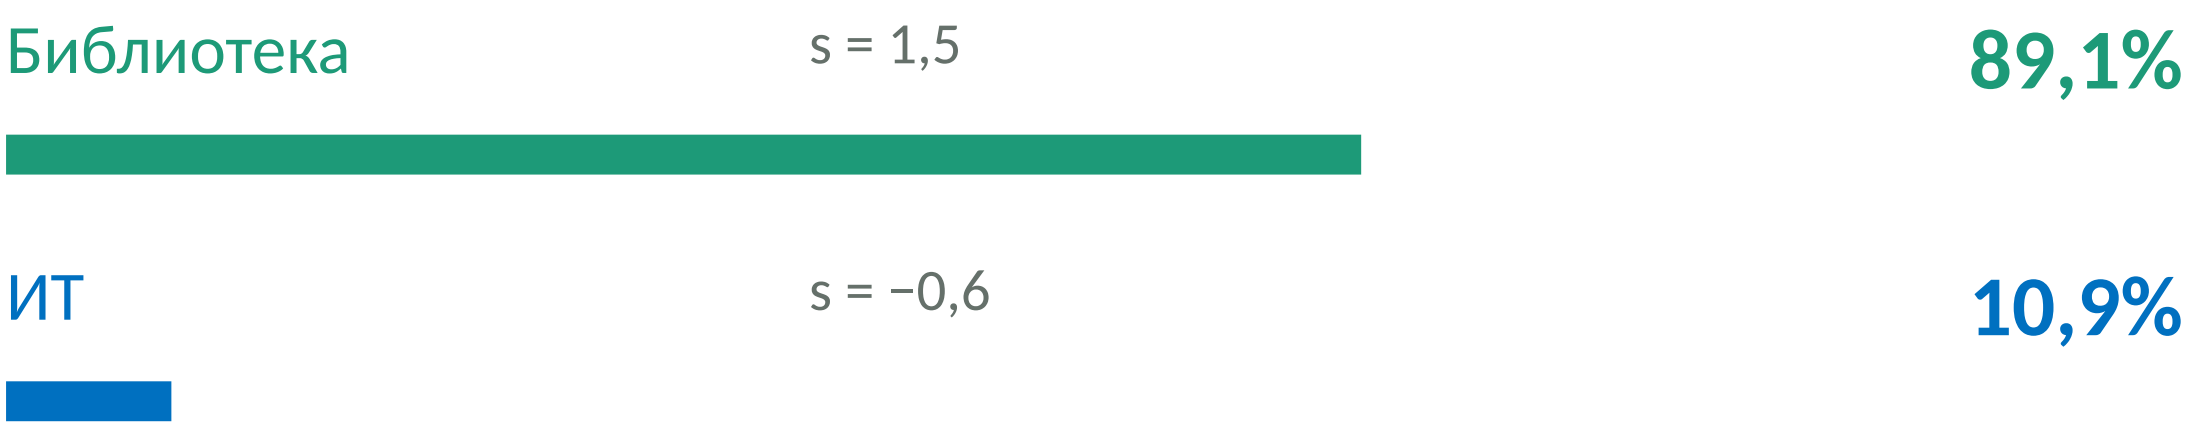
Библиотека $2 \times 0{,}8 - 0{,}1 = 1{,}5$

ИТ $-0{,}8 + 2 \times 0{,}1 = -0{,}6$

Учебный пример · $s_c = w_c^T x + b_c$

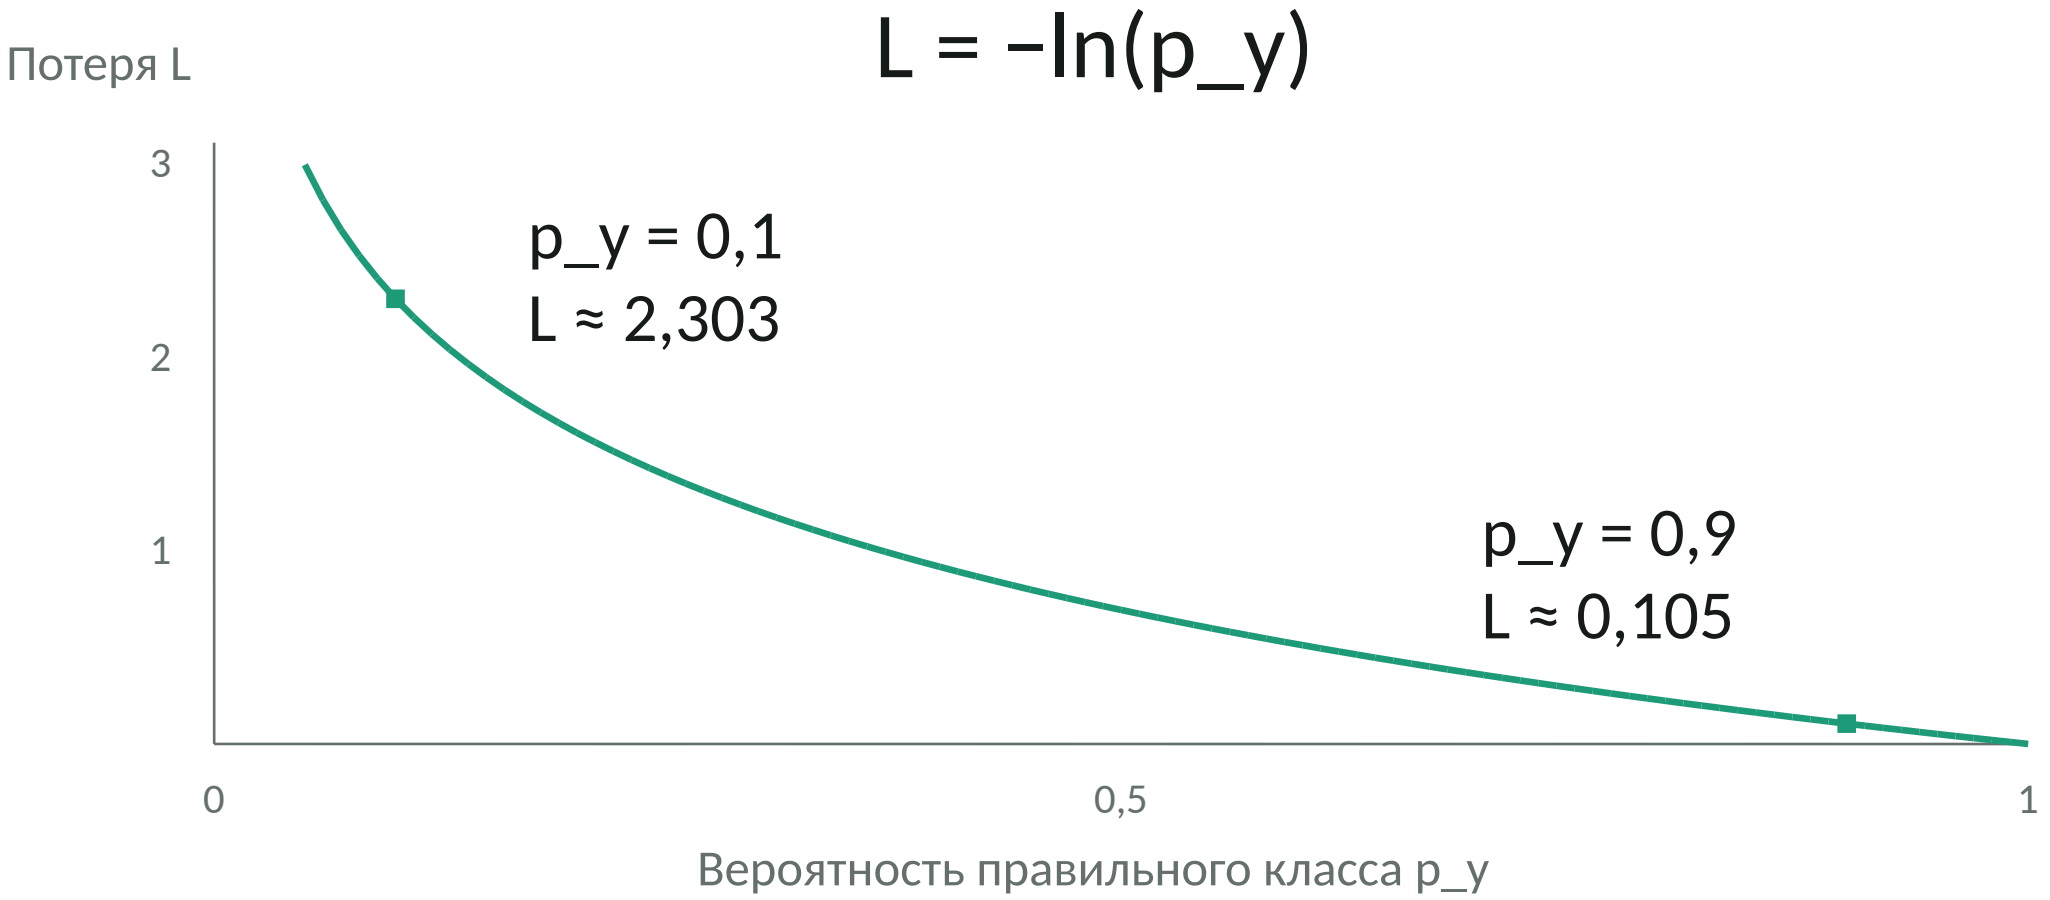
Softmax даёт вероятности

$$p(c) = \exp(s_c) / \Sigma \exp(s_j)$$



0,891 + 0,109 = 1

Уверенная ошибка стоит дороже



Новый вес — новая оценка

Правильный класс — библиотека

Вес «книги»	2	→	2,1
Оценка	1,5	→	1,58
Вероятность	0,891	→	0,898

Учебный шаг · изменён один вес; остальные параметры прежние

Регуляризация ограничивает веса

При обучении учитываем

Логарифмическую потерю на train + Штраф за большие коэффициенты

C ↓ → Более сильная регуляризация

scikit-learn · LogisticRegression: C — обратная сила регуляризации

Baseline задаёт точку отсчёта

Шесть равных классов

16,7%

Всегда одна категория

90% писем — ИТ

90%

Всегда ИТ

Обе стратегии обходятся без чтения текста

Учебные распределения · доля правильных ответов

Accuracy может скрыть провал

Модель всегда отвечает A

		Предсказанный класс A	Предсказанный класс B
Истинный класс	A	90	0
	B	10	0

Accuracy = 90 / 100 = 0,9

B: найдено 0 из 10

Precision и recall считают разное

Для A: TP = 90, FP = 10, FN = 0

Precision

$$\frac{90}{100} = 0{,}9$$

Среди предсказанных A

Recall

$$\frac{90}{90} = 1$$

Среди всех настоящих A

Macro-F1 даёт классам равный вес

$$F1 = 2TP / (2TP + FP + FN)$$

F1(A)

0,9474

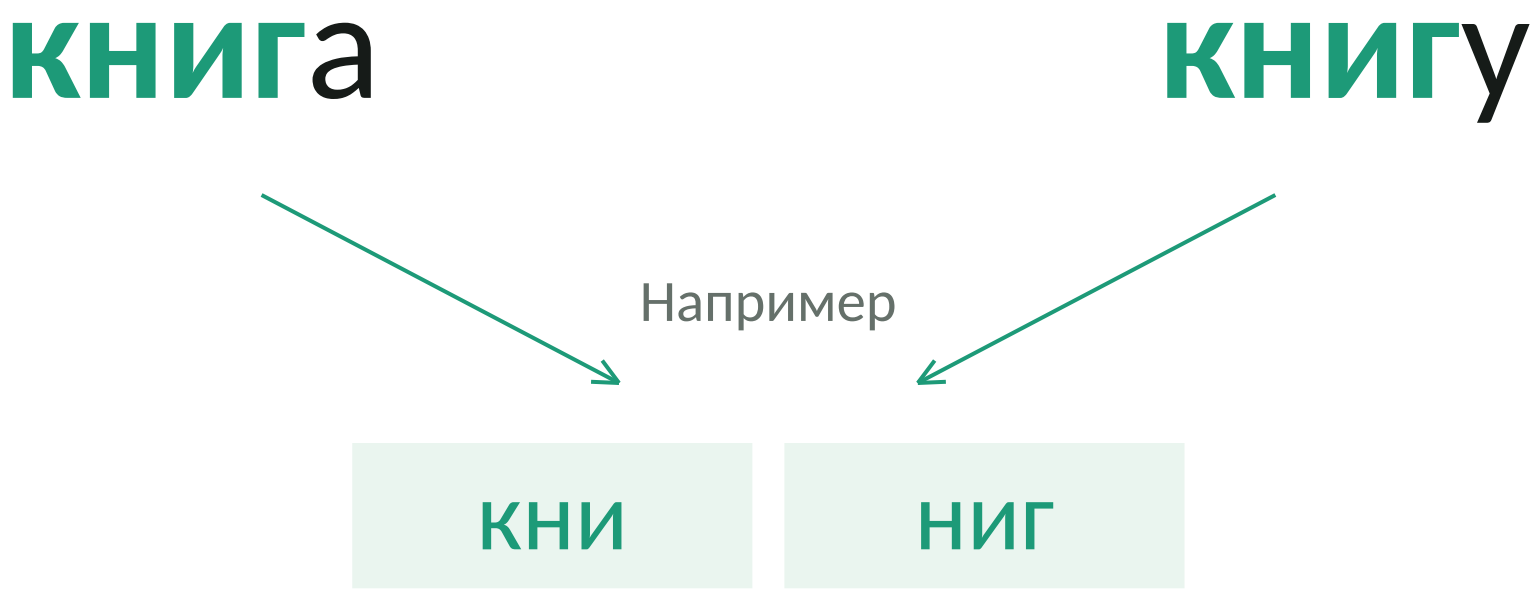
F1(B)

0

$$(0{,}9474 + 0) / 2 \approx 0{,}4737$$

У тех же ответов accuracy = 0,9

Словоформы имеют общие части



char_wb · длины 3–5 · внутри границ слов

Выбираем по validation

Macro-F1 на validation

Слова

Униграммы и биграммы

0,4120

Символы

char_wb, длины 3–5

0,7430

Одинаковый train и алгоритм · отдельное обучение

Выполненная лабораторная L02 · validation: 120 строк

Pipeline сохраняет порядок действий

Обучение

Тексты train	→	TF-IDF	→	Классификатор
train		fit		fit(X, y)

Применение

Новые тексты	→	TF-IDF	→	Классификатор
validation / test		transform		predict

y — верные метки train · predict использует сохранённые словарь, IDF и веса

Сначала split, затем fit

Ошибка: сначала обучили преобразователь на всех текстах

Все тексты → fit TF-IDF → split

Словарь и IDF уже учитывают test

Сначала отделяем проверочные ситуации

split по группам → fit только на train

Отложенные тексты проходят transform

На тесте верны 95 ответов из 120

TF-IDF char_wb + логистическая регрессия

Правильные ответы

95 / 120

Accuracy ≈ 0,792

Macro-F1

0,765

24 исходные ситуации

Выполненная лабораторная L02 · выбранный вариант, отложенный test

Число метрики не объясняет ошибку

«Не могу найти **монографию**
в списке доступной литературы.»

Верная категория

Библиотека

Ответ модели

ИТ

Какие признаки могли повлиять на ответ?

Учебный корпус · точная строка из ошибок выбранной модели

Одна просьба — разные ответы

Верная категория — библиотека

«Мне нужна помощь в подборе источников для курсовой.» → ИТ

«**Здравствуйте!** Мне нужна помощь в подборе источников для курсовой.» → Учебный процесс

Как проверить устойчивость к формулировке?

library-20 · все пять ошибочны: один ответ ИТ, четыре — учебный процесс