Классификация текста

От слов в сообщении
к решению модели

При обучении известны ответы

Обучение

Текст + верные метки → Параметры модели

Применение

Новый текст → Модель → Категория

Проверяем на новых ситуациях

Все варианты одного обращения остаются вместе

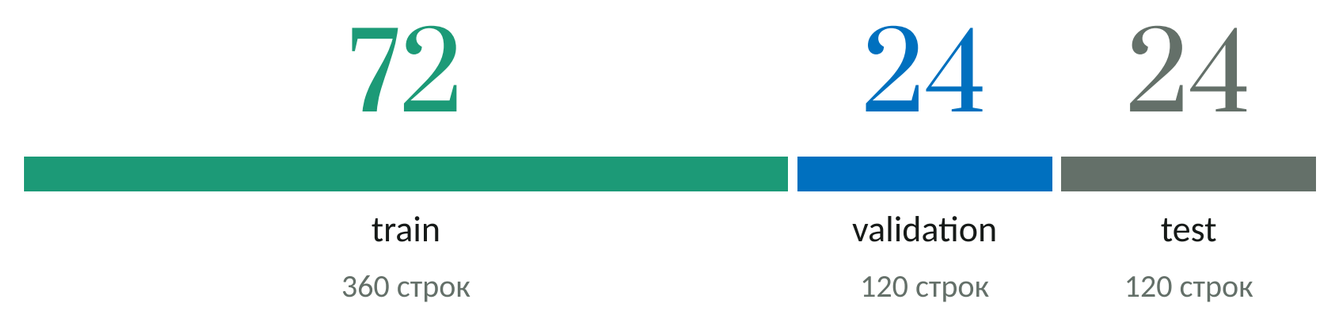

120 групп · 600 строк

Учебный корпус · разделение по group_id

Каждому слову — своя координата

d1 книга книга библиотека
d2 книга продление
d3 общежитие оплата

	библиотека	книга	общежитие	оплата	продление
d1	1	2	0	0	0
d2	0	1	0	0	1
d3	0	0	1	1	0

Учебный пример · строки — документы, столбцы — слова

TF и DF считают разные вещи

В первом документе	Во всей коллекции
книга книга библиотека	d1 книга книга библиотека d2 книга продление d3 общежитие оплата
TF = 2	DF = 2

Учебный пример · DF учитывает документ один раз

Меньше DF — больше IDF

N = 3 документа

IDF = 1 + ln((1 + N) / (1 + DF))

книга	библиотека
DF = 2	DF = 1
1,2877	1,6931

scikit-learn · сглаженный IDF; натуральный логарифм

Длина вектора становится единицей

Координаты: библиотека, книга

(1,6931; 2,5754)

↓ ÷ евклидова длина

(0,5494; 0,8356)

$0{,}5494^2 + 0{,}8356^2 \approx 1$

Сумма координат не обязана равняться 1

Побеждает наибольшая оценка

x: книга = 0,8; пароль = 0,1

Коэффициенты заданы вручную · b = 0

Библиотека 2 × 0,8 − 0,1 = 1,5

ИТ −0,8 + 2 × 0,1 = −0,6

Учебный пример · $s\_c = w\_c^{T}x + b\_c$

Softmax даёт вероятности

p(c) = exp(s_c) / Σ exp(s_j)

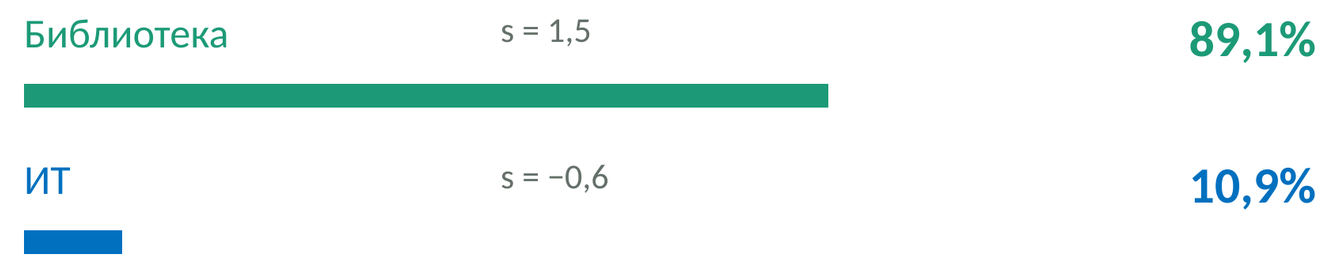

0,891 + 0,109 = 1

Уверенная ошибка стоит дороже

L = −ln(p_y)

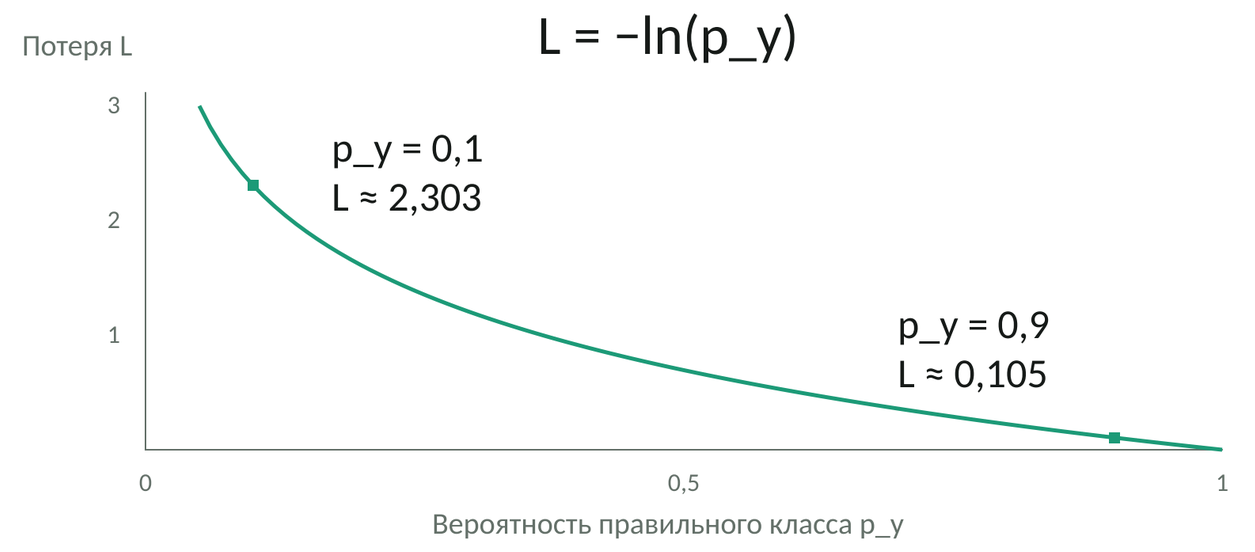

Новый вес — новая оценка

Правильный класс — библиотека

Вес «книги»	2	→	2,1
Оценка	1,5	→	1,58
Вероятность	0,891	→	0,898

Учебный шаг · изменён один вес; остальные параметры прежние

Регуляризация ограничивает веса

При обучении учитываем

Логарифмическую потерю на train + Штраф за большие коэффициенты

C ↓ → Более сильная регуляризация

scikit-learn · LogisticRegression: C — обратная сила регуляризации

Baseline задаёт точку отсчёта

Шесть равных классов	90% писем — ИТ
16,7%	90%
Всегда одна категория	Всегда ИТ

Обе стратегии обходятся без чтения текста

Учебные распределения · доля правильных ответов

Accuracy может скрыть провал

Модель всегда отвечает A

		Предсказанный класс	
		A	B
Истинный класс	A	90	0
	B	10	0

Accuracy = 90 / 100 = 0,9

B: найдено 0 из 10

Precision и recall считают разное

Для A: TP = 90, FP = 10, FN = 0

Precision	Recall
$\frac{90}{100} = 0{,}9$	$\frac{90}{90} = 1$
Среди предсказанных A	Среди всех настоящих A

Macro-F1 даёт классам равный вес

F1 = 2TP / (2TP + FP + FN)

F1(A)	F1(B)
0,9474	0

(0,9474 + 0) / 2 ≈ 0,4737

У тех же ответов accuracy = 0,9

Словоформы имеют общие части

книга **книг**у

Например

кни ниг

char_wb · длины 3–5 · внутри границ слов

Выбираем по validation

Macro-F1 на validation

Слова	Символы
Униграммы и биграммы	char_wb, длины 3–5
0,4120	0,7430

Одинаковый train и алгоритм · отдельное обучение

Выполненная лабораторная L02 · validation: 120 строк

Pipeline сохраняет порядок действий

Обучение

Тексты train → TF-IDF → Классификатор
train fit fit(X, y)

Применение

Новые тексты → TF-IDF → Классификатор
validation / test transform predict

y — верные метки train · predict использует сохранённые словарь, IDF и веса

Сначала split, затем fit

Ошибка: сначала обучили преобразователь на всех текстах

Все тексты → fit TF-IDF → split

Словарь и IDF уже учитывают test

Сначала отделяем проверочные ситуации

split по группам → fit только на train

Отложенные тексты проходят transform

На тесте верны 95 ответов из 120

TF-IDF char_wb + логистическая регрессия

Правильные ответы	Macro-F1
95 / 120	0,765
Accuracy ≈ 0,792	24 исходные ситуации

Выполненная лабораторная L02 · выбранный вариант, отложенный test

---

Число метрики не объясняет ошибку

«Не могу найти **монографию**
в списке доступной литературы.»

Верная категория	Ответ модели
Библиотека	ИТ

Какие признаки могли повлиять на ответ?

Учебный корпус · точная строка из ошибок выбранной модели

Одна просьба — разные ответы

Верная категория — библиотека

«Мне нужна помощь в подборе источников для курсовой.» → ИТ

«**Здравствуйте!** Мне нужна помощь в подборе источников для курсовой.» → Учебный процесс

Как проверить устойчивость к формулировке?

library-20 · все пять ошибочны: один ответ ИТ, четыре — учебный процесс