Как языковая модель продолжает текст

От частот соседних слов
к памяти последовательности

У префикса несколько продолжений

«Студент открыл…»

Префикс → Распределение → Выбранный токен

Варианты следующего токена

Токен добавляется к префиксу; начинается следующий шаг

У последовательности есть границы

BOS → Слова текста → EOS

Начало контекста

Предсказываемое завершение

BOS служит входом; EOS входит в цели оценки

Вероятность пути — произведение

Три события на одном выбранном пути

$$0{,}5 \times 0{,}25 \times 0{,}5 = 1/16$$

Внутри шага — сумма альтернатив

Вдоль выбранной последовательности — произведение переходов

Длина истории равна n − 1

Модель	n	Длина истории
Униграмма	1	0
Биграмма	2	1
Триграмма	3	2

n включает и предсказываемый токен

Три предложения дают счётчики

1 студент читает книгу

2 студент читает журнал

3 студент возвращает книгу

К каждому предложению добавляем BOS и EOS

Ручной мини-корпус из трёх предложений

Частота становится вероятностью

После слова «студент»

Продолжение	Частота	Вероятность
читает	2	2/3
возвращает	1	1/3

$$P(w|h) = c(h,w) / c(h)$$

Новый переход получает ноль

«студент журнал»

Наблюдённая частота

0

Вероятность текста

Один нулевой переход обнуляет произведение

Известные слова могут образовать невстречавшееся сочетание

Добавка меняет весь знаменатель

Add-alpha · α > 0

$$P(w|h) = (c(h,w) + \alpha) / (c(h) + \alpha|V|)$$

Добавка относится ко всем |V| продолжениям

Выходной словарь фиксирован

Сглаживание на семи токенах

$\alpha = 1$; $|V| = 7$; после «студент»: $c(h) = 3$

Продолжение	Расчёт	Вероятность
читает	(2 + 1) / 10	0,3
возвращает	(1 + 1) / 10	0,2
Каждый из пяти остальных	(0 + 1) / 10	0,1

$$0{,}3 + 0{,}2 + 5 \times 0{,}1 = 1$$

Словарь: студент, читает, возвращает, книгу, журнал, EOS, UNK

UNK объединяет разные слова

Словарь строится на train · min_count = 2

Редкие слова обучения → UNK → Тот же словарь

Для validation и test

Разные заменённые слова становятся одной целью

Потеря на целевых токенах

Потеря одной позиции: $-\ln p$

$$H = -(1/T)\ \Sigma\ \ln P(\text{цель} \mid \text{история})$$

$$\text{Perplexity} = \exp(H)$$

T — общее число целевых позиций

Perplexity на трёх событиях

Те же события: 0,5; 0,25; 0,5

Средняя потеря H

0,9242

ln(16) / 3

Perplexity

2,5198

16^(1/3)

Три цели включают EOS; BOS не является целью

Общие условия сравнения

Тексты и токены	Одинаковые события для обеих моделей
Словарь	Одинаковые замены на UNK
Границы и вес	Одинаковый учёт EOS и числа целей

Числа perplexity сравнимы при общей постановке

Greedy: локальный максимум

Два шага генерации

Greedy выбирает A

0,24

0,6 × 0,4

Путь через B

0,36

0,4 × 0,9

Локальный максимум не гарантирует самый вероятный полный путь

Остальные продолжения A: 0,35 и 0,25; остаток после B: 0,1

Sampling создаёт разные пути

Greedy	Sampling
Самый вероятный токен	Выбор по вероятностям
Один определённый путь	Возможны разные пути

Разные выбранные токены могут менять следующие распределения

RNN обновляет состояние

Одни и те же параметры на всех позициях

h_(t−1) → Обновление → h_t

Прежнее состояние

Учитывает вход e_t

Новое состояние

Состояние передаёт информацию о прочитанном префиксе

Нулевой вход не стирает прошлое

$$h_t = \tanh(0{,}5h_{t-1} + e_t);\ h_0 = 0$$

$$e_1 = 1 \rightarrow h_1 \approx 0{,}7616$$

$$e_2 = 0 \rightarrow h_2 \approx 0{,}3634$$

Параметры заданы вручную; второй вход нулевой, состояние — нет

Входы и цели сдвинуты

Позиция	1	2	3	4
Вход	BOS	студент	читает	книгу
Цель	студент	читает	книгу	EOS

Выход после w_t предсказывает w_(t+1)

Откуда берётся следующий вход

Модель предпочла «журнал», правильная цель — «книгу»

Teacher forcing

Следующий вход

книгу

Свободная генерация

Следующий вход

журнал

Ошибка генерации меняет условия следующих шагов

LSTM управляет сохранением

Сохранение	Часть прежнего состояния ячейки
Добавление	Новая информация
Выдача	Информация для текущего выхода

Коэффициенты обучаются и обычно непрерывны

Концептуальные роли механизмов LSTM

Валидация выбирает биграмму

Общий словарь: 47 выходных элементов · α = 0,1

Порядок	Validation PPL	Выбор
n = 1	6,6388	
n = 2	4,9800	Биграмма
n = 3	6,0382	

Выбор по validation, затем оценка на test

Лабораторная 4 · 72 / 24 / 24 исходных текста

Perplexity и покрытие словаря

Test perplexity

4,9404

190 целей с EOS

Слова test → UNK

71,08%

Доля без EOS

Модель оценивает последовательность после замены слов

Прочитаем продолжения

Greedy после «как»

<UNK> повторился 40 раз

Остановка по пределу

Sampling · seed 7

«как подать социальной стипендии»

EOS на четвёртом новом предсказании

Чтение результата дополняет числовую метрику

Буквальные результаты лабораторной 4