Внимание и Transformer

Как одна позиция получает информацию от остальных

Нужная деталь бывает далеко

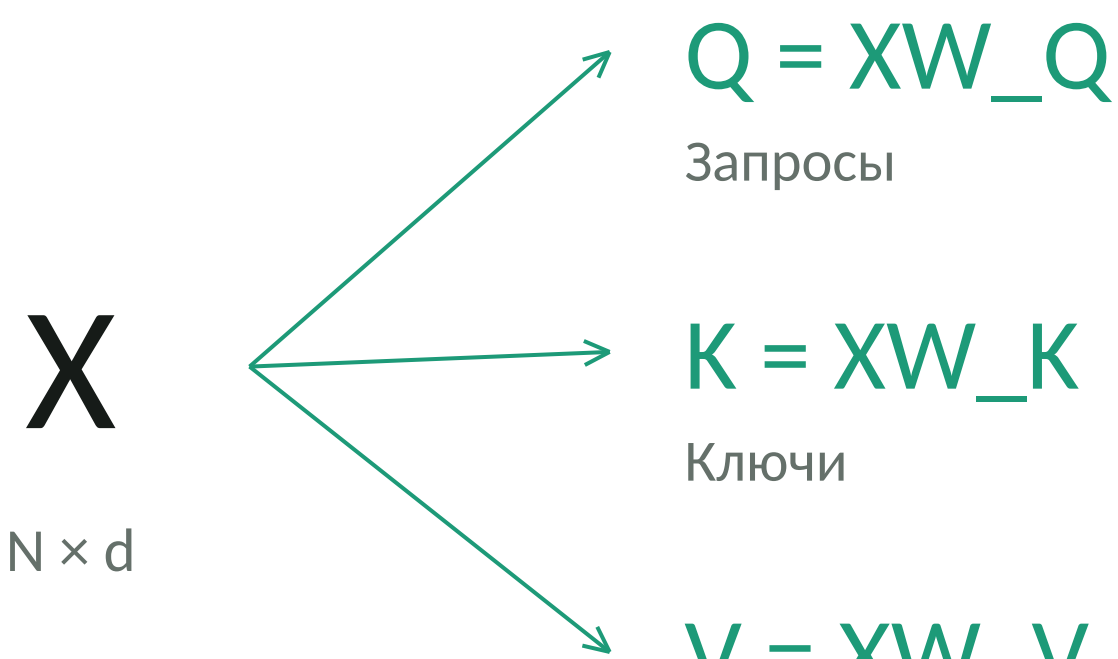
Части одного длинного обращения

Ошибка 403 → Попытки входа → Что делать?

В начале — В середине — В конце

Для ответа может понадобиться ранняя деталь

Из X получаем Q, K и V



Три обучаемые проекции одного входа

Размеры подсказывают порядок

Матрица	Размер	Роль
Q	$N \times d_k$	Запросы
K	$M \times d_k$	Ключи
V	$M \times d_v$	Значения
QK^T	$N \times M$	Все пары
AV	$N \times d_v$	Новые представления

Размерности Q и K согласованы; размерность V может отличаться

Два запроса, два ключа

$Q = K = I_2$; $d_k = 2$

Запросы и ключи	Значения V
(1; 0)	$V_1 = (10; 0)$
(0; 1)	$V_2 = (0; 20)$

Для q_1: оценки после деления на $\sqrt{2}$ равны (0,7071; 0)

Из оценок получаются веса

$$\exp(0{,}7071) \approx 2{,}028;\ \exp(0) = 1$$

$$\text{softmax}(0{,}7071;\ 0) \approx (0{,}6698;\ 0{,}3302)$$

Сумма весов равна 1

Нулевая оценка не означает нулевой вес

Выход — взвешенная сумма

Каждый вес умножается на соответствующий V

$$0{,}6698 \times (10;\ 0) + 0{,}3302 \times (0;\ 20)$$

$$O_1 \approx (6{,}6976;\ 6{,}6048)$$

Результат рассчитан с неокруглёнными весами

Расчёт для всех запросов

Запрос	Веса A	Выход O
q_1	(0,6698; 0,3302)	(6,6976; 6,6048)
q_2	(0,3302; 0,6698)	(3,3024; 13,3952)

Каждая строка нормируется отдельно; O = AV

Числа округлены для показа

Будущее закрыто до softmax

Причинная маска · недоступные оценки заменены на $-\infty$

	Ключ 1	Ключ 2
Запрос 1	1	0
Запрос 2	0,3302	0,6698

$$O_1 = V_1 = (10;\ 0)$$

Веса A после softmax · первая позиция не использует второй ключ

Что изменится при замене V2?

Q, K, V_1 и маска остаются прежними

Изменяем V_2

Изменится ли O_1?

Веса первой строки: (1; 0)

Ранний выход не изменился

Причинная маска сохранилась

$$O_1 = 1 \times V_1 + 0 \times V_2$$

O_1 остаётся равным (10; 0)

Изменение закрытого значения не влияет на этот выход

Padding исключаем из ключей

True означает доступный ключ в нашей функции

Ключ	Разрешён?
Позиция текста	True
Заполнитель PAD	False

Padding не используется как источник информации

Соглашение о булевой маске зависит от интерфейса

Когда все ключи закрыты

Все оценки строки: $(-\infty; -\infty)$

$$0 / (0 + 0)$$

Нормировка не определена

Учебная функция отклоняет такую маску

Перестановка входа и выхода

Без позиционной информации и без масок

$$\text{Attention}(\Pi X) = \Pi\,\text{Attention}(X)$$

Π — одна и та же перестановка строк

Выходные строки следуют за входными

Позиции остаются на местах

Содержимое токена и его место

$$H = X + P$$

Переставляем токены; позиции оставляем на местах

Теперь результат может измениться

У каждой головы свои проекции

Один исходный X

Голова 1	Голова 2
Свои W_Q, W_K, W_V	Другие W_Q, W_K, W_V
Свои сравнения	Другие сравнения

Языковая роль головы заранее не назначается

Соединяем результаты голов

Выходы голов → **Конкатенация** → **Проекция W_O**

Каждый: N × d_v

N × (h·d_v)

Нужная ширина модели

Конкатенация соединяет координаты; она не суммирует выходы

Внутри блока Transformer

Вариант pre-norm

$$H = X + \mathrm{Attention}(\mathrm{LayerNorm}(X))$$

$$Y = H + \mathrm{FFN}(\mathrm{LayerNorm}(H))$$

Attention включает объединение голов и выходную проекцию

Показан один из вариантов размещения LayerNorm

Разная доступность контекста

Энкодер
(пример: BERT)

Левое и правое окружение

Декодер
(авторегрессионный)

Только доступный префикс

Позиции PAD отдельно исключаются маской ключей

Cross-attention связывает два ряда

Cross-attention в encoder-decoder модели

Источник	Проекции	Последовательность
Декодер	Q	Создаваемый текст
Энкодер	K и V	Исходный текст

Запросы и источники информации относятся к разным рядам

Квадратичный рост

Память одной матрицы оценок в float32

Длина 1024

4 MiB

1024^2 элементов

Длина 4096

64 MiB

4096^2 элементов

Длина ×4 → число пар ×16

Эффективные реализации могут не хранить полную матрицу

Разные веса — тот же выход

$$V_1 = V_2 = (1; 2)$$

$$0{,}9V_1 + 0{,}1V_2 = (1; 2)$$

$$0{,}2V_1 + 0{,}8V_2 = (1; 2)$$

Разные карты весов могут дать один выход

Что проверить в реализации

Нормировка	Сумма весов допустимой строки равна 1
Запрет	Закрытый ключ получает нулевой вес
Независимость	Будущее не меняет ранний выход

Каждая проверка связана с конкретным шагом расчёта

От ручных матриц к модели

Следующая лекция

Ручные матрицы → Предобученный энкодер → Признаки для задачи

Запросы, ключи, значения и маски сохраняют свой смысл