Внимание
и Transformer

Как одна позиция получает
информацию от остальных

Нужная деталь бывает далеко

Части одного длинного обращения

Ошибка 403 → Попытки входа → Что делать?

В начале · В середине · В конце

Для ответа может понадобиться ранняя деталь

Из X получаем Q, K и V

X

N × d

Q = XW_Q
Запросы

K = XW_K
Ключи

V = XW_V
Значения

Три обучаемые проекции одного входа

Размеры подсказывают порядок

Матрица	Размер	Роль
Q	N × d_k	Запросы
K	M × d_k	Ключи
V	M × d_v	Значения
QK^T	N × M	Все пары
AV	N × d_v	Новые представления

Размерности Q и K согласованы; размерность V может отличаться

Два запроса, два ключа

$Q = K = I_2$; d_k = 2

Запросы и ключи	Значения V
(1; 0)	$V_1 = (10; 0)$
(0; 1)	$V_2 = (0; 20)$

Для q_1: оценки после деления на √2 равны (0,7071; 0)

Из оценок получаются веса

exp(0,7071) ≈ 2,028; exp(0) = 1

softmax(0,7071; 0) ≈ (0,6698; 0,3302)

Сумма весов равна 1

Нулевая оценка не означает нулевой вес

Выход — взвешенная сумма

Каждый вес умножается на соответствующий V

0,6698 × (10; 0) + 0,3302 × (0; 20)

$O_1 \approx (6{,}6976; 6{,}6048)$

Результат рассчитан с неокруглёнными весами

Расчёт для всех запросов

Запрос	Веса A	Выход O
q_1	(0,6698; 0,3302)	(6,6976; 6,6048)
q_2	(0,3302; 0,6698)	(3,3024; 13,3952)

Каждая строка нормируется отдельно; O = AV

Числа округлены для показа

Будущее закрыто до softmax

Причинная маска · недоступные оценки заменены на −∞

	Ключ 1	Ключ 2
Запрос 1	1	0
Запрос 2	0,3302	0,6698

$O_1 = V_1 = (10; 0)$

Веса A после softmax · первая позиция не использует второй ключ

Что изменится при замене V2?

Q, K, V_1 и маска остаются прежними

Изменяем V_2

Изменится ли O_1?

Веса первой строки: (1; 0)

Ранний выход не изменился

Причинная маска сохранилась

$O_1 = 1 \times V_1 + 0 \times V_2$

O_1 остаётся равным (10; 0)

Изменение закрытого значения не влияет на этот выход

Padding исключаем из ключей

True означает доступный ключ в нашей функции

Ключ	Разрешён?
Позиция текста	True
Заполнитель PAD	False

Padding не используется как источник информации

Соглашение о булевой маске зависит от интерфейса

Когда все ключи закрыты

Все оценки строки: (−∞; −∞)

0 / (0 + 0)

Нормировка не определена

Учебная функция отклоняет такую маску

Перестановка входа и выхода

Без позиционной информации и без масок

Attention(ΠX) = ΠAttention(X)

Π — одна и та же перестановка строк

Выходные строки следуют за входными

Позиции остаются на местах

Содержимое токена и его место

H = X + P

Переставляем токены; позиции оставляем на местах

Теперь результат может измениться

У каждой головы свои проекции

Один исходный X

Голова 1	Голова 2
Свои W_Q, W_K, W_V	Другие W_Q, W_K, W_V
Свои сравнения	Другие сравнения

Языковая роль головы заранее не назначается

Соединяем результаты голов

Выходы голов → Конкатенация → Проекция W_O

Каждый: N × d_v · N × (h·d_v) · Нужная ширина модели

Конкатенация соединяет координаты; она не суммирует выходы

Внутри блока Transformer

Вариант pre-norm

H = X + Attention(LayerNorm(X))

Y = H + FFN(LayerNorm(H))

Attention включает объединение голов и выходную проекцию

Показан один из вариантов размещения LayerNorm

Разная доступность контекста

Энкодер (пример: BERT)	Декодер (авторегрессионный)
Левое и правое окружение	Только доступный префикс

Позиции PAD отдельно исключаются маской ключей

Cross-attention связывает два ряда

Cross-attention в encoder-decoder модели

Источник	Проекции	Последовательность
Декодер	Q	Создаваемый текст
Энкодер	K и V	Исходный текст

Запросы и источники информации относятся к разным рядам

Квадратичный рост

Память одной матрицы оценок в float32

Длина 1024	Длина 4096
4 MiB	64 MiB
1024^2 элементов	4096^2 элементов

Длина ×4 → число пар ×16

Эффективные реализации могут не хранить полную матрицу

Разные веса — тот же выход

$V_1 = V_2 = (1; 2)$

$0{,}9V_1 + 0{,}1V_2 = (1; 2)$

$0{,}2V_1 + 0{,}8V_2 = (1; 2)$

Разные карты весов могут дать один выход

Что проверить в реализации

Нормировка	Сумма весов допустимой строки равна 1
Запрет	Закрытый ключ получает нулевой вес
Независимость	Будущее не меняет ранний выход

Каждая проверка связана с конкретным шагом расчёта

От ручных матриц к модели

Следующая лекция

Ручные матрицы → Предобученный энкодер → Признаки для задачи

Запросы, ключи, значения и маски сохраняют свой смысл