Внутри блока Transformer

Вариант pre-norm

$$H = X + \mathrm{Attention}(\mathrm{LayerNorm}(X))$$

$$Y = H + \mathrm{FFN}(\mathrm{LayerNorm}(H))$$

Attention включает объединение голов и выходную проекцию

Показан один из вариантов размещения LayerNorm