Cross-attention связывает два ряда

Cross-attention в encoder-decoder модели

Источник	Проекции	Последовательность
Декодер	Q	Создаваемый текст
Энкодер	K и V	Исходный текст

Запросы и источники информации относятся к разным рядам