Считаем весь вход модели

Подготовка входа перед вызовом модели

Шаблон → **Токенизация** → **Проверка длины**

содержимое и роли

без повторных специальных токенов

источник целиком

В этой работе вход длиннее 768 токенов отклоняется